

# Análise de Série Temporais - Trabalho 02

Prof Fernando Lucambio Pérez

Willian Meira Schlichta - GRR20159077

2019-12-02


## Modelos ARIMA

### Exercício 10

- a) Com os dados *cmort* foi ajustado um AR(2) usando regressão linear. Os dados foram coletados semanalmente ao longo dos anos, por isso a frequência utilizada para transformar os dados em uma série foi 52.

```
library(astsa)

cmort.ts = ts(cmort, freq = 52, start = c(1970,1))
par(mar=c(4,4,0,0.5))
plot.ts(cmort.ts)
```




```
x.lag1 <- lag(cmort.ts, 1)
x.lag2 <- lag(cmort.ts, 2)
```

```
dbajuste = na.omit(cbind(cmort.ts,x.lag2, x.lag1))

fit <- lm(cmort.ts ~ ., data = dbajuste)
```

No gráfico acima notamos a correlação dos erros, também na função de autocorrelação parcial (PACF) a correlação autoregressiva.


```
par(mar=c(4,4,0,0));acf2(resid(fit))
```



Consideramos o modelo bem ajustado, sendo que os resíduos estão dentro dos limites do intervalo de confiança.

- b) Uma maneira alternativa de ajustar o modelo de regressão como feito no exercício acima é utilizando a função `sarima()`. Como neste caso estamos lidando com predição, o código utilizado é o `sarima.pred()`, assim como foi feito abaixo. Um ponto de atenção é que modelos lineares são mais sensíveis a grande números quando comparado ao ajuste com `sarima()`.

```
par(mar=c(4,4,0,0));sarima.for(cmort.ts, 2,0,0, n.ahead = 4)
```



O gráfico apresenta apenas o final da série, pois esse período possui os dados mais importantes do o ajuste.

## Exercício 18

Ajustando um modelo  $AR(2)$  para a série de mortalidade cardiovascular *cmort* discutida no exercício anterior:

```
# Ajustando o AR(2)
AR2 <- arima(cmort, order=c(2,0,0))

# Usando regressão linear
mod1 <- ar.ols(cmort, order=2, demean=FALSE, intercept=TRUE)

# Usando o Yule-Walker
mod2 <- ar.yw(cmort, order=2)
```

- a) As estimativas ficaram muito próximas. A diferença é que a primeira possui estimativa para o intercepto, enquanto a segunda não.

```
# Usando regressão linear:
mod1$ar

## , , 1
##
##      [,1]
## [1,] 0.4285906
## [2,] 0.4417874
```

```
# Usando Yule-Walker:
mod2$ar
```

```
## [1] 0.4339481 0.4375768
```

- b) Valores baixos para as estimativas dos erros padrões nos dois modelos. Foram também bem próximas nos dois modelos concordando com a proposição III.10, que refere-se aos estimadores do modelo ARIMA para amostras grandes. Em outras palavras, muito provavelmente a distribuição dos estimadores para o modelo ARIMA está próxima da distribuição normal assintótica.

```
# Usando regressão linear:
mod1$asy.se.coef
```

```
## $x.mean
## [1] 2.393673
##
## $ar
## [1] 0.03979433 0.03976163
```

```
# Usando Yule-Walker:
mod2$ar
```

```
## [1] 0.4339481 0.4375768
```

```
sqrt(diag(mod2$asy.var.coef))
```


```
## [1] 0.04001303 0.04001303
```

## Exercício 20

Como o modelo depende somente dos dados amostrais, e as componentes de média móvel e autoregressivas dependem apenas das últimas realizações em cada modelo simulado, os resultados são diferentes em cada série.


```
set.seed(123)
arma_sim1 <- arima.sim(model=list(ar=c(.9),ma=c(.9)),n=500)

par(mar=c(4,4,0,0));ts.plot(arma_sim1)
```



```
par(mar=c(4,4,3,0));arma_acf1 <- acf(arma_sim1,type="correlation",plot=T)
```

series 'arma\_sim1'




```
arma_acf1
```

```
##
## Autocorrelations of series 'arma_sim1', by lag
##
##      0      1      2      3      4      5      6      7      8      9
## 1.000 0.929 0.801 0.696 0.608 0.538 0.489 0.453 0.420 0.382
##    10    11    12    13    14    15    16    17    18    19
## 0.335 0.284 0.239 0.208 0.182 0.145 0.101 0.063 0.038 0.022
##    20    21    22    23    24    25    26
## 0.013 0.010 0.010 0.001 -0.015 -0.032 -0.048
```

```
par(mar=c(4,4,3,0));arma_pacf1 <-acf(arma_sim1,type="partial",plot=T)
```

series arma\_sim1




arma\_pacf1

```
##
## Partial autocorrelations of series 'arma_sim1', by lag
##
##      1      2      3      4      5      6      7      8      9     10
## 0.929 -0.453  0.323 -0.217  0.239 -0.108  0.143 -0.126  0.045 -0.110
##     11     12     13     14     15     16     17     18     19     20
## 0.025  0.005  0.053 -0.101 -0.062 -0.032  0.058 -0.014  0.052 -0.048
##     21     22     23     24     25     26
## 0.074 -0.064 -0.020  0.001 -0.009 -0.007
```

```
ajust1 <- arima(arma_sim1, order = c(1,0,1), seasonal = c(0,0,0))
```

```
arma_sim2 <- arima.sim(model=list(ar=c(.9),ma=c(.9)),n=500)
```


```
par(mar=c(4,4,0,0));ts.plot(arma_sim2)
```



```
par(mar=c(4,4,3,0));arma_acf2 <-acf(arma_sim2,type="correlation",plot=T)
```



series arma\_sim2




```
arma_acf2
```

```
##
## Autocorrelations of series 'arma_sim2', by lag
##
##      0      1      2      3      4      5      6      7      8      9     10     11
## 1.000 0.947 0.853 0.772 0.698 0.627 0.561 0.502 0.452 0.413 0.378 0.342
##     12     13     14     15     16     17     18     19     20     21     22     23
## 0.311 0.287 0.267 0.252 0.240 0.226 0.211 0.192 0.170 0.146 0.127 0.118
##     24     25     26
## 0.115 0.113 0.106
```

```
par(mar=c(4,4,3,0));arma_pacf2 <-acf(arma_sim2,type="partial",plot=T)
```

series arma\_sim2




arma\_pacf2

```
##
## Partial autocorrelations of series 'arma_sim2', by lag
##
##      1      2      3      4      5      6      7      8      9     10
## 0.947 -0.432 0.285 -0.209 0.105 -0.081 0.053 0.016 0.033 -0.037
##     11     12     13     14     15     16     17     18     19     20
## -0.007 0.033 0.017 0.001 0.046 -0.029 0.008 -0.033 -0.029 -0.022
##     21     22     23     24     25     26
## -0.003 0.038 0.057 -0.002 -0.007 -0.037
```

```
ajust2 <- arima(arma_sim2, order = c(1,0,1), seasonal = c(0,0,0))
```


```
arma_sim3 <- arima.sim(model=list(ar=c(.9),ma=c(.9)),n=500)
```

```
par(mar=c(4,4,0,0));ts.plot(arma_sim3)
```



```
par(mar=c(4,4,3,0));arma_acf3 <- acf(arma_sim3,type="correlation",plot=T)
```


series arma\_sim3



```
arma_acf3
```

```
##
## Autocorrelations of series 'arma_sim3', by lag
##
##      0      1      2      3      4      5      6      7      8      9
## 1.000 0.949 0.851 0.760 0.677 0.597 0.518 0.445 0.381 0.316
##    10    11    12    13    14    15    16    17    18    19
## 0.251 0.194 0.145 0.102 0.059 0.016 -0.025 -0.064 -0.099 -0.126
##    20    21    22    23    24    25    26
## -0.145 -0.157 -0.164 -0.167 -0.164 -0.158 -0.150
```

```
par(mar=c(4,4,3,0));arma_pacf3<-acf(arma_sim3,type="partial",plot=T)
```



```
arma_pacf3
```

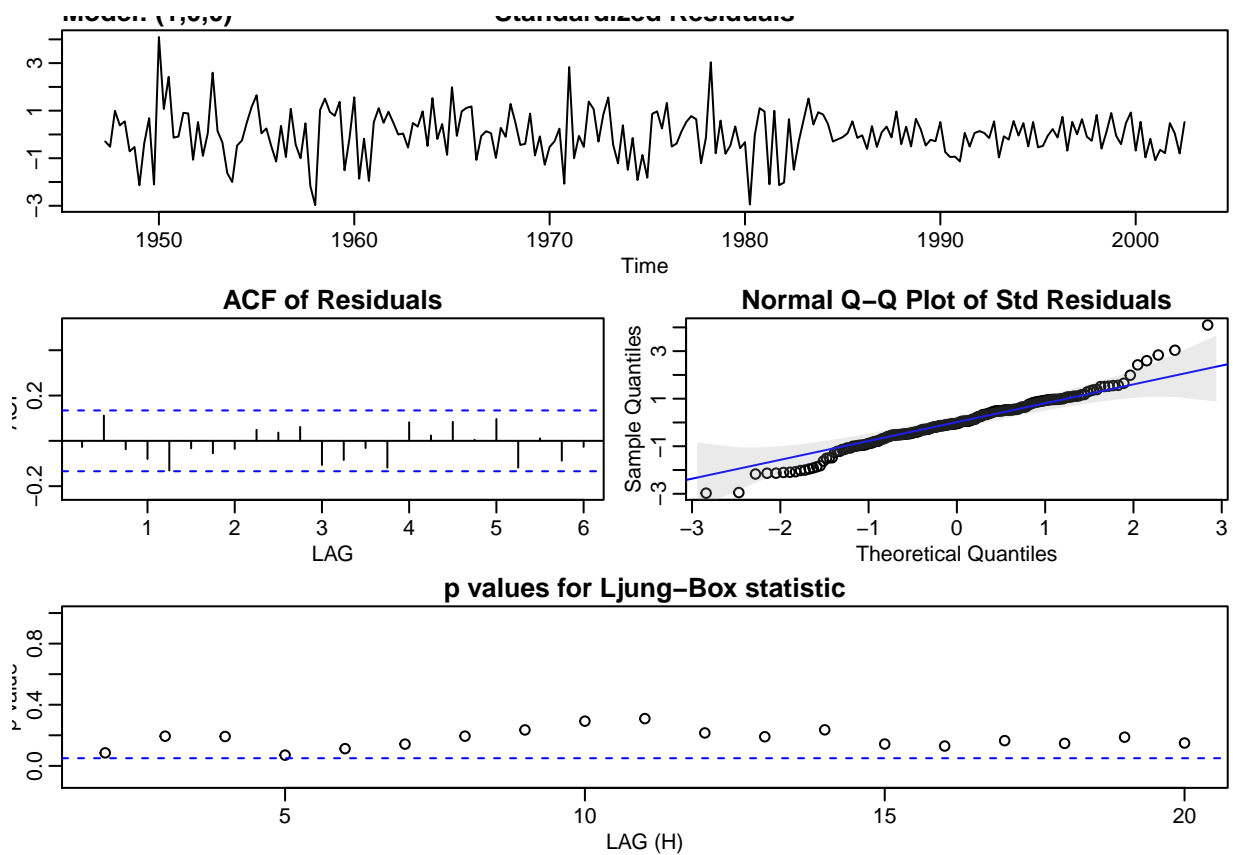
```
##
## Partial autocorrelations of series 'arma_sim3', by lag
##
##      1      2      3      4      5      6      7      8      9     10
## 0.949 -0.496  0.304 -0.222  0.074 -0.120  0.103 -0.109 -0.026 -0.030
##     11     12     13     14     15     16     17     18     19     20
## 0.028 -0.026 -0.018 -0.063 -0.001 -0.067 -0.007  0.002  0.006  0.001
##     21     22     23     24     25     26
## 0.006  0.007 -0.003  0.024 -0.022  0.016
```

```
ajust3 <- arima(arma_sim3, order = c(1,0,1), seasonal = c(0,0,0))
```

## Exercício 31


- I) Gráfico de resíduos padronizados: semelhante ao exemplo III.40, não há padrões claros no gráfico. Porém, devido a presença de valores discrepantes, algumas observações apresentam valores acima de três desvios padrões.
- II) ACF dos resíduos: não há nenhuma presença de auto-correlação evidente.
- III) Q-Qplot dos resíduos padronizados: há presença de valores discrepantes nas caudas. As observações entre -1 e 2 quantis teóricos estão bem ajustadas.
- IV) p-valores da estatística Q de Ljung-Box: nenhum p-valor abaixo do nível de significância, evidenciando a independência entre os resíduos.

```
gnpgr <- diff(log(gnp))
(Ex31 <- sarima(gnpgr,1,0,0))
```




### Exercício 36

- a) O comportamento da série temporal referente a variável preço mediano anual de varejo por GB de discos rígidos está apresentado na figura a seguir. De modo geral, é possível notar que a série não apresenta um comportamento estável ao longo do tempo. Inicialmente, há um aumento no valor da variável até 1983 e, na sequência, há uma evidente tendência de decrescimento da variável ao longo do tempo. Porém, a taxa de mudança nos valores da variável entre anos consecutivos é pequena a partir de 1988. Logo, os valores da variável se mostram bastante estáveis após 1990.



- b) O ajuste do modelo de regressão linear com a variável resposta transformada pelo logaritmo está apresentada na sequência. É possível notar que a transformação aplicada aos dados linearizou a relação da variável resposta e o tempo. Assim, o modelo de regressão linear apresentou um ajuste satisfatório aos dados e com elevado valor de coeficiente de determinação ajustado.



```
##
## Call:
## lm(formula = I(log(cpg)) ~ t, data = da)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.77156 -0.39840  0.04726  0.42186  1.13129
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1172.49431    27.57793   42.52  <2e-16 ***
## t           -0.58508     0.01383  -42.30  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.6231 on 27 degrees of freedom
## Multiple R-squared:  0.9851, Adjusted R-squared:  0.9846
## F-statistic: 1790 on 1 and 27 DF,  p-value: < 2.2e-16
```



- c) O gráfico Half-Normal plot sugere que o modelo está bem especificado e ajustado aos dados, uma vez que há apenas uma observação fora dos envelopes simulados. Porém, o gráfico de dispersão dos resíduos ordinários em relação ao tempo mostra uma variância não constante ao longo do tempo, com um padrão cúbico dos resíduos. Esse resultado sugere a possibilidade de incluir a covariável tempo com seu efeito de terceiro grau, isto é, o tempo pode ser inserido com uma especificação polinomial de grau três no preditor linear. O histograma dos resíduos indicou normalidade, a qual foi confirmada pelo teste de normalidade de Shapiro-Wilk, em que a hipótese nula não foi rejeitada, para nível de 5% de significância. Por fim, o gráfico de autocorrelação dos resíduos indicou que há baixa correlação temporal.



```
## Gaussian model (lm object)
```





```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(fit)
```

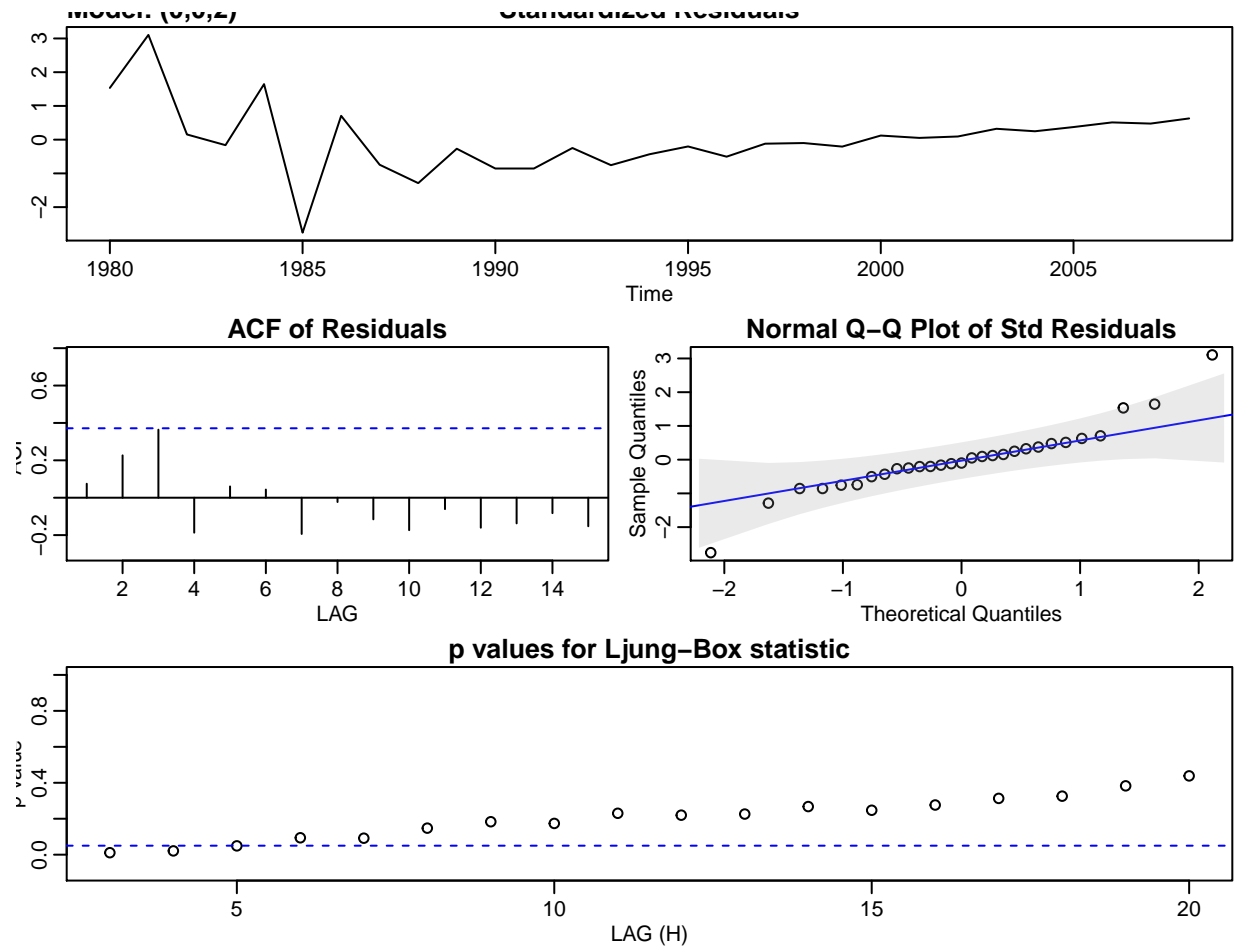
## W = 0.96464, p-value = 0.4251



- d) O modelo de regressão ajustado para erros autocorrelacionados foi o SARIMA(0,0,2), isto é, o modelo ajustado foi um SARIMA com médias móveis de ordem dois. A figura apresentada na sequência mostra que os resíduos padronizados estão estáveis a partir do ano de 1990 entre anos consecutivos. Ainda, os resíduos do modelo ajustado se mostram não correlacionados. Também é possível notar que a distribuição dos resíduos se aproxima de uma distribuição normal, com apenas dois valores extremos

no gráfico qqplot. Por fim, é possível observar que o p-valor do teste Ljung-Box aumenta em função da defasagem, sugerindo que a hipótese nula de que os resíduos são independentes e identicamente distribuídos não é rejeitada para grande valores de defasagem.

```
## initial value 10.952140
## iter 2 value 10.383886
## iter 3 value 10.359737
## iter 4 value 10.346885
## iter 5 value 10.342800
## iter 6 value 10.341432
## iter 7 value 10.339494
## iter 8 value 10.339453
## iter 9 value 10.339440
## iter 10 value 10.339440
## iter 10 value 10.339439
## final value 10.339439
## converged
## initial value 10.344527
## iter 2 value 10.342504
## iter 3 value 10.330557
## iter 4 value 10.329140
## iter 5 value 10.328806
## iter 6 value 10.328739
## iter 7 value 10.328733
## iter 7 value 10.328733
## iter 7 value 10.328733
## final value 10.328733
## converged
```




```
## $fit
##
## Call:
## stats::arima(x = xdata, order = c(p, d, q), seasonal = list(order = c(P, D,
##     Q), period = S), xreg = xreg, transform.pars = trans, fixed = fixed, optim.control = list(trace =
##     REPORT = 1, reltol = tol))
##
## Coefficients:
##      ma1      ma2  intercept      xreg
##      1.1476  0.7952  13017176 -6505.744
## s.e.  0.1864  0.2297   3542405  1776.370
##
## sigma^2 estimated as 858241410:  log likelihood = -340.68,  aic = 691.36
##
## $degrees_of_freedom
## [1] 25
##
## $ttable
##           Estimate      SE t.value p.value
## ma1          1.1476    0.1864  6.1558  0.0000
## ma2           0.7952    0.2297  3.4618  0.0019
## intercept 13017176.3326 3542404.9251  3.6747  0.0011
## xreg        -6505.7441   1776.3696 -3.6624  0.0012
##
```

```
## $AIC
## [1] 23.84017
##
## $AICc
## [1] 23.89764
##
## $BIC
## [1] 24.07591
```

## Análise Espectral e Filtragem

### Exercício 6A



```
##
## Call:
## arima(x = data[, 1], order = c(0, 0, 0), seasonal = list(order = c(0, 1, 1),
##   period = 12))
##
## Coefficients:
##          sma1
##        -0.8670
## s.e.    0.0285
##
## sigma^2 estimated as 0.1816:  log likelihood = -252.46,  aic = 508.91
##
```

```
## Call:
## arima(x = data[, 2], order = c(0, 0, 0), seasonal = list(order = c(0, 1, 1),
##   period = 12))
##
## Coefficients:
##      sma1
##      -0.8878
## s.e.    0.0330
##
## sigma^2 estimated as 0.1998:  log likelihood = -280.57,  aic = 565.13
```

## Exercício 6B

Os resultados encontrados sugerem três tipos de comportamento para as séries analisadas. Inicialmente, há correlação cruzada negativa, a qual vai diminuindo até não haver correlação. Posteriormente, há correlação cruzada positiva, seguido de correlação cruzada negativa. Os comportamentos distintos podem ser atribuídos a sazonalidade dos dados.

