

# Modelos Marginais: Estimadores GLS e GEE

José Luiz Padilha da Silva

11 de setembro de 2019

## Exemplo 1: Crianças Expostas ao Chumbo

O estudo *Tratamento de Crianças Expostas ao Chumbo (TLC)* foi um ensaio clínico aleatorizado envolvendo crianças com níveis de chumbo no sangue entre 20 – 44 microgramas/dL. Os grupos de comparação são placebo e um tratamento ativo. Os dados consistem de quatro medidas repetidas de níveis de chumbo no sangue obtidos na linha de base (semana 0), semana 1, semana 4 e semana 6 em 100 crianças aleatoriamente alocadas entre os dois grupos.

### Análise Exploratória

```
library(reshape); library(plyr); library(nlme); library(ggplot2); library(geepack)
datawide <- read.table("https://docs.ufpr.br/~jlpadilha/CE075/Datasets/chumbo.txt",
                      header=TRUE)
head(datawide)
```

```
##   ID Grupo Sem0 Sem1 Sem4 Sem6
## 1  1     P 30.8 26.9 25.8 23.8
## 2  2     A 26.5 14.8 19.5 21.0
## 3  3     A 25.8 23.0 19.1 23.2
## 4  4     P 24.7 24.5 22.0 22.5
## 5  5     A 20.4  2.8  3.2  9.4
## 6  6     A 20.4  5.4  4.5 11.9
```

Os dados estão no formato *largo*, no qual cada indivíduo é representado por uma linha e as medidas repetidas são apresentadas por colunas. A seguir um resumo das observações por grupo.

```
summary(subset(datawide, Grupo=="A")[,3:6]) #Grupo tratamento
```

```
##           Sem0           Sem1           Sem4           Sem6
## Min.      :19.70   Min.      : 2.800   Min.      : 3.000   Min.      : 4.10
## 1st Qu.:22.12   1st Qu.: 7.225   1st Qu.: 9.125   1st Qu.:15.40
## Median :26.20   Median :12.250   Median :15.350   Median :18.85
## Mean     :26.54   Mean     :13.522   Mean     :15.514   Mean     :20.76
## 3rd Qu.:29.55   3rd Qu.:17.500   3rd Qu.:19.725   3rd Qu.:23.75
## Max.     :41.10   Max.     :39.000   Max.     :40.400   Max.     :63.90
```

```
summary(subset(datawide, Grupo=="P")[,3:6]) #Grupo controle
```

```
##           Sem0           Sem1           Sem4           Sem6
## Min.      :19.70   Min.      :14.90   Min.      :15.30   Min.      :13.50
## 1st Qu.:21.88   1st Qu.:20.93   1st Qu.:19.82   1st Qu.:19.95
## Median :25.25   Median :24.10   Median :22.45   Median :22.35
## Mean     :26.27   Mean     :24.66   Mean     :24.07   Mean     :23.65
## 3rd Qu.:29.73   3rd Qu.:27.82   3rd Qu.:27.45   3rd Qu.:27.50
## Max.     :38.10   Max.     :40.80   Max.     :38.60   Max.     :43.30
```

Nota-se uma pequena diminuição das médias dos níveis de chumbo no grupo controle ao longo do tempo. Para o grupo tratamento há um grande decréscimo do baseline para a primeira semana e subseqüentes aumentos nas semanas seguintes.

Temos as seguintes estimativas para as correlações:

```
round(cor(datawide[,3:6]),2) #Todos os indivíduos
```

```
##      Sem0 Sem1 Sem4 Sem6
## Sem0 1.00 0.42 0.47 0.56
## Sem1 0.42 1.00 0.84 0.56
## Sem4 0.47 0.84 1.00 0.58
## Sem6 0.56 0.56 0.58 1.00
```

```
round(cor(subset(datawide, Grupo=="A"),[,3:6]),2) # Grupo tratamento
```


```
##      Sem0 Sem1 Sem4 Sem6
## Sem0 1.00 0.40 0.38 0.50
## Sem1 0.40 1.00 0.73 0.51
## Sem4 0.38 0.73 1.00 0.45
## Sem6 0.50 0.51 0.45 1.00
```

```
round(cor(subset(datawide, Grupo=="P"),[,3:6]),2) # Grupo controle
```

```
##      Sem0 Sem1 Sem4 Sem6
## Sem0 1.00 0.83 0.84 0.76
## Sem1 0.83 1.00 0.86 0.76
## Sem4 0.84 0.86 1.00 0.87
## Sem6 0.76 0.76 0.87 1.00
```

A seguir os boxplots marginais

```
with(datawide, boxplot(Sem0,Sem1,Sem4,Sem6,ylab="pb (mg/dl)",xlab="Semana"))
axis(1, 1:4, c(0,1,4,6))
```



Devemos ter cuidado pois o boxplot não considera a estrutura longitudinal dos dados.


É mais conveniente trabalharmos com os dados no formato *longo*, no qual cada variável é representada por uma coluna e há uma linha para cada medida repetida do indivíduo. Vamos usar a função `reshape` do pacote de mesmo nome.

```
datalong <- reshape(data=datawide,direction="long", idvar="ID", v.names="chumbo",
                    varying = list(names(datawide)[3:6]), time= c(0,1,4,6), timevar="tempo")
datalong <- arrange(datalong, ID); head(datalong, 8)
```

```
##   ID Grupo tempo chumbo
## 1  1     P     0   30.8
## 2  1     P     1   26.9
## 3  1     P     4   25.8
## 4  1     P     6   23.8
## 5  2     A     0   26.5
## 6  2     A     1   14.8
## 7  2     A     4   19.5
## 8  2     A     6   21.0
```

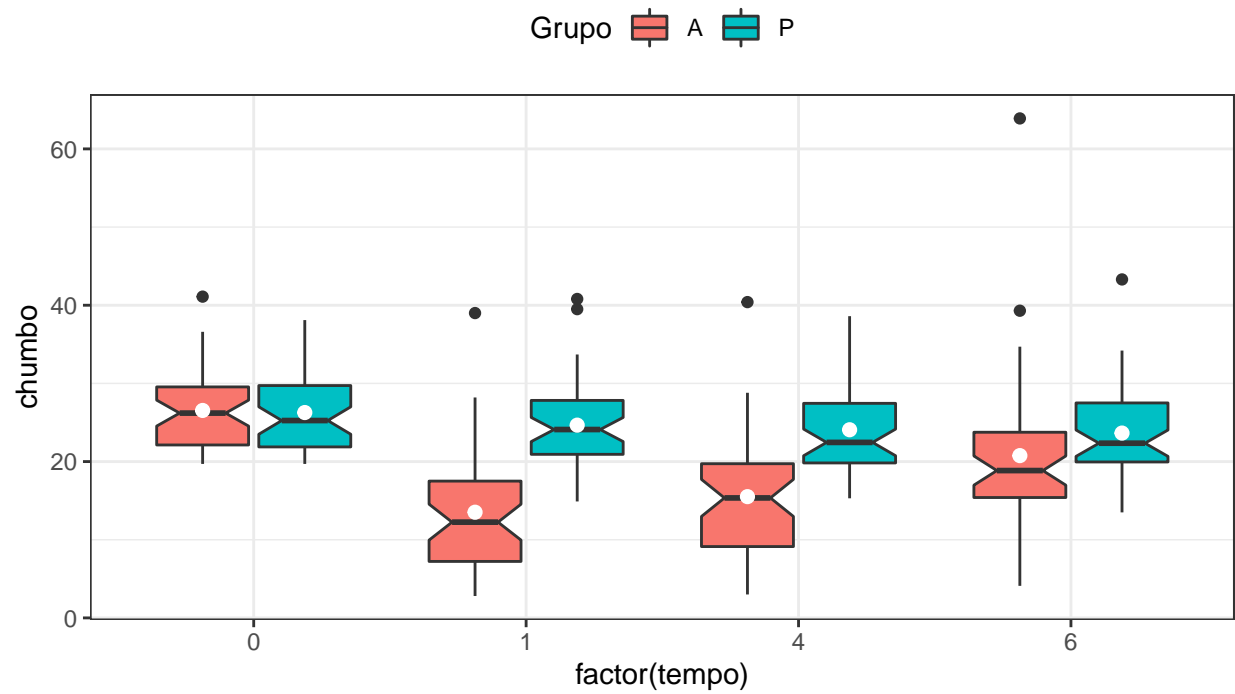
A representação gráfica mais interessante para as respostas em nível individual é o gráfico de perfis:

```
p1 <- ggplot(datalong, aes(x=tempo, y=chumbo, color=Grupo)) + theme_bw() +
  geom_line(aes(group=ID)) + theme(legend.position="top") +
  scale_x_continuous(breaks=unique(datalong$tempo))
p1
```



Podemos examinar as diferenças dentro de cada tempo por meio de boxplots:

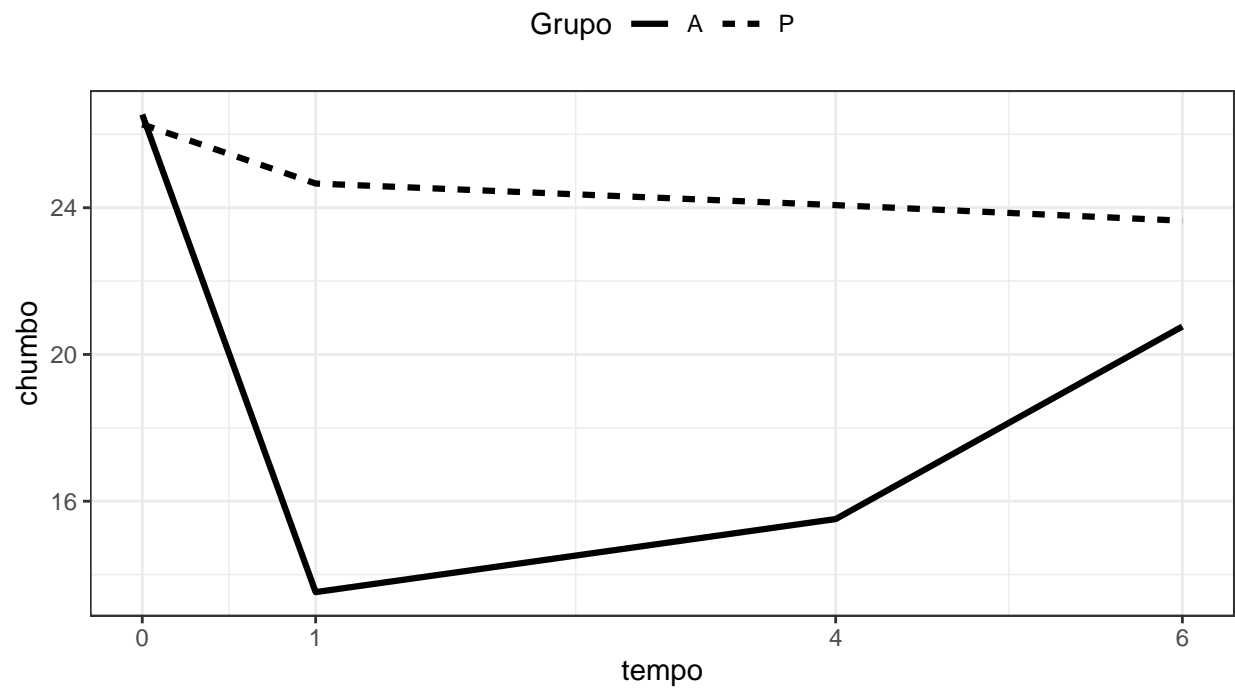
```
p2 <- ggplot(datalong, aes(x=factor(tempo), y=chumbo, fill=Grupo)) + geom_boxplot(notch=TRUE) +
  theme_bw() + theme(legend.position="top") + stat_summary(fun.y="mean", geom="point", size=2,
  position=position_dodge(width=0.75), color="white", show.legend=FALSE)
p2
```



Da ajuda do `geom_boxplot`: *In a notched box plot, the notches extend  $1.58IQR / \sqrt{n}$ . This gives a roughly 95% confidence interval for comparing medians. See McGill et al. (1978) for more details.*

Os valores centrais em branco representam as médias.

```
p3 <- ggplot(datalong, aes(x=tempo, y=chumbo, group = Grupo, shape = Grupo)) + theme_bw() +
  stat_summary(fun.y="mean", geom="line", size=1.1, aes(linetype = Grupo)) +
  theme(legend.position="top") + scale_x_continuous(breaks=unique(datalong$tempo)); p3
```



Como vimos, as maiores diferenças ocorrem no tempo 1 e vão diminuindo ao longo das semanas. Passaremos aos ajustes dos modelos marginais por mínimos quadrados generalizados. Consideraremos as estruturas de correlação do tipo *independente*, *simetria composta*, *AR(1)* e *não estruturada*.

## Formulação 1: Modelo linear de efeitos fixos (com intercepto)

O primeiro modelo é da forma `chumbo ~ tempo*Grupo` e tem a seguinte representação:

$$E(Y_{ij}) = \beta_1 + \beta_2 I(\text{tempo}_j = 1) + \beta_3 I(\text{tempo}_j = 4) + \beta_4 I(\text{tempo}_j = 6) + \beta_5 I(\text{Grupo}_i = P) + \beta_6 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 1) + \beta_7 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 4) + \beta_8 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 6).$$

## Estimador GEE

Para fazer o ajuste GEE no R podemos utilizar os seguintes comandos:

```
datalong$tempo=as.factor(datalong$tempo); datalong$Grupo=as.factor(datalong$Grupo)
gee1a.ind<-geeglm(chumbo ~ tempo*Grupo, corstr="independence", id=ID,
                  family="gaussian", data=datalong) #Independente
gee1a.exch<-geeglm(chumbo ~ tempo*Grupo, corstr="exchangeable", id=ID,
                  family="gaussian", data=datalong) #Simetria composta
gee1a.ar1<-geeglm(chumbo ~ tempo*Grupo, corstr="ar1", id=ID,
                  data=datalong) #AR(1)
gee1a.unst<-geeglm(chumbo ~ tempo*Grupo, corstr="unstructured", id=ID,
                  data=datalong) #Não estruturada
```

Os resultados dos ajustes são:

```
# Independente
round(coef(summary(gee1a.ind)),3)
```

##	Estimate	Std.err	Wald	Pr(> W )
## (Intercept)	26.540	0.703	1425.530	0.000
## tempo1	-13.018	1.021	162.690	0.000
## tempo4	-11.026	1.053	109.606	0.000
## tempo6	-5.778	1.126	26.313	0.000
## GrupoP	-0.268	0.994	0.073	0.788
## tempo1:GrupoP	11.406	1.109	105.840	0.000
## tempo4:GrupoP	8.824	1.141	59.820	0.000
## tempo6:GrupoP	3.152	1.244	6.421	0.011

```
# Simetria composta
round(coef(summary(gee1a.exch)),3)
```

##	Estimate	Std.err	Wald	Pr(> W )
## (Intercept)	26.540	0.703	1425.530	0.000
## tempo1	-13.018	1.021	162.690	0.000
## tempo4	-11.026	1.053	109.606	0.000
## tempo6	-5.778	1.126	26.313	0.000
## GrupoP	-0.268	0.994	0.073	0.788
## tempo1:GrupoP	11.406	1.109	105.840	0.000
## tempo4:GrupoP	8.824	1.141	59.820	0.000
## tempo6:GrupoP	3.152	1.244	6.421	0.011

```
# AR(1)
round(coef(summary(gee1a.ar1)),3)
```

```
##           Estimate Std.err      Wald Pr(>|W|)
## (Intercept)      26.540   0.703 1425.530   0.000
## tempo1          -13.018   1.021  162.690   0.000
## tempo4          -11.026   1.053  109.606   0.000
## tempo6           -5.778   1.126   26.313   0.000
## GrupoP          -0.268   0.994    0.073   0.788
## tempo1:GrupoP    11.406   1.109  105.840   0.000
## tempo4:GrupoP     8.824   1.141   59.820   0.000
## tempo6:GrupoP     3.152   1.244    6.421   0.011
```

*# Não estruturada*

```
round(coef(summary(gee1a.unst)),3)
```

```
##           Estimate Std.err      Wald Pr(>|W|)
## (Intercept)      26.540   0.703 1425.530   0.000
## tempo1          -13.018   1.021  162.690   0.000
## tempo4          -11.026   1.053  109.606   0.000
## tempo6           -5.778   1.126   26.313   0.000
## GrupoP          -0.268   0.994    0.073   0.788
## tempo1:GrupoP    11.406   1.109  105.840   0.000
## tempo4:GrupoP     8.824   1.141   59.820   0.000
## tempo6:GrupoP     3.152   1.244    6.421   0.011
```

Note a concordância das inferências mesmo considerando estruturas de correlação de trabalho bastante distintas.

```
round(summary(gee1a.ind)$corr,3)
```

```
## [1] Estimate Std.err
## <0 rows> (or 0-length row.names)
```

```
round(summary(gee1a.exch)$corr,3)
```

```
##           Estimate Std.err
## alpha      0.595   0.072
```

```
round(summary(gee1a.ar1)$corr,3)
```

```
##           Estimate Std.err
## alpha      0.733   0.052
```

```
round(summary(gee1a.unst)$corr,3)
```

```
##           Estimate Std.err
## alpha.1:2      0.435   0.076
## alpha.1:3      0.449   0.085
## alpha.1:4      0.506   0.058
## alpha.2:3      0.809   0.112
## alpha.2:4      0.676   0.104
## alpha.3:4      0.698   0.137
```

Vamos comparar as estimativas do modelo marginal dadas pelo GEE com aquelas do estimador GLS para as mesmas estruturas de correlação.

## Estimador GLS

Fazemos o ajuste no R através dos seguintes comandos:

```

gls1a.ind<-gls(chumbo ~ tempo*Grupo, data=datalong) #Independente
gls1a.exch<-gls(chumbo ~ tempo*Grupo, correlation=corCompSymm(form=~1|ID),
               data=datalong) #Simetria composta
gls1a.ar1<-gls(chumbo ~ tempo*Grupo, correlation=corAR1(form=~1|ID),
               data=datalong) #AR(1)
gls1a.unst<-gls(chumbo ~ tempo*Grupo, correlation=corSymm(form=~1|ID),
               data=datalong) #Não estruturada

```

Os resultados são:

*# Independente*

```
round(coef(summary(gls1a.ind)),3)
```

##		Value	Std.Error	t-value	p-value
##	(Intercept)	26.540	0.937	28.324	0.000
##	tempo1	-13.018	1.325	-9.824	0.000
##	tempo4	-11.026	1.325	-8.321	0.000
##	tempo6	-5.778	1.325	-4.360	0.000
##	GrupoP	-0.268	1.325	-0.202	0.840
##	tempo1:GrupoP	11.406	1.874	6.086	0.000
##	tempo4:GrupoP	8.824	1.874	4.709	0.000
##	tempo6:GrupoP	3.152	1.874	1.682	0.093

*# Simetria composta*

```
round(coef(summary(gls1a.exch)),3)
```

##		Value	Std.Error	t-value	p-value
##	(Intercept)	26.540	0.937	28.324	0.000
##	tempo1	-13.018	0.843	-15.445	0.000
##	tempo4	-11.026	0.843	-13.082	0.000
##	tempo6	-5.778	0.843	-6.855	0.000
##	GrupoP	-0.268	1.325	-0.202	0.840
##	tempo1:GrupoP	11.406	1.192	9.569	0.000
##	tempo4:GrupoP	8.824	1.192	7.403	0.000
##	tempo6:GrupoP	3.152	1.192	2.644	0.009

*# AR(1)*

```
round(coef(summary(gls1a.ar1)),3)
```

##		Value	Std.Error	t-value	p-value
##	(Intercept)	26.540	0.932	28.482	0.000
##	tempo1	-13.018	0.801	-16.261	0.000
##	tempo4	-11.026	1.022	-10.785	0.000
##	tempo6	-5.778	1.140	-5.067	0.000
##	GrupoP	-0.268	1.318	-0.203	0.839
##	tempo1:GrupoP	11.406	1.132	10.075	0.000
##	tempo4:GrupoP	8.824	1.446	6.103	0.000
##	tempo6:GrupoP	3.152	1.613	1.955	0.051

*# Não estruturada*

```
round(coef(summary(gls1a.unst)),3)
```

##		Value	Std.Error	t-value	p-value
##	(Intercept)	26.540	0.937	28.310	0.000
##	tempo1	-13.018	0.843	-15.450	0.000
##	tempo4	-11.026	0.858	-12.856	0.000
##	tempo6	-5.778	0.903	-6.396	0.000

```
## GrupoP      -0.268      1.326 -0.202  0.840
## tempo1:GrupoP 11.406      1.192  9.572  0.000
## tempo4:GrupoP  8.824      1.213  7.275  0.000
## tempo6:GrupoP  3.152      1.278  2.467  0.014
```

Observe como os erros padrões estimados dependem da escolha da estrutura de correlação. Isso ocorre apesar da coincidência nas estimativas pontuais dos parâmetros de média.

```
gls1a.ind$modelStruct$corStruct
```

```
## NULL
```

```
gls1a.exch$modelStruct$corStruct
```

```
## Correlation structure of class corCompSymm representing
##      Rho
## 0.5954401
```

```
gls1a.ar1$modelStruct$corStruct
```

```
## Correlation structure of class corAR1 representing
##      Phi
## 0.6309418
```

```
gls1a.unst$modelStruct$corStruct
```

```
## Correlation structure of class corSymm representing
## Correlation:
##  1      2      3
## 2 0.596
## 3 0.582 0.769
## 4 0.536 0.552 0.551
```

Podemos comparar as diferentes estruturas de correlação por meio dos critérios AIC e BIC para estruturas gerais (não encaixadas) e via teste de razão de verossimilhanças para modelos encaixados.

```
anova(gls1a.unst, gls1a.exch)
```

```
##           Model df      AIC      BIC    logLik    Test  L.Ratio p-value
## gls1a.unst     1 15 2471.632 2531.200 -1220.816
## gls1a.exch     2 10 2480.621 2520.334 -1230.311 1 vs 2 18.98944  0.0019
```

```
anova(gls1a.unst, gls1a.ar1)
```

```
##           Model df      AIC      BIC    logLik    Test  L.Ratio p-value
## gls1a.unst     1 15 2471.632 2531.200 -1220.816
## gls1a.ar1      2 10 2492.631 2532.343 -1236.315 1 vs 2 30.99904 <.0001
```

```
anova(gls1a.exch, gls1a.ar1)
```

```
##           Model df      AIC      BIC    logLik
## gls1a.exch     1 10 2480.621 2520.334 -1230.311
## gls1a.ar1      2 10 2492.631 2532.343 -1236.315
```

Pelo teste da razão de verossimilhanças escolhemos o modelo com correlação não estruturada. O critério AIC também identifica a correlação não estruturada como a melhor escolha; já o BIC elege a correlação simetria composta.

Como consideramos o tempo como fator e efeito de interação tempo e grupo, podemos testar a diferença entre os grupos para um tempo especificado. Seja  $\delta_j$ ,  $j = 1, \dots, 4$  a verdadeira diferença entre os grupos



tratamento e controle no tempo  $j$ . Para  $j = 4$  (seis semanas), por exemplo, o modelo especifica:

$$\begin{aligned}\hat{E}(Y_{i4}|\text{grupo}_i = P) &= \hat{\beta}_1 + \hat{\beta}_4, \\ \hat{E}(Y_{i4}|\text{grupo}_i = A) &= \hat{\beta}_1 + \hat{\beta}_4 + \hat{\beta}_5 + \hat{\beta}_8.\end{aligned}$$

Assumindo correlação de trabalho não estruturada e estimador GLS, temos

$$\hat{\delta}_4 = \hat{\beta}_5 + \hat{\beta}_8$$

```
delta4 <- as.numeric(coef(gls1a.unst)[5]+coef(gls1a.unst)[8])
delta4
```

```
## [1] 2.884
```

A variância estimada de  $\hat{\delta}$  é dada por:

$$\widehat{Var}(\hat{\delta}_4) = \widehat{Var}(\hat{\beta}_5) + \widehat{Var}(\hat{\beta}_8) + 2\widehat{Cov}(\hat{\beta}_5, \hat{\beta}_8).$$

```
var.beta <- vcov(gls1a.unst)
round(var.beta,2)
```

```
##          (Intercept) tempo1 tempo4 tempo6 GrupoP tempo1:GrupoP
## (Intercept)          0.88 -0.35 -0.37 -0.41 -0.88          0.35
## tempo1             -0.35  0.71  0.52  0.37  0.35         -0.71
## tempo4             -0.37  0.52  0.74  0.38  0.37         -0.52
## tempo6             -0.41  0.37  0.38  0.82  0.41         -0.37
## GrupoP             -0.88  0.35  0.37  0.41  1.76         -0.71
## tempo1:GrupoP        0.35 -0.71 -0.52 -0.37 -0.71          1.42
## tempo4:GrupoP        0.37 -0.52 -0.74 -0.38 -0.74          1.04
## tempo6:GrupoP        0.41 -0.37 -0.38 -0.82 -0.82          0.74
##          tempo4:GrupoP tempo6:GrupoP
## (Intercept)          0.37          0.41
## tempo1             -0.52         -0.37
## tempo4             -0.74         -0.38
## tempo6             -0.38         -0.82
## GrupoP             -0.74         -0.82
## tempo1:GrupoP        1.04          0.74
## tempo4:GrupoP        1.47          0.76
## tempo6:GrupoP        0.76          1.63
```

Logo, temos:

```
var.delta4 <- as.numeric(diag(var.beta)[5]+diag(var.beta)[8]+2*var.beta[5,8])
var.delta4
```

```
## [1] 1.757711
```

```
sqrt(var.delta4)
```

```
## [1] 1.325787
```

A estatística de teste é:

```
delta4/sqrt(var.delta4)
```

```
## [1] 2.175312
```

Observamos uma diferença estatisticamente significativa entre os grupos. Contudo, é mais direto realizar comparações como essa por meio de outra especificação do preditor linear. O modelo permanecerá o mesmo mas as comparações dentro de cada tempo serão mais diretas, pois envolverão apenas um parâmetro.

## Formulação 2: Modelo linear de efeitos fixos (sem intercepto)

O segundo modelo é da forma  $\text{chumbo} \sim \text{tempo} * \text{Grupo} - \text{Grupo} - 1$  e tem a seguinte representação:

$$E(Y_{ij}) = \beta_1 I(\text{tempo}_j = 0) + \beta_2 I(\text{tempo}_j = 1) + \beta_3 I(\text{tempo}_j = 4) + \beta_4 I(\text{tempo}_j = 6) + \\ \beta_5 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 0) + \beta_6 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 1) + \\ \beta_7 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 4) + \beta_8 I(\text{Grupo}_i = P) \times I(\text{tempo}_j = 6).$$

Os quatro últimos parâmetros permitem a comparação entre os dois grupos. Eles representam diretamente as estimativas de  $\delta_j$ ,  $j = 1, \dots, 4$ .

### Estimador GEE

```
gee1b.ind<-geeglm(chumbo ~ tempo*Grupo - Grupo - 1, corstr="independence", id=ID,
                  family="gaussian", data=datalong) #Independente
gee1b.exch<-geeglm(chumbo ~ tempo*Grupo - Grupo - 1, corstr="exchangeable", id=ID,
                  family="gaussian", data=datalong) #Simetria composta
gee1b.ar1<-geeglm(chumbo ~ tempo*Grupo - Grupo - 1, corstr="ar1", id=ID, data=datalong) #AR(1)
gee1b.unst<-geeglm(chumbo ~ tempo*Grupo - Grupo - 1, corstr="unstructured", id=ID,
                  data=datalong) #Não estruturada
```

As estimativas são dadas por:

```
# Independente
```

```
round(coef(summary(gee1b.ind)),3)
```

##	Estimate	Std.err	Wald	Pr(> W )
## tempo0	26.540	0.703	1425.530	0.000
## tempo1	13.522	1.074	158.472	0.000
## tempo4	15.514	1.099	199.163	0.000
## tempo6	20.762	1.294	257.243	0.000
## tempo0:GrupoP	-0.268	0.994	0.073	0.788
## tempo1:GrupoP	11.138	1.318	71.363	0.000
## tempo4:GrupoP	8.556	1.363	39.417	0.000
## tempo6:GrupoP	2.884	1.516	3.618	0.057

```
# Simetria composta
```

```
round(coef(summary(gee1b.exch)),3)
```

##	Estimate	Std.err	Wald	Pr(> W )
## tempo0	26.540	0.703	1425.530	0.000
## tempo1	13.522	1.074	158.472	0.000
## tempo4	15.514	1.099	199.163	0.000
## tempo6	20.762	1.294	257.243	0.000
## tempo0:GrupoP	-0.268	0.994	0.073	0.788
## tempo1:GrupoP	11.138	1.318	71.363	0.000
## tempo4:GrupoP	8.556	1.363	39.417	0.000
## tempo6:GrupoP	2.884	1.516	3.618	0.057

```
# AR(1)
```

```
round(coef(summary(gee1b.ar1)),3)
```

##	Estimate	Std.err	Wald	Pr(> W )
## tempo0	26.540	0.703	1425.530	0.000
## tempo1	13.522	1.074	158.472	0.000
## tempo4	15.514	1.099	199.163	0.000
## tempo6	20.762	1.294	257.243	0.000

```
## tempo0:GrupoP -0.268 0.994 0.073 0.788
## tempo1:GrupoP 11.138 1.318 71.363 0.000
## tempo4:GrupoP 8.556 1.363 39.417 0.000
## tempo6:GrupoP 2.884 1.516 3.618 0.057
```

*# Não estruturada*

```
round(coef(summary(gee1b.unst)),3)
```

```
##           Estimate Std.err      Wald Pr(>|W|)
## tempo0      26.540   0.703 1425.530   0.000
## tempo1      13.522   1.074  158.472   0.000
## tempo4      15.514   1.099  199.163   0.000
## tempo6      20.762   1.294  257.243   0.000
## tempo0:GrupoP -0.268   0.994   0.073   0.788
## tempo1:GrupoP 11.138   1.318  71.363   0.000
## tempo4:GrupoP 8.556   1.363  39.417   0.000
## tempo6:GrupoP 2.884   1.516   3.618   0.057
```

## Estimador GLS

```
gls1b.ind<-glS(chumbo ~ tempo*Grupo - Grupo - 1, data=datalong) #Independente
gls1b.exch<-glS(chumbo ~ tempo*Grupo - Grupo - 1,
               correlation=corCompSymm (form=~1|ID), data=datalong) #Simetria Composta
gls1b.ar1<-glS(chumbo ~ tempo*Grupo - Grupo - 1,
               correlation=corAR1 (form=~1|ID), data=datalong) #AR1
gls1b.unst<-glS(chumbo ~ tempo*Grupo - Grupo - 1,
               correlation=corSymm (form=~1|ID), data=datalong) #Não estruturada
```

*# Independente*

```
round(coef(summary(gls1b.ind)),3)
```

```
##           Value Std.Error t-value p-value
## tempo0      26.540    0.937  28.324   0.00
## tempo1      13.522    0.937  14.431   0.00
## tempo4      15.514    0.937  16.557   0.00
## tempo6      20.762    0.937  22.158   0.00
## tempo0:GrupoP -0.268    1.325  -0.202   0.84
## tempo1:GrupoP 11.138    1.325   8.405   0.00
## tempo4:GrupoP 8.556    1.325   6.457   0.00
## tempo6:GrupoP 2.884    1.325   2.176   0.03
```

*# Simetria composta*

```
round(coef(summary(gls1b.exch)),3)
```

```
##           Value Std.Error t-value p-value
## tempo0      26.540    0.937  28.324   0.00
## tempo1      13.522    0.937  14.431   0.00
## tempo4      15.514    0.937  16.557   0.00
## tempo6      20.762    0.937  22.158   0.00
## tempo0:GrupoP -0.268    1.325  -0.202   0.84
## tempo1:GrupoP 11.138    1.325   8.405   0.00
## tempo4:GrupoP 8.556    1.325   6.457   0.00
## tempo6:GrupoP 2.884    1.325   2.176   0.03
```

*# AR(1)*

```
round(coef(summary(gls1b.ar1)),3)
```

##		Value	Std.Error	t-value	p-value
##	tempo0	26.540	0.932	28.482	0.000
##	tempo1	13.522	0.932	14.512	0.000
##	tempo4	15.514	0.932	16.649	0.000
##	tempo6	20.762	0.932	22.282	0.000
##	tempo0:GrupoP	-0.268	1.318	-0.203	0.839
##	tempo1:GrupoP	11.138	1.318	8.452	0.000
##	tempo4:GrupoP	8.556	1.318	6.493	0.000
##	tempo6:GrupoP	2.884	1.318	2.189	0.029

*# Não estruturada*

```
round(coef(summary(gls1b.unst)),3)
```

##		Value	Std.Error	t-value	p-value
##	tempo0	26.540	0.937	28.310	0.00
##	tempo1	13.522	0.937	14.424	0.00
##	tempo4	15.514	0.937	16.549	0.00
##	tempo6	20.762	0.937	22.147	0.00
##	tempo0:GrupoP	-0.268	1.326	-0.202	0.84
##	tempo1:GrupoP	11.138	1.326	8.401	0.00
##	tempo4:GrupoP	8.556	1.326	6.454	0.00
##	tempo6:GrupoP	2.884	1.326	2.175	0.03

Comparando os estimadores GLS e GEE notamos que o primeiro apresenta erros padrões menores. Assim, assumindo um nível de significância  $\alpha = 0.05$ , o efeito de grupo no GEE não é significativo em seis semanas, embora o seja na primeira e na quarta. Na aleatorização (semana zero) os grupos são estatisticamente iguais, como esperado. As inferências via GLS coincidem com as do GEE, exceto para a semana seis, para a qual a diferença encontrada é estatisticamente significativa.

Observação: o modelo GLS acima é homocedástico pois há apenas uma variância residual. É possível, contudo, estimar variâncias diferentes por grupo por meio do argumento **weights**. Por exemplo, a opção **weights = varIdent(form = ~ 1 | Grupo)** especifica variâncias diferentes por grupo. De forma similar, é possível especificar variâncias heterogêneas por tempo. Como exercício, avalie a necessidade de considerar variâncias distintas por grupo ou tempo.