

# CE075 - Análise de Dados Longitudinais

Silva, J.L.P.

28 de agosto, 2019

# Modelos de Regressão

# Notação

Seja  $Y_{ij}$  a variável resposta para  $i$ -ésimo indivíduo ( $i = 1, \dots, N$ ) na  $j$ -ésima ocasião ( $j = 1, \dots, n_i$ ).

Dado que temos  $n_i$  medidas repetidas da resposta no mesmo indivíduo, podemos agrupá-las em um vetor  $n_i \times 1$ , denotado por

$$\mathbf{Y}_i = \begin{pmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{in_i} \end{pmatrix},$$

ou, por conveniência,

$$\mathbf{Y}_i = (Y_{i1}, Y_{i2}, \dots, Y_{in_i})'.$$

# Dependência e Correlação

O principal interesse está na média da resposta (em particular, em mudanças da média no tempo e como esta mudança depende de covariáveis).

Denote a média ou esperança de cada resposta  $Y_{ij}$  por  $\mu_j = E(Y_{ij})$ .

Adicionalmente, para permitir que a resposta média varie de indivíduo para indivíduo como função de covariáveis medidas em nível de indivíduo, requeremos  $\mu_{ij} = E(Y_{ij})$ .

Denotando a média condicional de  $Y_{ij}$  por  $\mu_{ij}$ , a variância condicional de  $Y_{ij}$  é definida como:

$$\sigma_j^2 = E[Y_{ij} - E(Y_{ij})]^2 = E(Y_{ij} - \mu_{ij})^2.$$

# Dependência e Correlação

A *covariância* condicional entre as respostas em duas ocasiões diferentes, digamos  $Y_{ij}$  e  $Y_{ik}$ , é definida por

$$\sigma_{jk} = E [(Y_{ij} - \mu_{ij})(Y_{ik} - \mu_{ik})] .$$

e fornece uma medida da dependência *linear* entre  $Y_{ij}$  e  $Y_{ik}$ , dado as covariáveis.

A correlação condicional entre  $Y_{ij}$  e  $Y_{ik}$  é denotada por

$$\rho_{jk} = \frac{E [(Y_{ij} - \mu_{ij})(Y_{ik} - \mu_{ik})]}{\sigma_j \sigma_k} ,$$

que, por definição, assume valores entre  $-1$  e  $+1$ .

# Dependência e Correlação

Definimos a matriz de variância-covariância como segue

$$\begin{aligned} \text{Cov} \begin{pmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{in_i} \end{pmatrix} &= \begin{pmatrix} \text{Var}(Y_{i1}) & \text{Cov}(Y_{i1}, Y_{i2}) & \dots & \text{Cov}(Y_{i1}, Y_{in_i}) \\ \text{Cov}(Y_{i2}, Y_{i1}) & \text{Var}(Y_{i2}) & \dots & \text{Cov}(Y_{i2}, Y_{in_i}) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(Y_{in_i}, Y_{i1}) & \text{Cov}(Y_{in_i}, Y_{i2}) & \dots & \text{Var}(Y_{in_i}) \end{pmatrix} \\ &= \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1n_i} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2n_i} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n_i1} & \sigma_{n_i2} & \dots & \sigma_{n_in_i} \end{pmatrix}. \end{aligned}$$

Assumimos que as variâncias e covariâncias são constantes. Note que há simetria, ou seja,  $\text{Cov}(Y_{ij}, Y_{ik}) = \sigma_{jk} = \sigma_{kj} = \text{Cov}(Y_{ik}, Y_{ij})$ .

# Dependência e Correlação

Usaremos frequentemente a notação

$$\text{Cov}(\mathbf{Y}_i) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n_i} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2n_i} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n_i1} & \sigma_{n_i2} & \dots & \sigma_{n_i}^2 \end{pmatrix}.$$

Definimos a matriz de correlação em termos de

$$\text{Corr}(\mathbf{Y}_i) = \begin{pmatrix} 1 & \rho_{12} & \dots & \rho_{1n_i} \\ \rho_{21} & 1 & \dots & \rho_{2n_i} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n_i1} & \rho_{n_i2} & \dots & 1 \end{pmatrix},$$

que é simétrica, ou seja,  $\text{Corr}(Y_{ij}, Y_{ik}) = \rho_{jk} = \rho_{kj} = \text{Corr}(Y_{ik}, Y_{ij})$ .

# Modelo Marginal

O modelo para a resposta média em cada ocasião não incorpora a dependência sobre nenhum efeito aleatório ou sobre respostas anteriores.

Apropriado quando o foco da análise é inferir sobre a população média.

- 1  $E(Y_{ij}|X_{ij}) = \mu_{ij}$ , com  $g(\mu_{ij}) = \eta_{ij} = X'_{ij}\beta$ .
- 2  $Var(Y_{ij}|X_{ij}) = \phi v(\mu_{ij})$ , em que  $\phi$  é um parâmetro de dispersão e  $v(\cdot)$  é uma função conhecida da média.
- 3 A correlação intra-indivíduos é função de  $\alpha$ . Por exemplo:
  - $Corr(Y_{ij}, Y_{ik}) = \alpha^{|k-j|}$  (AR-1 para respostas contínuas);
  - $logOR(Y_{ij}, Y_{ik}) = \alpha_{jk}$  (não-estruturado para respostas categóricas).



# Modelo Marginal

A caracterização de um modelo marginal envolve:

- 1 Modelar a resposta média  $E(\mathbf{Y}_i)$ .
- 2 Modelar a estrutura de Variância-Covariância  $Var(\mathbf{Y}_i)$ ,  $i = 1, \dots, N$ .
- 3 Assumir uma distribuição (normal) para a resposta (dispensável).

Dois caminhos:

- 1 Assumir resposta normal: usar MQG ou MV (usual ou restrita).
- 2 Não assumir distribuição para a resposta: usar GEE: "Generalized Estimation Equations".

# Modelos Mistos

Incluem efeitos aleatórios no modelo de efeitos fixos, em nível de indivíduo, modelando a heterogeneidade entre indivíduos e induzindo, assim, uma estrutura de covariância entre as respostas repetidas.

- 1  $E(Y_{ij}|X_{ij}, b_i) = \mu_{ij}$ , com  $g(\mu_{ij}) = \eta_{ij} = X'_{ij}\beta + Z'_{ij}b_i$ , sendo  $b_i$  o efeito aleatório associado com  $Y_i$ .
- 2  $Var(Y_{ij}|X_{ij}, b_i) = \phi v(\mu_{ij})$ .
- 3 Geralmente assume-se  $b_i \sim N_q(0, G)$ .

# Modelos de Transição

A distribuição condicional de  $Y_{ij}$  é descrita como uma função explícita das respostas passadas e de um vetor de variáveis preditoras.

- 1  $E(Y_{ij}|X_{ij}, H_{ij}) = \mu_{ij}$ , com  $H_{ij} = \{Y_{id}, d = 1, \dots, j-1\}$ .  
 $g(\mu) = X'_{ij}\beta + \sum_{q=1}^Q f_q(H_{ij}, \alpha)$ , em que  $f_q(\cdot)$  são funções conhecidas.
- 2  $Var(Y_{ij}|X_{ij}, H_{ij}) = \phi v(\mu_{ij})$ .
- 3 A correlação entre  $Y_{i1}, \dots, Y_{in_i}$  é avaliada através do parâmetro  $\alpha$  que aparece na função  $f_q(\cdot)$ .