

Análise de Dados Longitudinais

Aula 01.08.2018

José Luiz Padilha da Silva - UFPR
www.docs.ufpr.br/~jlpadilha

- 1 Comparação de Médias
- 2 Caracterização dos Dados Longitudinais
- 3 Modelos de Regressão
 - Modelos Marginais
 - Modelos Mistos
 - Modelos de Transição

Comparação de duas Médias

Retomar a Comparação dos Colírios A e B

- Pacientes com pressão intra-ocular (PIO) elevada irão participar do estudo.
- A pressão será medida após dois meses de uso do colírio.
- O objetivo é comparar a redução média de PIO dos dois colírios.

Então, queremos o seguinte:

$$\delta = \mu_A - \mu_B.$$

O interesse é então testar a hipótese:

$$H_0 : \delta = 0$$

Comparação de Médias

- Existem duas formas de conduzir o estudo:
 - 50 pacientes são submetidos ao colírio A e ao colírio B (medidas repetidas). Considera-se um período de descanso de dois meses entre a aplicação dos colírios. É indicado aleatorizar a ordem de aplicação de A e B.
 - 100 pacientes são selecionados e 50 são sorteados para receber o colírio A e os demais recebem o B.
- Ambos estudos são experimentais
 - Pareado: Estudo Cross-over
 - Amostras Independentes: Estudo Clínico Aleatorizado.
- Qual forma você utilizaria?

Amostra Pareada ou Independente?

1 Vantagens de Parear as Amostras

- Controlar por possíveis fatores de confusão.
- Menos pacientes/unidades na amostra.
- Teste mais preciso com menos suposições.
- Controla pelo efeito de coorte.

2 Vantagens de Amostras Independentes

- Dados são obtidos de forma mais rápida.

Amostras Pareada ou Independente?

Quando devemos parear?

SEMPRE (que for possível).

- Caso típico: antes e depois.
- Situações impossíveis: fumantes e não-fumantes, etc.

Teste-t pareado

O objetivo é comparar duas medidas pareadas.

$$\delta = \mu_A - \mu_B.$$

Uma estimativa natural para δ é a diferença das médias. Ou seja

$$\hat{\delta} = \hat{\mu}_A - \hat{\mu}_B.$$

A variância de $\hat{\delta}$ é



$$Var(\hat{\delta}) = \frac{1}{N}(\sigma_A^2 + \sigma_B^2 - 2\sigma_{AB})$$

Teste-t pareado

Usualmente dados longitudinais têm correlação positiva. Ou seja $\sigma_{AB} > 0$.

Isto significa que a estatística a ser utilizada tem menor variância do que aquela obtida com dados independentes.

Exemplo: Colírio A: Timoptol (timo) e Colírio B: Betoptic (cor=0,43).



Teste-t pareado

Considere as diferenças:

$$d_i = y_{i1} - y_{i2} \quad i = 1, \dots, n.$$

A estatística é:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}},$$

que, sob H_0 , tem uma distribuição t com $n - 1$ graus de liberdade.

Suposição: d_i vem de uma distribuição normal.

Exemplo Colírio¹: $t = 2.9934$, $df = 31$, $p\text{-value} = 0.005378$.

¹o teste somente é válido se não houver efeito de período e de “carry-over”

Exemplo Colírio

```
> head(colirio)
  PRONT. IDADE SEXO IOP_sem IOP_betop IOP_timo Ordem
1   6649   75    F   19.1    17.7    14.4      0
2   3106   61    M   30.5    21.7    21.4      1
3  15231   57    F   19.1    18.4    17.8      0
4    799   42    F   20.0    14.8    18.1      1
5   9371   59    M   24.0    21.8    14.7      0
6    757   65    M   19.3    20.3    20.8      1

> colMeans(cbind(colirio$IOP_beto,colirio$IOP_timo))
[1] 18.2375 16.1375

> var(cbind(colirio$IOP_beto,colirio$IOP_timo))
      [,1]      [,2]
[1,] 16.20242  5.65629
[2,]  5.65629 10.85919
```

- Calcule e discuta estatística t considerando e desconsiderando o pareamento.

Comparação de mais de duas Médias

Comparação dos Colírios A e B e C

- Pacientes com pressão intra-ocular elevada irão participar do estudo.
- A pressão será medida após dois meses de uso do colírio.
- O objetivo é comparar a redução média dos três colírios.

Então, queremos testar a seguinte hipótese:

$$H_0 : \mu_A = \mu_B = \mu_C.$$

ANOVA é válido?

Análise de Dados Longitudinais

1 Características:

- As respostas de diferentes unidades são independentes;
- As respostas para a mesma unidade são correlacionadas. De uma forma geral, as respostas próximas no tempo devem ser mais correlacionadas.

2 Medida Temporal

- Idade;
- Calendário medido a partir de um certo evento.

3 Objetivos do Estudo:

- avaliar o comportamento temporal;
- avaliar o efeito de covariáveis sobre a resposta;
- predição.

4 Modelos de Regressão

- Modelos marginais (modelar a média e a estrutura de covariância);
- Modelo de efeitos aleatórios.
- Modelo de transição.

Características da Correlação dos Dados

- As correlações usualmente são positivas;
- as correlações usualmente diminuem à medida que aumenta a separação no tempo;
- as correlações entre medidas repetidas raramente aproximam do zero.
- medidas muito próximas tendem a ter correlação um.


Fontes de Variabilidade em Estudos Longitudinais




- Variação entre-unidades;
- Variação intra-unidade;
- Erro de medição.

Fontes de Variabilidade em Estudos Longitudinais

Estas três fontes de variação podem ser visualizadas de forma gráfica.

- pontos pretos são respostas livre de erro de medição;
- pontos brancos são as respostas observadas;
- A e B são diferentes indivíduos.





Notação

Seja Y_{ij} a variável resposta para i -ésimo indivíduo ($i = 1, \dots, N$) na j -ésima ocasião² ($j = 1, \dots, n$).

Dado que temos n medidas repetidas da resposta no mesmo indivíduo, podemos agrupá-las em um vetor $n \times 1$, denotado por

$$Y_i = \begin{pmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{in} \end{pmatrix},$$

ou, por conveniência,

$$Y_i = (Y_{i1}, Y_{i2}, \dots, Y_{in})'.$$

²Mais tarde estenderemos a notação para o caso desbalanceado.

Dependência e Correlação

O principal interesse está na média da resposta (em particular, em mudanças da média no tempo e como esta mudança depende de covariáveis).

Denote a média ou esperança de cada resposta Y_{ij} por $\mu_j = E(Y_{ij})$. Adicionalmente, para permitir que a resposta média varie de indivíduo para indivíduo como função de covariáveis medidas em nível de indivíduo, requeremos $\mu_{ij} = E(Y_{ij})$.

Denotando a média condicional de Y_{ij} por μ_{ij} , a variância condicional de Y_{ij} é definida como:

$$\sigma_j^2 = E [Y_{ij} - E(Y_{ij})]^2 = E (Y_{ij} - \mu_{ij})^2 .$$

Dependência e Correlação

A *covariância* condicional entre as respostas em duas ocasiões diferentes, digamos Y_{ij} e Y_{ik} , é definida por

$$\sigma_{jk} = E [(Y_{ij} - \mu_{ij})(Y_{ik} - \mu_{ik})] .$$

e fornece uma medida da dependência *linear* entre Y_{ij} e Y_{ik} , dado as covariáveis.

A correlação condicional entre Y_{ij} e Y_{ik} é denotada por

$$\rho_{jk} = \frac{E [(Y_{ij} - \mu_{ij})(Y_{ik} - \mu_{ik})]}{\sigma_j \sigma_k} ,$$

que, por definição, assume valores entre -1 e $+1$.

Dependência e Correlação

Definimos a matriz de variância-covariância como segue

$$\begin{aligned} \text{Cov} \begin{pmatrix} Y_{i1} \\ Y_{i2} \\ \vdots \\ Y_{in} \end{pmatrix} &= \begin{pmatrix} \text{Var}(Y_{i1}) & \text{Cov}(Y_{i1}, Y_{i2}) & \dots & \text{Cov}(Y_{i1}, Y_{in}) \\ \text{Cov}(Y_{i2}, Y_{i1}) & \text{Var}(Y_{i2}) & \dots & \text{Cov}(Y_{i2}, Y_{in}) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(Y_{in}, Y_{i1}) & \text{Cov}(Y_{in}, Y_{i2}) & \dots & \text{Var}(Y_{in}) \end{pmatrix} \\ &= \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_{nn} \end{pmatrix}. \end{aligned}$$

Assumimos que as variâncias e covariâncias são constantes. Note que há simetria, ou seja, $\text{Cov}(Y_{ij}, Y_{ik}) = \sigma_{jk} = \sigma_{kj} = \text{Cov}(Y_{ik}, Y_{ij})$.

Dependência e Correlação

Usaremos frequentemente a notação

$$\text{Cov}(Y_i) = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \dots & \sigma_n^2 \end{pmatrix}.$$

Definimos a matriz de correlação em termos de

$$\text{Corr}(Y_i) = \begin{pmatrix} 1 & \rho_{12} & \dots & \rho_{1n} \\ \rho_{21} & 1 & \dots & \rho_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n1} & \rho_{n2} & \dots & 1 \end{pmatrix},$$

que é simétrica, ou seja, $\text{Corr}(Y_{ij}, Y_{ik}) = \rho_{jk} = \rho_{kj} = \text{Corr}(Y_{ik}, Y_{ij})$.

Modelo Marginal

O modelo para a resposta média em cada ocasião não incorpora a dependência sobre nenhum efeito aleatório ou sobre respostas anteriores.

Apropriado quando o foco da análise é inferir sobre a população média.

- 1 $E(Y_{ij}|X_{ij}) = \mu_{ij}$, com $g(\mu_{ij}) = \eta_{ij} = X'_{ij}\beta$.
- 2 $Var(Y_{ij}|X_{ij}) = \phi v(\mu_{ij})$, em que ϕ é um parâmetro de dispersão e $v(\cdot)$ é uma função conhecida da média.
- 3 A correlação intra-indivíduos é função de α . Por exemplo:
 - $Corr(Y_{ij}, Y_{ik}) = \alpha^{|k-j|}$ (AR-1 para respostas contínuas);
 - $logOR(Y_{ij}, Y_{ik}) = \alpha_{jk}$ (não-estruturado para respostas categóricas).

Modelos Mistos

Incluem efeitos aleatórios no modelo de efeitos fixos, em nível de indivíduo, modelando a heterogeneidade entre indivíduos e induzindo, assim, uma estrutura de covariância entre as respostas repetidas.

- 1 $E(Y_{ij}|X_{ij}, b_i) = \mu_{ij}$, com $g(\mu_{ij}) = \eta_{ij} = X'_{ij}\beta + Z'_{ij}b_i$, sendo b_i o efeito aleatório associado com Y_i .
- 2 $Var(Y_{ij}|X_{ij}, b_i) = \phi v(\mu_{ij})$.
- 3 Geralmente assume-se $b_i \sim N_q(0, G)$.

Modelos de Transição

A distribuição condicional de Y_{ij} é descrita como uma função explícita das respostas passadas e de um vetor de variáveis preditoras.

- 1 $E(Y_{ij}|X_{ij}, H_{ij}) = \mu_{ij}$, com $H_{ij} = \{Y_{id}, d = 1, \dots, j-1\}$.
 $g(\mu) = X'_{ij}\beta + \sum_{q=1}^Q f_q(H_{ij}, \alpha)$, em que $f_q(\cdot)$ são funções conhecidas.
- 2 $Var(Y_{ij}|X_{ij}, H_{ij}) = \phi v(\mu_{ij})$.
- 3 A correlação entre Y_{i1}, \dots, Y_{in} é avaliada através do parâmetro α que aparece na função $f_q(\cdot)$.