

Análise de Dados Longitudinais

Aula 05.09.2018

José Luiz Padilha da Silva - UFPR
www.docs.ufpr.br/~jlpadilha

- 1 Modelo Linear Misto
- 2 Formulação em dois estágios
- 3 Predição e interpretação dos efeitos aleatórios

Modelo Linear Misto

Ideia:

- Os parâmetros da regressão variam de indivíduo para indivíduo explicando as fontes de heterogeneidade da população.
- Cada indivíduo tem a sua própria trajetória média e um subconjunto dos parâmetros de regressão são tomados como aleatórios.
- Efeitos fixos são compartilhados por todos os indivíduos e os aleatórios são específicos de cada um.

Modelo Linear Misto

- **Características:**

- 1 Características populacionais β (fixos);
- 2 Características individuais β_i ou b_i (aleatórios).

- **Efeito:**

- 1 Média: $E(Y_i) = X_i\beta$
- 2 Estrutura de Covariância: Efeito aleatório induz $Var(Y_i)$.
Separa a variação entre indivíduos daquela intra indivíduos.
- 3 Permite obter estimativa de trajetórias individuais no tempo.

Modelo Linear Misto - Simetria Composta

Exemplo: $Y_{ij} = \beta_{0i} + \beta t_{ij} + \varepsilon_{ij}$ (Intercepto aleatório).

- $\beta_{0i} \sim N(\beta_0, \sigma_{\beta_0}^2)$.
- $\varepsilon_{ij} \sim N(0, \sigma^2)$.
- β_{0i} e ε_{ij} são independentes.

- 1 $Var(Y_{ij}) = \sigma^2 + \sigma_{\beta_0}^2$.
- 2 $Cov(Y_{ij}, Y_{ij'}) = \sigma_{\beta_0}^2$

Modelo Linear Misto - Inclinação aleatória

Exemplo: $Y_{ij} = \beta_{0i} + \beta_{1i}t_{ij} + \varepsilon_{ij}$ (Intercepto e inclinação aleatórios).

- $\beta_{0i} \sim N(\beta_0, \sigma_{\beta_0}^2)$, $\beta_{1i} \sim N(\beta_1, \sigma_{\beta_1}^2)$, $Cov(\beta_{0i}, \beta_{1i}) = \sigma_{\beta_{01}}$.
- $\varepsilon_{ij} \sim N(0, \sigma^2)$.
- $\beta' = (\beta_{0i}, \beta_{1i})$ e ε_{ij} são independentes.

- 1 $Var(Y_{ij}) = \sigma_{\beta_0}^2 + \sigma_{\beta_1}^2 t_{ij}^2 + 2t_{ij}\sigma_{\beta_{01}} + \sigma^2.$

- 2 $Cov(Y_{ij}, Y_{ij'}) = \sigma_{\beta_0}^2 + t_{ij}t_{ij'}\sigma_{\beta_1}^2 + (t_{ij} + t_{ij'})\sigma_{\beta_{01}}.$

Vantagens

- 1 Predizer trajetórias individuais (ex: intercepto aleatório)

$$Y_{ij} = X_{ij}\beta + b_i + \varepsilon_{ij}$$

Resposta Média populacional:

$$E(Y_{ij}) = X_{ij}\beta$$

Resposta média para o i-ésimo indivíduo (trajetória):

$$E(Y_{ij}|b_i) = X_{ij}\beta + b_i.$$

- 2 Flexibilidade em acomodar estruturas não balanceadas

Forma Geral do Modelo Misto

$$Y_i = X_i\beta + Z_ib_i + \varepsilon_i$$

em que:

$(\beta)_{p \times 1}$: efeitos fixos;

$(b_i)_{q \times 1}$: efeitos aleatórios.

e,

$$b_i \sim N_q(0, \Sigma) \text{ e } \varepsilon_{ij} \sim N(0, \sigma^2)$$

Sendo b_i e ε_{ij} independentes.

$$q \leq p \Rightarrow Z_i \text{ é um subconjunto de } X_i$$

Incluimos efeitos aleatórios somente para as covariáveis que variam com o tempo.

Característica do Modelo

- 1 Média Populacional ou Marginal

$$E(Y_i) = X_i\beta.$$

- 2 Média condicional ou específica por indivíduo

$$E(Y_i|b_i) = X_i\beta + Z_ib_i.$$

- 3 Covariância Marginal

$$\text{Var}(Y_i) = Z_i \text{Var}(b_i) Z_i' + \sigma^2 I_{n_i}.$$

- 4 Podemos assumir que $\varepsilon_i \sim N(0, R_i)$ mas o usual é tomar $R_i = \sigma^2 I_{n_i}$ e interpretá-lo como covariância condicional. Ou seja,

$$\text{Var}(Y_i/b_i) = R_i = \sigma^2 I_{n_i}.$$

Inferência para o Modelo Misto

$$Y_i = X_i\beta + Z_ib_i + \varepsilon_i,$$

em que,

$$b_i \sim N_q(0, \Sigma(\alpha)) \text{ e } \varepsilon_{ij} \sim N(0, \sigma^2),$$

b_i e ε_{ij} independentes.

Desta forma tem-se:

p efeitos fixos e $\frac{q(q+1)}{2} + 1$ efeitos aleatórios.

Inferência Estatística para $\theta = (\beta, \alpha, \sigma^2)$;

- 1 Máxima Verossimilhança.
- 2 Máxima Verossimilhança Restrita.

Função de Verossimilhança

$$\begin{aligned}
 L(\theta|y) &= \prod_{i=1}^N p(y_i|\theta) \\
 &= \prod_{i=1}^N \int p(y_i, b_i|\theta) db_i \\
 &= \prod_{i=1}^N \int p(y_i|b_i, \theta) p(b_i|\theta) db_i
 \end{aligned}$$

em que,

$$p(y_i|b_i, \theta) \sim N_{n_i}(X_i\beta + Z_ib_i, \sigma^2 I_{n_i})$$

e

$$p(b_i|\theta) \sim N_q(0, \Sigma)$$

Avaliação dos Componentes de Variância

- 1 Número de componentes é igual a $\frac{q(q+1)}{2} + 1$ em que q é o número de efeitos aleatórios no modelo.
- 2 Muitas situações envolvem $q = 2$ (intercepto e inclinação aleatórios) e portanto:

$$\frac{2(2 + 1)}{2} + 1 = 4,$$

que permite termos heterogeneidade de variâncias e covariâncias pois ficam em função do tempo.

- 3 A escolha da “melhor” estrutura de variância-covariância pode ser realizada utilizando o teste da RMVR. Estes testes, usualmente, são na fronteira do espaço de parâmetros. Neste caso, a estatística da RMVR não tem, sob H_0 uma distribuição qui-quadrado.

Dist. da Estatística da RMVR sob H_0

- 1 A distribuição neste caso é uma mistura (50:50) de dist. qui-quadrado. Ou seja, por exemplo, para $H_0 : \sigma_{\beta_1} = 0$

$$RMVR \sim 0.5\chi_q + 0.5\chi_{q+1}$$

- 2 Exemplo

Modelo completo: $q=2$ (intercepto e inclinação aleatórios)

Modelo restrito: $q=1$ (somente intercepto aleatório)

Teste usual (errado): nível de significância: 5,99

Teste correto:

$$RMVR \sim 0,5\chi_1 + 0,5\chi_2$$

nível é 5,14 (Tabela, Apend. C, Fitzmaurice et al, 2004).

- 3 Proposta ad hoc: para testar a 0,05, use o nível de 0,10.

Formulação em dois Estágios do Modelo Linear Misto

1 Estágio 1

Medidas Longitudinais no i -ésimo indivíduo são modeladas como:

$$Y_i = Z_i\beta_i + \varepsilon_i$$

em que Z_i covariáveis intra-indivíduo (ou tempo dependente) e

$$\varepsilon_i \sim N(0, \sigma^2 I_{n_i}).$$

2 Estágio 2

β_i : aleatório (variando de indivíduo para indivíduo) tal que:

$$E(\beta_i) = A_i\beta$$

em que A_i ($q \times p$) contém somente covariáveis que variam entre indivíduos (não dependente do tempo) e

Formulação em dois Estágios do Modelo Linear Misto

$$\text{Var}(\beta_i) = \Sigma.$$

Desta forma,

$$\begin{aligned} Y_i &= Z_i(A_i\beta + b_i) + \varepsilon_i \\ &= X_i\beta + Z_ib_i + \varepsilon_i \end{aligned}$$

Ou seja, sob a restrição que

$$X_i = Z_iA_i$$

obtém-se o modelo de efeitos aleatórios.

Predição dos Efeitos Aleatórios

Objetivo: prever perfis individuais ou identificar indivíduos acima ou abaixo do perfil médio.

Obs.: não dizemos estimar os efeitos pois os mesmos são aleatórios. Dizemos prever os efeitos aleatórios.

Deseja-se:

$$\hat{Y}_i = \hat{E}(Y_i|b_i) = X_i\hat{\beta} + Z_i\hat{b}_i$$

e para tal necessita-se de \hat{b}_i , o chamado Estimador BLUP (“Best Linear Unbiased Predictor”) de b_i .

Predição dos Efeitos Aleatórios

No modelo linear misto,

- Y_i e b_i tem uma distribuição conjunta normal multivariada.
- Usando conhecidas propriedades da normal multivariada, temos que

$$E(b_i | Y_i, \hat{\beta}) = \Sigma Z_i' \text{Var}(Y_i)^{-1} (Y_i - X_i \hat{\beta})$$

- Usando os estimadores MVR dos componentes de variância,

$$\hat{b}_i = \hat{\Sigma} Z_i' \widehat{\text{Var}}(Y_i)^{-1} (Y_i - X_i \hat{\beta})$$

o BLUP de b_i .

Predição dos Efeitos Aleatórios

Desta forma obtemos:

$$\begin{aligned}
 \hat{Y}_i &= X_i \hat{\beta} + Z_i \hat{b}_i \\
 &= X_i \hat{\beta} + Z_i \hat{\Sigma} Z_i' \widehat{\text{Var}}(Y_i)^{-1} (Y_i - X_i \hat{\beta}) \\
 &= X_i \hat{\beta} + (Z_i \hat{\Sigma} Z_i' + \hat{R}_i - \hat{R}_i) \widehat{\text{Var}}(Y_i)^{-1} (Y_i - X_i \hat{\beta}) \\
 &= (\hat{R}_i \widehat{\text{Var}}(Y_i)^{-1}) X_i \hat{\beta} + (I_{n_i} - \hat{R}_i \widehat{\text{Var}}(Y_i)^{-1}) Y_i
 \end{aligned}$$

em que $\text{Var}(\varepsilon_i) = R_i$.

Interpretação: média ponderada entre a média populacional $X_i \hat{\beta}$ e o i -ésimo perfil observado. Isto significa que o perfil predito é encolhido na direção da média populacional.

Interpretação dos Efeitos Aleatórios Preditos

Ou seja,

- R_i : variação intra-indivíduo:
 - $Var(Y_i)$: variação total.
-
- R_i grande, mais peso em $X_i\hat{\beta}$;
 - $Var(b_i)$ grande, mais peso em Y_i ;
 - n_i pequeno, mais peso em $X_i\hat{\beta}$.