

# **Análise de Dados Longitudinais**

## **Aula 27.08.2018**

---

José Luiz Padilha da Silva - UFPR  
[www.docs.ufpr.br/~jlpadilha](http://www.docs.ufpr.br/~jlpadilha)

## Sumário

- 1 Teoria da verossimilhança
- 2 Função escore
- 3 Estimador de máxima verossimilhança
- 4 Modelos marginais

## Revisão - Teoria de Verossimilhança

Considere  $Y_1, Y_2, \dots, Y_N$  respostas iid de uma população  $f(y; \theta)$ . Então a função de verossimilhança para  $\theta$  é dada por

$$L(\theta|y) = \prod_{i=1}^N f(y_i|\theta),$$

em que  $\theta$  é um vetor p-dimensional de parâmetros.

O EMV (Estimador de Máxima Verossimilhança) é aquele  $\hat{\theta}$  que maximiza  $L(\theta|y)$  ou, de forma equivalente,  $l(\theta|y) = \log(L(\theta|y))$  no espaço de parâmetros de  $\theta$ .

## Revisão - Teoria de Verossimilhança: Função Escore

A função escore é dada por

$$S(\theta) = \frac{\partial l(\theta|y)}{\partial \theta},$$

que é p-dimensional.

O EMV é a solução do sistema de equações determinado pela função escore:

$$S(\hat{\theta}) = 0.$$

Propriedade importante:  $E(S(\theta)) = 0$ .

## Revisão - Teoria de Verossimilhança: Medida de Incerteza

$$\begin{aligned} I(\theta) &= \text{Var}(S(\theta)) \\ &= E(S(\theta)^2) \\ &= -E\left(\frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'}\right), \end{aligned}$$

que é uma matriz  $p \times p$  chamada de Informação de Fisher.

A variância assintótica de  $\hat{\theta}$  é

$$\text{Var}(\hat{\theta}) = I(\theta)^{-1}$$

que é estimada avaliando  $\theta$  em  $\hat{\theta}$ .

## Revisão - Teoria de Verossimilhança: Medida de Incerteza

Usualmente é difícil encontrar o valor esperado na distribuição de  $Y$ . No entanto, podemos utilizar qualquer estimador consistente de  $I$ .

Usamos a matriz de informação observada

$$I_o(\theta) = - \left( \frac{\partial^2 l(\theta)}{\partial \theta \partial \theta'} \right),$$

que é consistente para  $I(\theta)$ . Ou seja,

$$\text{Var}(\hat{\theta}) \approx I_o(\theta)^{-1}.$$

Obs. O resultado é verdadeiro para qualquer estimador consistente de  $I$ .

## Estimador de Máxima Verossimilhança

A função de Verossimilhança:

$$L(\beta, \sigma^2, \alpha) = \prod_{i=1}^N f(y_i | \beta, \sigma^2, \alpha, X_i)$$

e a função de log-verossimilhança:

$$\begin{aligned} l(\beta, \sigma^2, \alpha) = & - \frac{nN}{2} \left[ \log(2\pi) + \log(\sigma^2) \right] - \frac{N}{2} \log(|V_0|) - \\ & - \frac{1}{2\sigma^2} \sum_{i=1}^N \left\{ (y_i - X_i\beta)' V_0^{-1} (y_i - X_i\beta) \right\} \end{aligned}$$

## Observações:

- ❶ O vetor de parâmetros  $\beta$  somente aparece no último termo;
- ❷ Se  $V_0$  e  $\sigma^2$  forem fixos, o estimador de  $\beta$  consiste em minimizar :

$$\sum_{i=1}^N (y_i - X_i \beta)' V_0^{-1} (y_i - X_i \beta)$$

cuja solução é:

$$\hat{\beta}_{MQG} = (X' V^{-1} X)^{-1} X' V^{-1} Y$$

- ❸ Sob heterocedasticidade, as variâncias são absorvidas em  $V_0$ . Ou seja,  $Var(Y_i) = V_0$  e  $V_0$  não é mais a matriz de correlação.



## Propriedades de $\hat{\beta}_{EMV}$ (ASSINTÓTICAS)

- 1  $\hat{\beta}_{EMV}$  é consistente para  $\beta$ ;
- 2  $\hat{\beta}_{EMV}$  é assintoticamente normal (Wald):

$$\sqrt{Nn}(\hat{\beta}_{EMV} - \beta) \xrightarrow{\mathcal{D}} N(0, I^{-1})$$

- 3 Estas propriedades valem assintoticamente, mesmo se  $y_i$  não tiver distribuição normal multivariada (para dados completos).
- 4 Usamos as estatísticas:  
**WALD** e da **RV** (Razão de Verossimilhança) para fazer inferência sobre  $\beta$

## Propriedades de $\hat{\beta}_{EMV}$ (ASSINTÓTICAS)

- 5 As distribuições de referência (assintótica) normal e qui-quadrado são utilizadas como aproximações da  $t$  e da  $F$ , respectivamente. É possível estimar os gl para utilizar a  $t$  e a  $F$ , especialmente para amostras de tamanho pequeno.
- 6 O valor-p obtido através da estatística de Wald é menor do que o verdadeiro (e será tão menor quanto menor for o tamanho da amostra).
- 7 Devemos evitar o uso da estatística de Wald para testar os componentes de variância ( $\alpha$  e  $\sigma^2$ ) pois a convergência para normal é lenta para amostras pequenas e variâncias próximas de zero. Desta forma, o recomendado é a estatística da razão de verossimilhança.

## Estimação Conjunta $(\beta, \alpha)$

- 1 EMV;
- 2 EMVR (Estimador de Máxima Verossimilhança Restrita).

EMV ( $\sigma^2$  é absorvido por  $V_0$ )

$$l(\beta, \alpha) = -\frac{nN}{2} \log(2\pi) - \frac{N}{2} \log|V_0| - \frac{1}{2} \sum_{i=1}^N (y_i - x_i\beta)' V_0^{-1} (y_i - x_i\beta)$$

**Propriedades do EMV:**  $\hat{\beta}$  é consistente e assintoticamente Normal (para dados completos).

**Estatísticas:** Wald e RV (Inferência para  $\beta$ ).

## Estimador de Máxima Verossimilhança Restrita (ou Residual)

Estudo linear-normal transversal EMV (amostra de tamanho  $N$ )

$$\hat{\sigma}^2 = \frac{SQR}{N} = \frac{(y - x\hat{\beta})'(y - x\hat{\beta})}{N}$$

$$E[\hat{\sigma}^2] = \frac{N}{N-p}\sigma^2$$

- **Razão:** EMV não leva em consideração que  $\beta$  é estimado pelos dados;
- **Proposta:** utilizar EMVR (Estimador Máxima Verossimilhança Restrita);
- **Ideia:** Separar as partes dos dados para estimar  $\alpha$  daqueles utilizados para estimar  $\beta$ .

## Estimador de Máxima Verossimilhança Restrita (ou Residual)

Transformar a resposta  $Y$  tal que a distribuição resultante não dependa de  $\beta$ . Ou seja,

$$Z = AY \quad \text{tal que} \quad E(Z) = 0$$

**Exemplo:** Modelo Linear-Normal Transversal

$$A = I - H = I - X(X'X)^{-1}X'$$

$$E(Z) = (I - X(X'X)^{-1}X')E(Y) = X\beta - X(X'X)^{-1}X'X\beta = 0$$

## Transformação $y \rightarrow (Z, \hat{\beta})$

A função de log-verossimilhança para  $Z$  escrita em termos de  $Y$  e  $\hat{\beta}$  é:

$$l^*(\alpha) = -\frac{1}{2} \sum_{i=1}^N \log |V_0| - \frac{1}{2} \sum_{i=1}^N (y_i - x_i \hat{\beta})' V_0^{-1} (y_i - x_i \hat{\beta}) - \frac{1}{2} \left| \sum_{i=1}^N x_i' V_0^{-1} x_i \right|$$

**Justificativa:** Na ausência de informação de  $\beta$ , nenhuma informação sobre  $\alpha$  é perdida se a inferência para  $\alpha$  for feita por  $l^*(\alpha)$  ao invés de  $l(\alpha)$ .

## Observação

O termo adicional da função de log-verossimilhança restrita:

$$-\frac{1}{2} \left| \sum_{i=1}^N x_i' V_0^{-1} x_i \right| = \log |\text{cov}(\hat{\beta})|^{1/2}.$$

Este termo é o equivalente a fazer a correção no denominador de  $\hat{\sigma}^2$ .

## Processo de Estimação: EMVR

- 1 Estimar  $\beta$  por:

$$\begin{aligned}\hat{\beta} &= (X'V^{-1}X)^{-1}XV^{-1}Y \\ &= \left( \sum_{i=1}^N x_i' V_0^{-1} x_i \right)^{-1} \left( \sum_{i=1}^N x_i' V_0^{-1} y_i \right); \end{aligned}$$

- 2 Encontrar o EMVR para  $\alpha$  a partir de  $l^*(\alpha)$ ;
- 3 Continuar este processo até a convergência.



## Processo de Estimação: EMVR

- 1 O EMVR é recomendado para  $\alpha$  quando comparado ao EMV. No entanto, a correção do vício se torna *desprezível* quando  $Nn$  é muito maior que  $p$ ;
- 2 A estatística da Razão de MVR pode ser usado para comparar modelos de covariâncias aninhadas mas não pode ser utilizado para comparar modelos aninhados para a média. Neste caso devemos usar o EMV.

## Modelos Marginais: GEE/EMVR

- 1 GEE e EMVR são similares (igualmente eficientes) com dados completos.
- 2 A única condição para GEE produzir inferências válidas é a estrutura da média estar corretamente especificada.
- 3 Especificando corretamente a estrutura de variância-covariância ganha-se em eficiência no processo inferencial.
- 4 Na presença de dados faltantes (MAR e NMAR), o GEE não produz inferências válidas. Por outro lado, o EMVR produz inferências válidas nesta condição (somente MAR) se a distribuição normal for corretamente especificada para a resposta.