

# Exemplo: GEE e Modelo Misto

*José Luiz Padilha da Silva*

*05 de setembro de 2018*

## Exemplo: Dados de Crescimento

Vamos revisitar os dados de crescimento de Potthoff & Roy (1964). No exemplo, são apresentadas medidas de crescimento de 11 meninas e 16 meninos. As medidas referem-se à distância entre dois marcos faciais (do centro da pituitária à fissura do maxilar) em quatro idades (8, 10, 12 e 14 anos). O objetivo era descrever e comparar o crescimento de meninos e meninas.

### Análise Exploratória

Os dados estão disponíveis no R no pacote `mice` e podem ser acessados como:

```
library(mice); library(plyr); library(ggplot2); library(gridExtra); library(nlme)
data(potthoffroy)
```

Resumo dos dados por sexo:

```
with(potthoffroy,by(potthoffroy[, -c(1,2)],sex,summary,digits=3))
```

```
## sex: F
##      d8      d10      d12      d14
## Min.   :16.5   Min.   :19.0   Min.   :19.0   Min.   :19.5
## 1st Qu.:20.2   1st Qu.:21.0   1st Qu.:21.8   1st Qu.:22.8
## Median :21.0   Median :22.5   Median :23.0   Median :24.0
## Mean   :21.2   Mean   :22.2   Mean   :23.1   Mean   :24.1
## 3rd Qu.:22.2   3rd Qu.:23.5   3rd Qu.:24.2   3rd Qu.:25.8
## Max.   :24.5   Max.   :25.0   Max.   :28.0   Max.   :28.0
## -----
## sex: M
##      d8      d10      d12      d14
## Min.   :17.0   Min.   :20.5   Min.   :22.5   Min.   :25.0
## 1st Qu.:21.9   1st Qu.:22.4   1st Qu.:23.9   1st Qu.:26.0
## Median :23.0   Median :23.5   Median :25.0   Median :26.8
## Mean   :22.9   Mean   :23.8   Mean   :25.7   Mean   :27.5
## 3rd Qu.:24.1   3rd Qu.:25.1   3rd Qu.:26.6   3rd Qu.:28.8
## Max.   :27.5   Max.   :28.0   Max.   :31.0   Max.   :31.5
```

Correlações marginais:

```
cor(potthoffroy[, -c(1:2)])
```

```
##      d8      d10      d12      d14
## d8  1.0000000 0.6255833 0.7108079 0.5998338
## d10 0.6255833 1.0000000 0.6348775 0.7593268
## d12 0.7108079 0.6348775 1.0000000 0.7949980
## d14 0.5998338 0.7593268 0.7949980 1.0000000
```

Correlações por sexo:

```
with(potthoffroy,by(potthoffroy[, -c(1,2)],sex,cor))
```


```
## sex: F
##          d8          d10          d12          d14
## d8  1.0000000  0.8300900  0.8623146  0.8413558
## d10 0.8300900  1.0000000  0.8954156  0.8794236
## d12 0.8623146  0.8954156  1.0000000  0.9484070
## d14 0.8413558  0.8794236  0.9484070  1.0000000
## -----
## sex: M
##          d8          d10          d12          d14
## d8  1.0000000  0.4373932  0.5579310  0.3152311
## d10 0.4373932  1.0000000  0.3872909  0.6309234
## d12 0.5579310  0.3872909  1.0000000  0.5859866
## d14 0.3152311  0.6309234  0.5859866  1.0000000
```

Transformação dos dados para o formato longo:

```
dados=reshape(data=potthoffroy,direction="long", idvar="id", v.names="resp",
              varying = list(names(potthoffroy)[3:6]), time= c(8,10,12,14), timevar="tempo")
dados=arrange(dados, id) #Ordenamos os dados por ID, função do pacote plyr
```

Gráficos de perfis:

```
p1=ggplot(dados, aes(x=tempo, y=resp, color=sex)) + theme_bw() +
  geom_line(aes(group=id)) + theme(legend.position="top") +
  scale_x_continuous(breaks=unique(dados$tempo))
p2 = p1 + geom_smooth(method="loess", se=FALSE, size=2)
grid.arrange(p1,p2,ncol=2)
```



O modelo ajustado é dado pela expressão a seguir:

$$E(Y_{ij}) = \beta_0 + \beta_1 \times sexo_i + \beta_2 \times tempo_j + \beta_3 \times tempo_j \times sexo_i.$$

## Estimador GEE

Considere os quatro ajustes GEE realizados.

```
library(geepack)
gee2.ind<-geeglm(resp ~ sex*tempo, id=id, corstr="independence", data=dados) #Independente
gee2.exch<-geeglm(resp ~ sex*tempo, id=id, corstr="exchangeable", data=dados) #Simetria composta
gee2.ar1<-geeglm(resp ~ sex*tempo, id=id, corstr="ar1", data=dados) #AR(1)
gee2.unst<-geeglm(resp ~ sex*tempo, id=id, corstr="unstructured", data=dados) #Não estruturada
```

Resultados:

```
# Independente
```

```
round(coef(summary(gee2.ind)),3)
```

| ## |             | Estimate | Std.err | Wald    | Pr(> W ) |
|----|-------------|----------|---------|---------|----------|
| ## | (Intercept) | 17.373   | 0.725   | 573.869 | 0.000    |
| ## | sexM        | -1.032   | 1.378   | 0.561   | 0.454    |
| ## | tempo       | 0.480    | 0.063   | 57.697  | 0.000    |
| ## | sexM:tempo  | 0.305    | 0.117   | 6.803   | 0.009    |

```
# Simetria composta
```

```
round(coef(summary(gee2.exch)),3)
```

| ## |             | Estimate | Std.err | Wald    | Pr(> W ) |
|----|-------------|----------|---------|---------|----------|
| ## | (Intercept) | 17.373   | 0.725   | 573.869 | 0.000    |
| ## | sexM        | -1.032   | 1.378   | 0.561   | 0.454    |
| ## | tempo       | 0.480    | 0.063   | 57.697  | 0.000    |
| ## | sexM:tempo  | 0.305    | 0.117   | 6.803   | 0.009    |

```
# AR(1)
```

```
round(coef(summary(gee2.ar1)),3)
```

| ## |             | Estimate | Std.err | Wald    | Pr(> W ) |
|----|-------------|----------|---------|---------|----------|
| ## | (Intercept) | 17.312   | 0.792   | 477.573 | 0.000    |
| ## | sexM        | -0.659   | 1.526   | 0.186   | 0.666    |
| ## | tempo       | 0.484    | 0.063   | 58.979  | 0.000    |
| ## | sexM:tempo  | 0.283    | 0.124   | 5.216   | 0.022    |

```
# Não estruturada
```

```
round(coef(summary(gee2.unst)),3)
```

| ## |             | Estimate | Std.err | Wald    | Pr(> W ) |
|----|-------------|----------|---------|---------|----------|
| ## | (Intercept) | 17.397   | 0.724   | 576.702 | 0.000    |
| ## | sexM        | -1.074   | 1.376   | 0.609   | 0.435    |
| ## | tempo       | 0.478    | 0.064   | 56.023  | 0.000    |
| ## | sexM:tempo  | 0.310    | 0.117   | 6.997   | 0.008    |

Conclusões:

- As estimativas de erro padrão dos coeficientes são similares entre as diferentes estruturas, o que mostra a robustez do método GEE à má especificação da estrutura de dependência entre as medidas repetidas.
- O efeito de interação é significativo em todas as análises.
- Podemos concluir que meninos e meninas crescem em ritmos distintos.

## Modelo Misto

Vamos agora repetir a análise, mas considerando o modelo misto. Ajustaremos dois modelos, um com intercepto aleatório apenas, e outro com intercepto e inclinação aleatórios.

Modelo com intercepto aleatório:

$$E(Y_{ij}|b_i) = \beta_0 + b_{0i} + \beta_1 \times \text{sexo}_i + \beta_2 \times \text{tempo}_j + \beta_3 \times \text{tempo}_j \times \text{sexo}_i.$$

Modelo com intercepto e inclinação aleatórios:

$$E(Y_{ij}|b_i) = \beta_0 + b_{0i} + \beta_{1i} \times \text{sexo}_i + \beta_2 \times \text{tempo}_j + b_{1i} \times \text{tempo}_j + \beta_3 \times \text{tempo}_j \times \text{sexo}_i.$$

```
lme1 <-lme(resp~sex*tempo, random= ~1|id,data=dados)
lme2 <-lme(resp~sex*tempo, random= ~tempo|id,data=dados)
```

Para o primeiro modelo, obtemos:

```
summary(lme1)

## Linear mixed-effects model fit by REML
## Data: dados
##      AIC      BIC    logLik
##  445.7572 461.6236 -216.8786
##
## Random effects:
## Formula: ~1 | id
##      (Intercept) Residual
## StdDev:      1.816214 1.386382
##
## Fixed effects: resp ~ sex * tempo
##              Value Std.Error DF   t-value p-value
## (Intercept) 17.37272  1.1835071 79 14.679023  0.0000
## sexM        -1.032102  1.5374208 25 -0.671321  0.5082
## tempo        0.479545  0.0934698 79  5.130483  0.0000
## sexM:tempo    0.304830  0.1214209 79  2.510520  0.0141
## Correlation:
##              (Intr) sexM  tempo
## sexM        -0.770
## tempo       -0.869  0.669
## sexM:tempo   0.669 -0.869 -0.770
##
## Standardized Within-Group Residuals:
##      Min      Q1      Med      Q3      Max
## -3.59804400 -0.45461690  0.01578365  0.50244658  3.68620792
##
## Number of Observations: 108
## Number of Groups: 27
```

Para o segundo modelo, obtemos:

```
summary(lme2)

## Linear mixed-effects model fit by REML
## Data: dados
##      AIC      BIC    logLik
##  448.5817 469.7368 -216.2908
```

```
##
## Random effects:
## Formula: ~tempo | id
## Structure: General positive-definite, Log-Cholesky parametrization
##           StdDev   Corr
## (Intercept) 2.4055009 (Intr)
## tempo       0.1803455 -0.668
## Residual    1.3100396
##
## Fixed effects: resp ~ sex * tempo
##           Value Std.Error DF   t-value p-value
## (Intercept) 17.372727 1.2283958 79 14.142614 0.0000
## sexM        -1.032102 1.5957329 25 -0.646789 0.5237
## tempo        0.479545 0.1037193 79  4.623492 0.0000
## sexM:tempo   0.304830 0.1347353 79  2.262432 0.0264
## Correlation:
##           (Intr) sexM   tempo
## sexM      -0.770
## tempo     -0.880  0.678
## sexM:tempo 0.678 -0.880 -0.770
##
## Standardized Within-Group Residuals:
##           Min           Q1           Med           Q3           Max
## -3.168077732 -0.385939009  0.007104087  0.445154545  3.849463576
##
## Number of Observations: 108
## Number of Groups: 27
```

Os dois modelos permitem conclusões semelhantes com relação aos efeitos fixos. Os efeitos aleatórios podem ser acessados via:

```
ranef(lme1)
```

```
## (Intercept)
## 1 -1.11090166
## 2  0.30748171
## 3  0.96212019
## 4  1.94407791
## 5 -0.01983753
## 6 -1.32911449
## 7  0.30748171
## 8  0.63480095
## 9 -1.32911449
## 10 -3.62034916
## 11  3.25335486
## 12  2.42761769
## 13 -1.39110677
## 14 -0.62736188
## 15  1.44565997
## 16 -1.71842601
## 17  1.22744715
## 18 -1.06378753
## 19 -0.95468112
## 20  0.13638302
## 21  3.95510748
```

```
## 22 -1.17289394
## 23 -0.62736188
## 24 -0.62736188
## 25 -0.08182981
## 26  0.79102150
## 27 -1.71842601
```

```
ranef(lme2)
```

```
##      (Intercept)      tempo
## 1  -0.64132024 -0.044754845
## 2  -0.66020223  0.090293750
## 3  -0.24892689  0.113565208
## 4   1.66111350  0.028212826
## 5   0.57096833 -0.054963721
## 6  -0.82630563 -0.048057940
## 7   0.05820188  0.023482879
## 8   1.41328613 -0.071778786
## 9  -0.53894398 -0.074782288
## 10 -2.98417340 -0.062697171
## 11  2.19630252  0.101480090
## 12  1.58201968  0.081009128
## 13 -1.15234167 -0.023562635
## 14 -0.43305242 -0.018682891
## 15  2.97663819 -0.140968498
## 16 -1.64534099 -0.008474015
## 17  1.35484459 -0.010649850
## 18 -0.94670401 -0.011926906
## 19  0.36707567 -0.123853840
## 20 -0.43216727  0.053007723
## 21  3.45164067  0.050682093
## 22  0.32577111 -0.140519109
## 23 -1.15145653  0.048127980
## 24 -3.88139215  0.302009290
## 25  0.67597475 -0.070554939
## 26 -0.30825358  0.103003530
## 27 -0.78325605 -0.088647061
```

A comparação entre os dois modelos é realizada a seguir. O teste usual da razão de verossimilhança retorna:

```
anova(lme1,lme2)
```

```
##      Model df      AIC      BIC    logLik   Test  L.Ratio p-value
## lme1      1  6 445.7572 461.6236 -216.8786
## lme2      2  8 448.5817 469.7368 -216.2908 1 vs 2 1.175588  0.5556
```

Como a hipótese testada está no limite do espaço paramétrico, um teste com melhores propriedades é dado por:

```
chisq=2*(lme2$logLik-lme1$logLik);chisq
```

```
## [1] 1.175588
```

```
0.5*pchisq(chisq, 1, lower.tail = FALSE) + 0.5*pchisq(chisq, 2, lower.tail = FALSE)
```

```
## [1] 0.4169038
```

A hipótese nula não é rejeitada: devemos ficar com o modelo que possui apenas intercepto aleatório.

Conclusões gerais:

- Modelos mistos, aqui considerando que cada indivíduo tenha um intercepto aleatório, permitem que os dados sejam modelados de forma flexível.
- Pelos valores-p obtidos podemos responder às questões iniciais do estudo dizendo que existe diferença estatisticamente significativas entre as medidas ao longo do tempo.
- Podemos dizer que os sexos diferem com relação à resposta, sendo que os meninos apresentam as maiores medidas.
- O efeito da interação indica que essa diferença entre os sexos não pode ser considerada marginalmente, mas que depende do tempo em que é avaliada.