

# Análise de Dados Longitudinais

## Aula 15.10.2018

José Luiz Padilha da Silva - UFPR  
[www.docs.ufpr.br/~jlpadilha](http://www.docs.ufpr.br/~jlpadilha)

1/30

### Sumário

- 1 Respostas Longitudinal Não-Gaussiana
- 2 Revisão: Modelos Lineares Generalizados

2/30

### Respostas Longitudinal Não-Gaussiana

- 1  $Y_{ij}$ ,  $i = 1, \dots, N$ ;  $j = 1, \dots, n_i$ : binária, contagem, etc.
- 2 Modelos Estatísticos:
  - Modelos Lineares Generalizados Mistos.
  - Modelos Marginais: GEE

3/30

### Exemplos

- 1 Mecanismo Evacuatório de Recém-Nascidos
- 2 Fatores de Risco Coronariano: MCRF, (FLW, pag. 364)

4/30

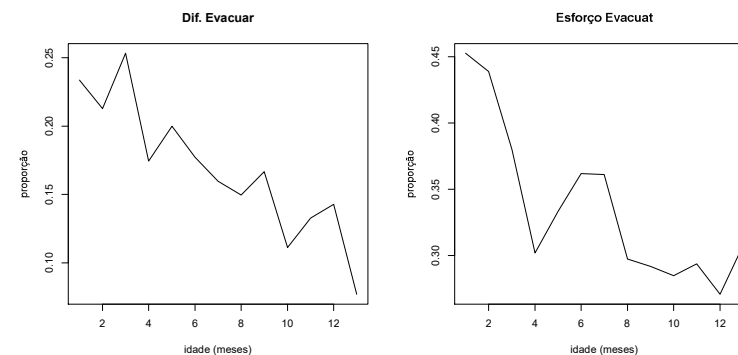
## Mecanismo Evacuatório de Recém-Nascidos

- 151 recém-nascidos acompanhados nos primeiros 12 meses de vida no Hospital das Clínicas da UFMG em 2010 e 2011.
- Acompanhamento mensal totalizando 1751 medidas (61 perdas)
- Respostas:
  - 1 Binárias: Dificuldade para evacuar; esforço evacuatório; dor ao evacuar.
  - 2 Contagem: Frequência evacuatória/semana.

5/30

## Resposta: Dificuldade e Esforço para Evacuar

Obs.: idade foi arredondada para mês (um único dígito).



7/30

## Mecanismo Evacuatório de Recém-Nascidos

- Variável temporal: idade (em dias ou meses).
- Covariáveis:
  - 1 Fixa: sexo.
  - 2 Dependentes do tempo: aleitamento materno; dieta (0/1): cereais; frutas; vegetais, carnes, etc.
- Objetivo: avaliar o comportamento temporal das respostas e seus respectivos indicadores.

6/30

## “Muscatine Coronary Risk Factor Study”

- Estudo longitudinal de crianças em idade escolar realizado em Muscatine, Iowa, Estados Unidos na década de 80.
- Cinco coortes de crianças, inicialmente com idades em 5-7, 7-9, 9-11, 11-13 e 13-15 foram acompanhadas bianualmente de 1977 a 1981 (3 medidas).
- Respostas binária: obesidade.
- Variável temporal: idade (em dias ou meses).
- Covariável: sexo.
- Objetivo: avaliar (1) se o risco de obesidade aumenta com a idade e (2) se os padrões são os mesmos para meninos e meninas.

8/30

**“Muscatine Coronary Risk Factor Study”**

Gênero	Coorte	Idade	Obesidade ( %)		
			1977	1979	1981
Meninos		5-7	7.9	15.4	21.2
		7-9	18.8	20.5	23.7
		9-11	21.2	22.7	22.5
		11-13	24.3	21.8	19.4
		13-15	19.2	21.1	18.2
Meninas		5-7	14.0	17.2	25.1
		7-9	16.5	24.0	24.9
		9-11	25.4	26.2	22.2
		11-13	23.8	22.1	19.9
		13-15	22.9	25.8	20.9

9/30

**Modelos Lineares Generalizados (MLG)**

3 O MLG é definido por três componentes:

- Distribuição de  $Y_i$ .
- Componente Sistemático (preditor linear).

$$\eta_i = X_i' \beta = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}$$

- Função de Ligação.

11/30

**Revisão: Modelos Lineares Generalizados**

Modelos Lineares Generalizados (MLG) é uma classe unificada de modelos de regressão.

- 1 Considere  $Y_1, \dots, Y_N$  uma amostra aleatória de respostas univariadas (desenho transversal).
- 2 Um vetor de p-covariáveis associados a cada resposta  $Y_i$ . Ou seja

$$X_i = \begin{pmatrix} X_{i0} \\ X_{i1} \\ \vdots \\ X_{ip} \end{pmatrix}$$

em que  $X_{i0} = 1$ .

10/30

**MLG - Família Exponencial**

A distribuição de  $Y_i$  pertence à família exponencial que inclui os principais modelos estatísticos: normal, binomial, poisson, exponencial, etc.

Ou seja,  $Y_i$  tem densidade  $f(Y_i|\theta, \phi)$  pertencente à família exponencial.

$$f(y_i|\theta_i, \phi) = \exp\{\phi^{-1}(y_i\theta_i - \psi(\theta_i)) + c(y_i, \phi)\}$$

em que  $\theta_i$  é parâmetro natural,  $\phi$  é o de escala e específicas funções  $\psi(\cdot)$  e  $c(\cdot)$ .

12/30

## Modelos Lineares Generalizados

- $\psi(\cdot)$  é a função geradora de momentos

- $\mu = E(Y) = \psi'(\theta)$  e
- $Var(Y) = \phi\psi''(\theta)$

- Em geral, média e variância são relacionadas.

$$Var(Y) = \phi\psi'' \quad (\psi'^{-1}(\mu) = \phi\nu(\mu))$$

- A função  $\nu(\mu)$  é chamada de função de variância.
- $\psi'^{-1}$  que relaciona  $\theta$  com  $\mu$  é chamada de função de ligação.

13/30

## Exemplos

### 2 Modelo Bernoulli ( $\pi$ )

- $\theta = \log(\pi/(1 - \pi))$
- $\phi = 1$
- $\psi(\theta) = -\log(1 - \pi) = \log(1 + \exp(\theta))$
- Média:  $\mu = \pi = \frac{\exp(\theta)}{1 + \exp(\theta)}$  e  $\nu(\mu) = \pi(1 - \pi) = \frac{\exp(\theta)}{(1 + \exp(\theta))^2}$
- Observe que no modelo bernoulli, média e variância são relacionadas

$$\phi\nu(\mu) = \mu(1 - \mu)$$

- Função de ligação natural:  $\theta = \log(\mu/(1 - \mu))$ .

15/30

## Exemplos

### 1 Modelo Normal ( $\mu, \sigma^2$ )

- $\theta = \mu$
- $\phi = \sigma^2$
- $\psi(\theta) = \theta^2/2$
- Média:  $\mu = \theta$  e  $\nu(\mu) = 1$
- Observe que no modelo normal, média e variância não são relacionadas

$$\phi\nu(\mu) = \sigma^2$$

- Função de ligação natural:  $\theta = \mu$ .

14/30

## Função de Ligação Natural ou Canônica

$$g(\mu_i) = \eta_i = X_i' \beta = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$$

- Gaussiano:  $g(\mu_i) = \eta_i$  (identidade)
- Bernoulli:  $g(\mu_i) = \text{logit}(\eta_i)$ .
- Poisson:  $g(\mu_i) = \log(\eta_i)$

16/30

## Inferência por MV

- Função de log-verossimilhança  $\log L(\cdot) = l(\cdot)$

$$L(\beta) = \prod_{i=1}^N f(y_i | \theta_i, \phi) = \prod_{i=1}^N \exp\{\phi^{-1}(y_i \theta_i - \psi(\theta_i)) + c(y_i, \phi)\}$$

- Equações escore: derivada de  $l(\cdot)$ .
- Inferência baseada na teoria assintótica de MV.

17/30

## Exemplo - Regressão Binária

- Uma amostra de 100 indivíduos acompanhados por um período de cinco anos.
- Resposta: ocorrência de doença coronariana.
- Resposta para cada indivíduo foi sim (1) ou não (0).
- Covariável de interesse: 8 faixas etárias (idade): 20-29, ..., 60-69.
- Aconteceram 43 ocorrências de doença coronariana.

Ref: Giolo (2010) pg. 98- Introdução à Análise de Dados Categóricos.


18/30

## Tabela Resumo

Idade (X = x)	Doença coronária		Totais	E(Y   x)
	Não (Y = 0)	Sim (Y = 1)		
20-29	9	1	10	0,10
30-34	13	2	15	0,13
35-39	9	3	12	0,25
40-44	10	5	15	0,33
45-49	7	6	13	0,46
50-54	3	5	8	0,63
55-59	4	13	17	0,76
60-69	2	8	10	0,80
Totais	57	43	100	0,43

19/30

## Descrição Gráfica por Faixa Etária



20/30

## MLG

$$\text{logit}(\text{idade}_i) = \log\{\mu_i/(1 - \mu_i)\} = \beta_0 + \beta_1 \text{idade}_i$$

e

$$E(Y_i|\text{idade}_i) = P(Y_i = 1|\text{idade}_i)$$

O modelo logístico pode ser escrito como:

$$P(Y_i = 1|\text{idade}_i) = \frac{\exp(\beta_0 + \beta_1 \text{idade}_i)}{1 + \exp(\beta_0 + \beta_1 \text{idade}_i)}$$

21/30

## Resultados do Ajuste

$Y$ : presença ou não de doença coronariana;

$X$ : idade (em anos);

$n = 100$ .

Variável	Estimativa	E.P.	Wald
Idade	0,106	0,023	4,53 ( $p < 0,001$ )
Constante	-5,123	1,11	-4,61 ( $p < 0,001$ )

$$\hat{\pi}(x) = \frac{\exp(-5,12 + 0,106 \text{ idade})}{1 + \exp(-5,12 + 0,106 \text{ idade})}$$

$$\widehat{\text{logit}}(x) = -5,12 + 0,106 \text{ idade}$$

$$\log(\text{verossimilhança}) = \log L(\hat{\beta}_0, \hat{\beta}_1) = -10,86$$

$$\text{Sob } H_0 : \beta_1 = 0, \log L(\hat{\beta}_0) = -24,92.$$

$$\text{TRV} = 2(-10,86 + 24,92) = \text{Null Deviance} - \text{Residual Deviance} = 28,118.$$

23/30

## Resultados do Ajuste MV

```
> summary(ajust1)
```

Coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
(Intercept) -5.12300    1.11111  -4.611 4.01e-06 ***
idade        0.10578    0.02337   4.527 5.99e-06 ***
```

Number of Fisher Scoring iterations: 4


```
> anova(ajust1, test="Chisq")
```

Terms added sequentially (first to last)

```
      Df Deviance Resid. Df Resid. Dev P(>|Chi|)
NULL      7      28.7015
idade  1      28.118      6      0.5838 1.142e-07 ***
```

22/30

## Modelo Estimado



24/30

## Interpretação dos Coeficientes

Interpretação: Razão de chances =  $\exp(0,1058) = 1,11$  (1,06;1,16).

Isto significa que para o aumento de um ano na idade a chance de doença coronariana aumenta em 11%.

25/30

## Outros MLG

- $Y$  tem uma Bernoulli.
- Outras funções de ligação:
  - $\pi(x) = \Phi(x)$  (probit)
  - $\pi(x) = \exp\{-\exp(x)\}$  (complemento log-log)
  - etc (qualquer função de distribuição)

26/30

## Modelos para Resposta Gaussiana Longitudinal

### 1 Modelo Marginal

$$Y_{ij} = X'_{ij}\beta + \varepsilon_{ij}$$

e

$$E(Y_{ij}|X_{ij}) = X'_{ij}\beta.$$

### 2 Modelo Condicional

$$Y_{ij} = X'_{ij}\beta + Z'_{ij}b_i + \varepsilon_{ij}$$

em que:

$(\beta)_{p \times 1}$  : efeitos fixos;

$(b_i)_{q \times 1}$  : efeitos aleatórios.

e,

$$b_i \sim N_q(0, \Sigma) \text{ e } \varepsilon_{ij} \sim N(0, \sigma^2)$$

Sendo  $b_i$  e  $\varepsilon_{ij}$  independentes.

27/30

## Modelos para Resposta Gaussiana

### • Média Condicional ou Específica por Indivíduo

$$E(Y_{ij}|b_i, X_{ij}) = X'_{ij}\beta + Z'_{ij}b_i.$$

e a Covariância Marginal

$$\text{Var}(Y_i) = Z_i \Sigma Z'_i + \sigma^2 I_{n_i}.$$

28/30

## Modelos para Resposta Não-Gaussiana

- 1  $\mu_{ij} = E(Y_{ij}|X_{ij})$  (modelo marginal)  
 $\mu_{ij} = E(Y_{ij}|b_i, X_{ij})$  (modelo condicional).

### 2 Modelo Bernoulli

- $Y_{ij}$  : 0/1 (Bernoulli)
- função de ligação: logit (mais comum)

$$\text{logit}(\mu_{ij}) = X'_{ij}\beta \quad \text{Modelo Marginal}$$

$$\text{logit}(\mu_{ij}) = X'_{ij}\beta + Z'_{ij}b_i \quad \text{Modelo Condicional}$$

29/30

## Modelos para Resposta Não-Gaussiana

### 3 Modelo Poisson

- $Y_{ij}$  :contagem (Poisson)
- função de ligação: logarítmica (mais comum)

$$\log(\mu_{ij}) = X'_{ij}\beta \quad \text{Modelo Marginal}$$

$$\log(\mu_{ij}) = X'_{ij}\beta + Z'_{ij}b_i \quad \text{Modelo Condicional}$$

30/30