

Trabalho 2 - Lista de exercícios

Carolina Bercki (GRR20137542); Ketlin Padilha (GRR20137564); Marcelo Maceno (GRR20165678);

20 de setembro de 2017

```
dados <- read.dta("toenail.dta")
dados$trt <- as.factor(dados$trt)
summary(dados)
```

##	id	y	trt	month	visit
##	Min. : 1.0	Min. :0.0000	0:937	Min. : 0.000	Min. :1.000
##	1st Qu.:101.8	1st Qu.:0.0000	1:971	1st Qu.: 1.000	1st Qu.:2.000
##	Median :192.0	Median :0.0000		Median : 3.000	Median :4.000
##	Mean :189.8	Mean :0.2138		Mean : 4.691	Mean :3.896
##	3rd Qu.:276.2	3rd Qu.:0.0000		3rd Qu.: 8.893	3rd Qu.:6.000
##	Max. :383.0	Max. :1.0000		Max. :18.500	Max. :7.000

12.1.1

Modelo:

$$\text{logit}E(Y_i) = \beta_1 + \beta_2 * \text{month}_{i,j} + \beta_3 * \text{treatment}_i * \text{month}_{i,j}$$

```
gee <- geeglm(y~month+month*trt-trt,
             family=binomial(link="logit"), data=dados, id=id,
             corstr = "exchangeable", std.err="san.se")
summary(gee)
```

```
##
## Call:
## geeglm(formula = y ~ month + month * trt - trt, family = binomial(link = "logit"),
##       data = dados, id = id, corstr = "exchangeable", std.err = "san.se")
##
## Coefficients:
##              Estimate Std.err   Wald Pr(>|W|)
## (Intercept) -0.57822   0.13041 19.661 9.25e-06 ***
## month       -0.17132   0.02957 33.574 6.86e-09 ***
## month:trt1  -0.07770   0.05379  2.086  0.149
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Estimated Scale Parameters:
##              Estimate Std.err
## (Intercept)   1.088   0.5265
##
## Correlation: Structure = exchangeable Link = identity
##
## Estimated Correlation Parameters:
##              Estimate Std.err
## alpha       0.4217   0.2203
## Number of clusters: 294 Maximum cluster size: 7
```

12.1.2

Interpretação do parâmetro β_2 do modelo (correspondente ao mês)

```
coef(gee)[2]
```

```
## month  
## -0.1713
```

Estima-se que para a população de indivíduos que estão sob o tratamento B a chance de a oncolise evoluir a um estado moderado ou severo diminui em 15.74% ($1 - \exp(\beta_2)$) após 1 mês de tratamento. Já para a população sob mesma condição, porém, após 2 meses de tratamento, a chance diminui em 29.01% ($1 - \exp(\beta_2 * 2)$).

Já para a população que está submetida sob o tratamento A estima-se que a chance de a oncolise evoluir a um estado moderado ou severo diminui em 22.04% ($1 - \exp(\beta_2 + \beta_3)$) após 1 mês de tratamento. Já para a população sob mesma condição, porém, após 2 meses de tratamento, a chance diminui em 34.32% ($1 - \exp(\beta_2 * 2 + \beta_3)$).

12.1.3

Interpretação do parâmetro β_3 do modelo (correspondente à interação tratamento.mês)

```
coef(gee)[3]
```


```
## month:trt1  
## -0.0777
```

Estima-se que para a população de indivíduos que estão submetidos ao tratamento A tem-se uma chance de 7.48% ($1 - \exp(\beta_3)$) de ocorrer oncolise moderada ou severa menor do que o grupo que está submetido ao tratamento B.

12.1.4

Gráfico de log(Odd) dos tratamentos em função do mês.

```
tabela1 <- data.frame(grupo=rep(c("A","B"),each=19),  
                      mês=rep(c(0:18),times=2),  
  dimlogodd=c((coef(gee)[1]+coef(gee)[2]*0:18+coef(gee)[3]*0:18),  
              (coef(gee)[1]+coef(gee)[2]*0:18)))  
  
xyplot(dimlogodd ~ mês,  
       groups=grupo,  
       type=c("p","l"),  
       ylab=list("Diminuição no log odds"),  
       grid=T,  
       main="Figura 1",  
       auto.key=list(columns=2, cex.title=1,  
                     title=expression('Grupos')),  
       data=tabela1)
```



Pela Figura 1 tem-se que há uma tendência de diminuição no logodds para ambos os grupos. Para o grupo A a diminuição é mais acentuada do que para o grupo B. Assim, para o grupo A tem-se que o efeito do tratamento no tempo é maior do que para o grupo B.

12.1.5

Modelo misto com intercepto aleatório:

$$\text{logit}E(Y_i) = (\beta_1 + _i) + \beta_2 * \text{month}_{i,j} + \beta_3 * \text{treatment}_i * \text{month}_{i,j}$$

```
m1 <- glmer(y~(1|id)+month+month*trt-trt,
            family=binomial,
            nAGQ=20,
            data=dados)
summary(m1)
```

```
## Generalized linear mixed model fit by maximum likelihood (Adaptive
##   Gauss-Hermite Quadrature, nAGQ = 20) [glmerMod]
##   Family: binomial ( logit )
##   Formula: y ~ (1 | id) + month + month * trt - trt
##   Data: dados
##
##           AIC          BIC    logLik deviance df.resid
##    1258.8    1281.0   -625.4   1250.8     1904
##
## Scaled residuals:
```

```
##      Min      1Q Median      3Q      Max
## -3.18 -0.19 -0.09 -0.01  44.33
##
## Random effects:
##   Groups Name      Variance Std.Dev.
##   id      (Intercept) 16      4
## Number of obs: 1908, groups: id, 294
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.6972    0.3284   -5.17  2.4e-07 ***
## month        -0.3883    0.0432   -8.98  < 2e-16 ***
## month:trt1    -0.1424    0.0649   -2.19   0.028 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) month
## month        -0.040
## month:trt1   -0.001 -0.541
```

12.1.6

Estimativa de σ_b^2

```
VarCorr(m1)
```

```
##   Groups Name      Std.Dev.
##   id      (Intercept) 4
```

Verifica-se que a variância do intercepto aleatório é igual a 16, um valor elevado. Assim, há uma grande variabilidade na propensão de experimentar maior grau de infecção de unha do pé. Tem-se o seguinte intervalo de 95 % de confiança para a propensão:

0 - 1

Praticamente uma variação de 0 a 100 % de propensão.

12.1.7

O parâmetro β_2 é o seguinte:

```
m1@beta[2]
```

```
## [1] -0.3883
```

Estima-se que para um indivíduo do grupo que está sob o tratamento B a chance de a oconólise evoluir a um estado moderado ou severo diminui em 32.18% ($1 - \exp(\beta_2)$) após 1 mês de tratamento. Já após 2 meses de tratamento, a chance diminui em 54% ($1 - \exp(\beta_2 * 2)$).

Já para um indivíduo que está submetida sob o tratamento A estima-se que a chance de a oconólise evoluir a um estado moderado ou severo diminui em NA% ($1 - \exp(\beta_2 + \beta_3)$) após 1 mês de tratamento. Já após 2 meses de tratamento, a chance diminui em 60.11% ($1 - \exp(\beta_2 * 2 + \beta_3)$). Pode interpretar também em função do log Odds, sendo que para um indivíduo pertencente ao grupo B estima-se que o log Odds diminui linearmente em -0.3883 após 1 mês e para um indivíduo pertencente ao grupo A diminui linearmente em -0.5307 após 1 mês.

12.1.8

O parâmetro β_3 é o seguinte:

```
m1@beta[3]
```

```
## [1] -0.1424
```

Estima-se que para um indivíduo que está submetido ao tratamento A tem-se uma chance de 13.27 ($1 - \exp(\beta_3)$)% menor de ocorrer onicólise moderada ou severa menor do que o grupo que um indivíduo que está submetido ao tratamento B, sendo que este indivíduo possui o mesmo risco de experimentar maior grau de infecção de unha do pé quando da aleatorização.

12.1.9

Para os dois modelos as estimativas de β_3 são as seguintes:

```
coef(gee)[3] #Modelo marginal
```

```
## month:trt1  
## -0.0777
```

```
m1@beta[3] #Modelo misto de efeito aleatório
```

```
## [1] -0.1424
```

Conforme verificado a chance de a onicólise evoluir a um estado moderado ou severo em relação ao grupo de tratamento B é de 7.48% menor utilizando o modelo marginal, já utilizando um modelo misto de efeito aleatório é de 13.27% menor. Isto ocorreu pois há uma diferença na interpretação do β_3 para os dois modelos. Para o modelo de efeitos mistos o parâmetro se refere ao efeito do tratamento na diminuição da chance de evolução da onicólise em um determinado indivíduo. Já no caso do modelo marginal refere-se à prevalência de indivíduos com onicólise moderada ou severa na população em relação ao tratamento B contra o A.

12.1.10

Variando os pontos de quadratura do modelo:

```
#Número de pontos de quadratura = 2  
m12 <- glmer(y~(1|id)+month+month*trt-trt,  
             family=binomial,  
             nAGQ=2,  
             data=dados)  
  
#Número de pontos de quadratura = 5  
m15 <- glmer(y~(1|id)+month+month*trt-trt,  
             family=binomial,  
             nAGQ=5,  
             data=dados)  
  
#Número de pontos de quadratura = 10  
m110 <- glmer(y~(1|id)+month+month*trt-trt,
```

```

        family=binomial,
        nAGQ=10,
        data=dados)

#Número de pontos de quadratura = 20
m120 <- glmer(y~(1|id)+month+month*trt-trt,
              family=binomial,
              nAGQ=20,
              data=dados)

#Número de pontos de quadratura = 30
m130 <- glmer(y~(1|id)+month+month*trt-trt,
              family=binomial,
              nAGQ=30,
              data=dados)

#Número de pontos de quadratura = 50
m150 <- glmer(y~(1|id)+month+month*trt-trt,
              family=binomial,
              nAGQ=30,
              data=dados)

summary(m150)

```

```

## Generalized linear mixed model fit by maximum likelihood (Adaptive
##   Gauss-Hermite Quadrature, nAGQ = 30) [glmerMod]
## Family: binomial ( logit )
## Formula: y ~ (1 | id) + month + month * trt - trt
## Data: dados
##
##      AIC      BIC   logLik deviance df.resid
##  1258.9   1281.1   -625.4   1250.9     1904
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -3.18  -0.19  -0.09  -0.01  44.41
##
## Random effects:
##   Groups Name            Variance Std.Dev.
##   id      (Intercept) 16         4.01
## Number of obs: 1908, groups: id, 294
##
## Fixed effects:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -1.6978     0.3304   -5.14  2.8e-07 ***
## month         -0.3885     0.0433   -8.97 < 2e-16 ***
## month:trt1    -0.1424     0.0649   -2.19  0.028 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##              (Intr) month

```

```
## month          -0.035
## month:trt1     0.001 -0.540
```

```
#Estimativas dos parâmetros utilizando o número de pontos de quadratura descritos nas colunas.
t(data.frame("2 pontos"=summary(m12)$coefficients[,1:2],
             "5 pontos"=summary(m15)$coefficients[,1:2],
             "10 pontos"=summary(m110)$coefficients[,1:2],
             "20 pontos"=summary(m120)$coefficients[,1:2],
             "30 pontos"=summary(m130)$coefficients[,1:2],
             "50 pontos"=summary(m150)$coefficients[,1:2],
             check.names=FALSE))
```

```
##                (Intercept)      month month:trt1
## 2 pontos.Estimate      -1.4916 -0.36063  -0.13034
## 2 pontos.Std. Error      0.2723  0.03961   0.05893
## 5 pontos.Estimate      -1.5216 -0.37986  -0.13866
## 5 pontos.Std. Error      0.2946  0.04225   0.06288
## 10 pontos.Estimate     -1.7190 -0.39065  -0.14320
## 10 pontos.Std. Error     0.3476  0.04380   0.06535
## 20 pontos.Estimate     -1.6972 -0.38832  -0.14236
## 20 pontos.Std. Error     0.3284  0.04325   0.06490
## 30 pontos.Estimate     -1.6978 -0.38853  -0.14244
## 30 pontos.Std. Error     0.3304  0.04332   0.06494
## 50 pontos.Estimate     -1.6978 -0.38853  -0.14244
## 50 pontos.Std. Error     0.3304  0.04332   0.06494
```

Verifica-se que para estimar bem os parâmetros necessita-se acima de 20 pontos de quadratura, tanto para a estimativas do valor pontual quanto para o erro padrão dos parâmetros.

```
#Estimativa do erro padrão do intercepto aleatório
data.frame("2 pontos"=3.2452,
           "5 pontos"=3.6903,
           "10 pontos"=4.0606,
           "20 pontos"=4.0017,
           "30 pontos"=4.0058,
           "50 pontos"=4.0058,
           check.names=FALSE)
```

```
##    2 pontos 5 pontos 10 pontos 20 pontos 30 pontos 50 pontos
## 1      3.245      3.69      4.061      4.002      4.006      4.006
```

Para estimar bem o erro padrão do intercepto aleatório é necessário uma quadratura acima de 20 pontos de quadratura. Conclui-se que os resultados dependem do número de pontos de quadratura.