#### CE092 - Extensões dos modelos de regressão

Cesar Augusto Taconeli

02 de outubro, 2017

#### Métodos baseados em árvores

- Métodos baseados em árvores (tree based methods) consistem na partição do espaço das covariáveis em regiões retangulares e no ajuste de um modelo simples (como uma constante) em cada uma delas.
- Os métodos baseados em árvores compreendem uma grande variedade de algoritmos. Vamos nos concentrar, a princípio, no método CART (Classification and regression trees).
- O termo árvore de regressão é aplicado ao caso de variável resposta numérica e o termo árvore de classificação para o caso de variável resposta categórica.
- Em ambos os casos, as covariáveis podem ser categóricas e/ou numéricas.

- Dentre os principais atrativos de árvores de classificação e regressão, destacam-se:
  - Baseiam-se em um conjunto mínimo de pressupostos;
  - Servem como alternativa a diversos métodos estatísticos de classificação e regressão;
  - Permitem lidar com dados de estrutura complexa (elevada dimensão, dados ausentes, interações de diferentes ordens esntre as covariáveis, ...);
  - Produzem resultados simples e de fácil interpretação.

- Seja y a variável resposta e  $\mathbf{x} = (x_1, x_2, ..., x_p)$  o vetor de covariáveis. Considere uma amostra de n observações de y e x.
- O método CART inicia com a partição da amostra original em duas, segundo alguma regra do tipo

$$x_k \leq c \mid x_k > c,$$

para alguma covariável  $x_k$  numérica e c algum valor amostrado de  $x_k$ , ou

$$x_k \in A \mid x_k \notin A$$
,

para uma variável  $x_k$  categórica e A uma particular categoria (ou um subconjunto de categorias) de  $x_k$ .

 Uma vez efetuada a partição, temos o espaço das covariáveis dividido em duas regiões,  $R_1$  e  $R_2$ .

 A variável responsável pela partição e o ponto de corte são escolhidos de forma que proporcionem o melhor ajuste possível para y.

• Na sequência, o processo de partição é repetido em  $R_1$  e em  $R_2$ , novamente buscando a variável e respectivo ponto de corte que proporcionem melhor ajuste.

- Neste passo, temos quatro regiões delimitadas no espaço das covariáveis:  $R_3$  e  $R_4$  (formadas a partir de  $R_1$ );  $R_5$  e  $R_6$  (formadas a partir de  $R_2$ ).
- O processo é repetido sucessivamente. No final, teremos M regiões delimitadas no espaço das covariáveis, que denotaremos por  $R_1, R_2, ..., R_M$ .

 O resultado da aplicação do método CART pode ser representado por um diagrama contendo as partições e os grupos constituídos (nós), que denominamos árvore.

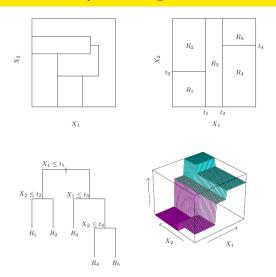


Figura 1: llustração - partições e árvores de regressão

 Podemos ainda expressar o resultado da aplicação do algoritmo CART por meio de um modelo de regressão na forma:

$$\hat{y} = \hat{f}(x) = \sum_{m=1}^{M} c_m I\{x \in R_m\},$$
 (1)

sendo  $c_m$  uma constante ajustada na região  $R_m$ , i=1,2,...,M.

### Árvores de regressão - Seleção das partições

 Para árvores de regressão, é usual considerar a soma de quadrados de resíduos como critério de minimização para a partição das amostras (nós):

$$SQR = \sum_{i=1}^{n} (y_i - \hat{f}(\mathbf{x}_i))^2.$$
 (2)

• Neste caso, temos que a melhor escolha para  $c_m$  em

$$\hat{y} = \hat{f}(x) = \sum_{m=1}^{M} c_m I\{x \in R_m\},$$
 (3)

é simplesmente a média dos  $y_i's$  em  $R_m$ :

$$\hat{c}_m = \frac{1}{n_m} \sum_{\mathbf{y} \in P} \mathbf{y}_i. \tag{4}$$

### Árvores de regressão - Seleção das partições

 Suponha a partição de um nó (O) em dois novos nós (L e R) segundo uma particular regra (variável e ponto de corte). A avaliação da partição se baseia na redução da soma de quadrados de resíduos:

$$\Delta SQR = SQR_O - \left(\frac{n_L}{n_O}SQR_L + \frac{n_R}{n_O}SQR_R\right),\tag{5}$$

sendo  $n_O$ ,  $n_L$  e  $n_R$  os números de observações nos respectivos nós.

- ullet A partição que produzir menor valor para  $\Delta SQR$  deve ser executada.
- A regra de partição apresentada é aplicada sucessivamente aos nós originados até atingir algum critério de parada (número mínimo de observações por nó ou nos nós a serem partidos, número máximo de níveis na árvore...).

#### Árvores de regressão - O processo de poda

- Após obtida uma grande árvore, inicia-se o processo de poda, em que as partições são sucessivamente desfeitas até voltar à amostra original.
- O processo de poda baseia-se na seguinte função de custo-complexidade:

$$R_{\alpha}(T) = R(T) + \alpha |T|, \tag{6}$$

em que T representa uma árvore, |T| o número de nós finais (complexidade) e R(T) a soma de quadrados de resíduos da árvore:

$$R(T) = \sum_{m=1}^{M} \frac{n_m}{n} SQR_m. \tag{7}$$

### Árvores de regressão - O processo de poda

• O parâmetro  $\alpha$  na função de custo-complexidade controla a complexidade do modelo.

• Para diferentes valores de  $\alpha$  tem-se diferentes árvores minimizando  $R_{\alpha}(T)$ .

• Tomando  $\alpha = 0$  tem-se como solução a maior árvore disponível (não podada), uma vez que não se penaliza sua complexidade.

### Árvores de regressão - O processo de poda

• Para  $\alpha \to \infty$  tem-se penalização máxima para a complexidade e a solução é a não partição da amostra original.

• Variando  $\alpha$  a partir de zero tem-se uma sequência de árvores aninhadas, cada uma ótima para seu particular tamanho (número de nós finais).

• É usual representar a função de custo-complexidade por meio de uma curva (versus  $\alpha$  e ou |T|).

#### Árvores de regressão - Seleção do modelo

- Uma vez definida a sequência de árvores aninhadas, deve-se identificar, nessa sequência, a árvore ótima (correspondente à melhor escolha para  $\alpha$ ).
- Nesta etapa, é comum utilizar validação cruzada. Uma descrição informal da seleção por validação cruzada é descrita na sequência.

### Árvores de regressão - Seleção do modelo

• **Passo 1:** Identificação de uma sequência de valores  $\alpha_1, \alpha_2, \ldots, \alpha_k$ para  $\alpha$  cada qual indicando uma das árvores na sequência aninhada como aquela que minimiza a função de custo-complexidade;

• Passo 2: Dividir a base de dados em s grupos de tamanho (aproximado) s/n:  $G_1, G_2, ..., G_s$ ;

 Passo 3: Ajustar o modelo à base completa (exceto pelas observações em  $G_i$ ) e determinar  $T_1, T_2, ..., T_k$ ;

# Árvores de regressão - Seleção do modelo

- Passo 4: Calcular a predição para cada observação i em  $G_j$  sob cada modelo  $T_i$ , j = 1, 2, ..., k;
- **Passo 5:** Calcular a soma de quadrados dos erros de predição para o conjunto de observações em *G<sub>i</sub>* :

$$\sum_{i \in G_j} (y_i - \hat{f}_{(j)}(\mathbf{x}_i))^2, \tag{8}$$

em que  $\hat{f}_{(j)}(\cdot)$  denota a predição sob o modelo ajustado sem as observações em  $G_i$ .

#### Arvores de regressão - Seleção do modelo

• Passo 6: Os passos 3, 4 e 5 são repetidos para cada um dos demais grupos  $G_i$ . Ao término, para cada árvore  $T_1, T_2, ..., T_k$  tem-se a respectiva soma de quadrados de predição obtida por validação cruzada:

$$SQVC = \sum_{j} \sum_{i \in G_{j}} (y_{i} - \hat{f}_{(j)}(\mathbf{x}_{i}))^{2}.$$
 (9)

- Pode-se então selecionar a árvore que produz menor valor de SQVC ou a menor árvore tal que seu SVQC não seja muito maior daquela que produz SQVC mínimo.
- Na prática, usa-se a regra do erro padrão, em que se seleciona a menor árvore tal que seu SQVC não exceda o SQVC mínimo por mais de um erro padrão de SQVC (estimado também na validação cruzada).

- Como dito anteriormente, árvores de classificação se aplicam quando a variável resposta é categórica (binária ou politômica);
- O algoritmo de árvores de classificação é semelhante ao de árvores de regressão, com algumas adaptações.
- A diferença mais importante é a troca da soma de quadrados dos resíduos por alguma medida de heterogeneidade mais apropriada para dados categóricos.
- Dentre as alternativas, temos os critérios de Gini e da informação, conforme apresentados na sequência.

- Vamos considerar um problema de classificação em que a resposta tenha r categorias, denotadas por 1, 2, ..., r.
- Considere uma amostra (ou um nó) e  $p_1, p_2, ..., p_r$  as proporções com que cada categoria é observada.
- A medida de informação (ou entropia) é definida por:

$$Inf = -2 \times \sum_{l=1}^{r} p_l \ln(p_l) \tag{10}$$

• A medida de Gini é definida por:

$$Gini = 1 - \sum_{l=1}^{r} p_{l}^{2}. \tag{11}$$

 Para o caso de duas categorias, em que as proporções de casos em cada uma delas são  $p \in 1 - p$ , as medidas de Informação e de Gini ficam dadas por:

$$Inf = -p \ln(p) - (1-p) \ln(1-p) \tag{12}$$

$$Gini = 1 - p^2 - (1 - p)^2 = 2p(1 - p).$$
 (13)

 A Figura 1 apresenta o comportamento das medidas de informação e Gini para o caso de duas categorias.

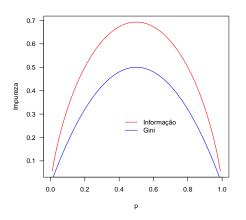


Figura 2: Comparação dos critérios de informação e de Gini para r=2 grupos

- Como pode ser observado na Figura 1, ambas as medidas são minimizadas quando os indivíduos da amostra pertencem a um mesmo grupo ( $p_l \rightarrow 1$ , para algum l) e maximizadas quando as proporções são iguais nas diferentes categorias ( $p_1 = p_2 = ... = p_r$ ).
- Suponha a partição de um nó (O) em dois novos nós (L e R) segundo uma particular regra (variável e ponto de corte). A avaliação da partição se baseia na redução da medida de impureza:

$$\Delta Imp = Imp_O - \left(\frac{n_L}{n_O}Imp_L + \frac{n_R}{n_O}Imp_R\right),\tag{14}$$

em que *Imp* denota, genericamente, a medida de informação, de Gini ou qualquer outra medida de impureza.

 Em árvores de classificação é comum classificar as observações em um nó *m* pela categoria mais frequente:

$$\hat{c}_m = \underset{I}{\operatorname{argmax}} \hat{\rho}_{lm}, \tag{15}$$

em que  $\hat{p}_{lm}$  representa a proporção de indivíduos da categoria l em m, I = 1, 2, ..., r

 O ajuste da árvore de classificação segue os mesmos passos de uma árvore de regressão, com o ajuste de uma grande árvore, poda e seleção da árvore por validação cruzada.

#### Incorporando perdas

- Em problemas de classificação, pode ocorrer que o custo de classificação incorreta não seja o mesmo para todas as categorias da resposta.
- Vamos admitir, novamente, um problema de classificação com r categorias (grupos).
- Considere L(I, I') o custo (perda) em classificar um indivíduo da categoria I na categoria I'. Obviamente, L(I, I) = 0.
- Uma maneira de incorporar os custos de má-classificação baseia-se na minimização do critério de Gini generalizado, definido por:

$$Gini^* = \sum_{l} \sum_{l'} L(l, l') p_{l'} p_{l}.$$
 (16)

#### Incorporando perdas

• Para o caso de r=2 grupos, o critério de Gini generalizado não se aplica, uma vez que o coeficiente associado a  $p_{l'}p_{l}$  será o mesmo, L(I, I') + L(I', I):

$$Gini^* = L(1,2)p_1p_2 + L(2,1)p_2p_1 = [L(1,2) + L(2,1)]p_1p_2,$$
 (17)

de forma que os custos simplesmente serão ignorados (tanto faz se L(1,2) > L(2,1) ou o contrário).

 Uma alternativa ao uso do crtitério de Gini generalizado, que funciona para r = 2, é incorporar pesos a priori (ver Therneau et al, 2017).

# Algumas notas sobre árvores de classificação e regressão

 O algoritmo tende a favorecer (proporcionar partições) covariáveis numéricas ou categóricas com grande número de categorias, uma vez que essas oferecem maior número de partições possíveis;

- Na presença de dados missing, o algoritmo usa os chamados surrogate splits (ou partições substitutas), buscando, dentre as demais covariáveis, a partição com maior nível de concordância em relação àquela para a qual não se dispõe dos dados.
- Árvores de classificação e regressão são altamente instáveis. Pequenas mudanças nos dados podem gerar ajustes consideravelmente diferentes.