

CE043 - GAMLSS

Distribuições discretas

Silva, J.P; Taconeli, C.A.

30 de agosto, 2020

Conteúdo

- 1 Introdução
- 2 Modelos probabilísticos para variáveis discretas
- 3 Superdispersão e subdispersão
- 4 Distribuições geradas por mistura
- 5 Distribuições contínuas discretizadas
- 6 O problema do excesso ou escassez de zeros
- 7 Distribuições zero-inflacionadas
- 8 Distribuições zero-ajustadas
- 9 Resumindo
- 10 Próximos passos

Introdução

- Distribuições discretas são amplamente utilizadas para modelar contagens:

- Distribuições discretas são amplamente utilizadas para modelar contagens:
 - Número de chegadas de aviões a um aeroporto;

- Distribuições discretas são amplamente utilizadas para modelar contagens:
 - Número de chegadas de aviões a um aeroporto;
 - Número de itens defeituosos em lotes de uma produção;

- Distribuições discretas são amplamente utilizadas para modelar contagens:
 - Número de chegadas de aviões a um aeroporto;
 - Número de itens defeituosos em lotes de uma produção;
 - Número de frutos gerados por plantas;

- Distribuições discretas são amplamente utilizadas para modelar contagens:
 - Número de chegadas de aviões a um aeroporto;
 - Número de itens defeituosos em lotes de uma produção;
 - Número de frutos gerados por plantas;
 - Número de problemas de execução de um sistema operacional. . .

- Diferentes modelos probabilísticos para variáveis discretas estão implementados na biblioteca `gamlss`, definidos em diferentes conjuntos de valores:

- Diferentes modelos probabilísticos para variáveis discretas estão implementados na biblioteca `gamlss`, definidos em diferentes conjuntos de valores:
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots\}$, como a distribuição Poisson (PO);

- Diferentes modelos probabilísticos para variáveis discretas estão implementados na biblioteca `gamlss`, definidos em diferentes conjuntos de valores:
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots\}$, como a distribuição Poisson (P0);
 - Variáveis com suporte no conjunto $R_y = \{1, 2, 3, \dots\}$, como a distribuição logarítmica (L0);

- Diferentes modelos probabilísticos para variáveis discretas estão implementados na biblioteca `gamlss`, definidos em diferentes conjuntos de valores:
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots\}$, como a distribuição Poisson (PO);
 - Variáveis com suporte no conjunto $R_y = \{1, 2, 3, \dots\}$, como a distribuição logarítmica (LO);
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots, n\}$, como a distribuição binomial (BI).

- Diferentes modelos probabilísticos para variáveis discretas estão implementados na biblioteca `gamlss`, definidos em diferentes conjuntos de valores:
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots\}$, como a distribuição Poisson (PO);
 - Variáveis com suporte no conjunto $R_y = \{1, 2, 3, \dots\}$, como a distribuição logarítmica (LO);
 - Variáveis com suporte no conjunto $R_y = \{0, 1, 2, \dots, n\}$, como a distribuição binomial (BI).
- Além dos modelos implementados, novas distribuições podem ser definidas, por exemplo, através de truncamento e discretização.

Distribuição de Poisson

- Para a distribuição de Poisson é o modelo clássico para contagens definidas no conjunto $R_y = \{0, 1, 2, \dots\}$.

Distribuição de Poisson

- Para a distribuição de Poisson é o modelo clássico para contagens definidas no conjunto $R_y = \{0, 1, 2, \dots\}$.
- A v.a. $y \sim \text{Poisson}(\mu)$ tem f.p. dada por:

$$P(Y = y|\mu) := f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y = 0, 1, 2, \dots; \mu > 0.$$

Distribuição de Poisson

- Para a distribuição de Poisson é o modelo clássico para contagens definidas no conjunto $R_y = \{0, 1, 2, \dots\}$.
- A v.a. $y \sim \text{Poisson}(\mu)$ tem f.p. dada por:

$$P(Y = y|\mu) := f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y = 0, 1, 2, \dots; \mu > 0.$$

- Por ter um único parâmetro, a distribuição de Poisson é pouco flexível na modelagem de dados de contagens.

Distribuição de Poisson

- Para a distribuição de Poisson é o modelo clássico para contagens definidas no conjunto $R_y = \{0, 1, 2, \dots\}$.
- A v.a. $y \sim \text{Poisson}(\mu)$ tem f.p. dada por:

$$P(Y = y|\mu) := f(y; \mu) = \frac{e^{-\mu} \mu^y}{y!}, \quad y = 0, 1, 2, \dots; \mu > 0.$$

- Por ter um único parâmetro, a distribuição de Poisson é pouco flexível na modelagem de dados de contagens.
- A distribuição de Poisson é caracterizada pela equidispersão:

$$E(y) = \text{Var}(y).$$

- Dentre as principais limitações da distribuição de Poisson, destacamos a impossibilidade de modelar adequadamente dados com:

- Dentre as principais limitações da distribuição de Poisson, destacamos a impossibilidade de modelar adequadamente dados com:
 - Superdispersão ($\text{Var}(y) > E(y)$) e subdispersão ($\text{Var}(y) < E(y)$);

- Dentre as principais limitações da distribuição de Poisson, destacamos a impossibilidade de modelar adequadamente dados com:
 - Superdispersão ($\text{Var}(y) > E(y)$) e subdispersão ($\text{Var}(y) < E(y)$);
 - Excesso ou escassez de zeros;

- Dentre as principais limitações da distribuição de Poisson, destacamos a impossibilidade de modelar adequadamente dados com:
 - Superdispersão ($\text{Var}(y) > E(y)$) e subdispersão ($\text{Var}(y) < E(y)$);
 - Excesso ou escassez de zeros;
 - Forte assimetria à direita.

- Dentre as principais limitações da distribuição de Poisson, destacamos a impossibilidade de modelar adequadamente dados com:
 - Superdispersão ($\text{Var}(y) > E(y)$) e subdispersão ($\text{Var}(y) < E(y)$);
 - Excesso ou escassez de zeros;
 - Forte assimetria à direita.
- Distribuições alternativas podem contornar as limitações da Poisson na modelagem de contagens.

Modelos probabilísticos para variáveis discretas

Modelos probabilísticos para variáveis discretas

Tabela 1: Distribuições com suporte em $R_y = \{0, 1, 2, \dots\}$

Distribuição	Nome gamlss	Parâmetro (função de ligação)			
		μ	σ	ν	τ
beta neg binomial	BNB	log	log	log	-
Delaporte	DEL	log	log	logit	-
discrete Burr XII	DBURR12	log	log	log	-
double Poisson	DPO	log	log	-	-
generalized Poisson	GPO	log	log	-	-
geometric	GEOM	log	-	-	-
geometric (original)	GEOMO	logit	-	-	-
negative binomial type I	NBI	log	log	-	-
negative binomial type II	NBII	log	log	-	-
neg binomial family	NBF	log	log	log	-
Poisson	PO	log	-	-	-
Poisson - inv Gaussian	PIG	log	log	-	-
Poisson - inv Gaussian 2 ^a	PIG2	log	log	-	-
Poisson shifted GIG	PSGIG	log	log	ident	logit
Sichel	SI	log	log	ident	-
Sichel (μ the mean)	SICHEL	log	log	ident	-
Waring	WARING	log	log	-	-
Yule	YULE	log	-	-	-

Modelos probabilísticos para variáveis discretas

Tabela 2: Distribuições com suporte em $R_y = \{0, 1, 2, \dots\}$ modificadas em $y = 0$

Distribuição	Nome gamlss	Parâmetro (função de ligação)			
		μ	σ	ν	τ
zero-adj beta neg binom	ZABNB	log	log	log	logit
zero-adj logarithmic	ZALG	logit	logit	-	-
zero-adj neg binomial	ZANBI	log	log	logit	-
zero-adj PIG	ZAPIG	log	log	logit	-
zero-adj Sichel	ZASICHEL	log	log	ident	logit
zero-adj Poisson	ZAP	log	logit	-	-
zero-adj Zipf	ZAZIPF	log	logit	-	-
zero-inf beta neg binom	ZIBNB	log	log	log	logit
zero-inf neg binomial	ZINBI	log	log	logit	-
zero-inf neg binom fam	ZINBF	log	log	log	logit
zero-inf Poisson	ZIP	log	logit	-	-
zero-inf Poisson (μ the mean)	ZIP2	log	logit	-	-
zero-inf PIG	ZIPIG	log	log	logit	-
zero-inf Sichel	ZISICHEL	log	log	ident	logit

Tabela 3: Distribuições com suporte em $R_y = \{0, 1, 2, \dots, n\}$

Distribuição	Nome gamlss	Parâmetro (função de ligação)			
		μ	σ	ν	τ
binomial	BI	logit	-	-	-
beta binomial	BB	logit	log	-	-
double binomial	DBI	logit	log	-	-
zero-adj beta binomial	ZABB	logit	log	logit	-
zero-adj binomial	ZABI	logit	logit	-	-
zero-inf beta binomial	ZIBB	logit	log	logit	-
zero-inf binomial	ZIBI	logit	logit	-	-

Tabela 4: Distribuições com suporte em $R_y = \{1, 2, \dots\}$

Distribuição	Nome gamlss	Parâmetro (ligação)			
		μ	σ	ν	τ
logarithmic	LG	logit	-	-	-
Zipf	BB	log	-	-	-

- Nesta sessão, vamos usar as demos do pacote `gamlss` para conhecer algumas das distribuições implementadas e suas propriedades.

Superdispersão e subdispersão

Superdispersão e subdispersão

- Superdispersão e subdispersão são recorrentes em problemas envolvendo dados de contagens.

Superdispersão e subdispersão

- Superdispersão e subdispersão são recorrentes em problemas envolvendo dados de contagens.
- Sob a distribuição de Poisson, os eventos sob contagem ocorrem de maneira aleatória ao longo do tempo, espaço, implicando em equidispersão, $\text{Var}(y) = E(y)$.

Superdispersão e subdispersão

- Superdispersão e subdispersão são recorrentes em problemas envolvendo dados de contagens.
- Sob a distribuição de Poisson, os eventos sob contagem ocorrem de maneira aleatória ao longo do tempo, espaço, implicando em equidispersão, $\text{Var}(y) = E(y)$.
- Quando os eventos ocorrem de maneira não aleatória, podemos ter superdispersão, $\text{Var}(y) > E(y)$, ou subdispersão, $\text{Var}(y) < E(y)$.

Superdispersão e subdispersão

- Superdispersão e subdispersão são recorrentes em problemas envolvendo dados de contagens.
- Sob a distribuição de Poisson, os eventos sob contagem ocorrem de maneira aleatória ao longo do tempo, espaço, implicando em equidispersão, $\text{Var}(y) = E(y)$.
- Quando os eventos ocorrem de maneira não aleatória, podemos ter superdispersão, $\text{Var}(y) > E(y)$, ou subdispersão, $\text{Var}(y) < E(y)$.
- A Figura 1 ilustra processos de contagens que caracterizados por equi, super e subdispersão.

Superdispersão e subdispersão




Figura 1: Ilustração de processos pontuais com equi, sub e superdispersão.

Superdispersão e subdispersão

- Não acomodar super (ou sub) dispersão na análise de dados de contagens pode comprometer a acurácia dos erros padrões, a taxa de cobertura dos intervalos de confiança, nível de significância e poder de testes de hipóteses;

Superdispersão e subdispersão

- Não acomodar super (ou sub) dispersão na análise de dados de contagens pode comprometer a acurácia dos erros padrões, a taxa de cobertura dos intervalos de confiança, nível de significância e poder de testes de hipóteses;
- Uma alternativa frequente nesses casos são os métodos de quase-verossimilhança;

Superdispersão e subdispersão

- Não acomodar super (ou sub) dispersão na análise de dados de contagens pode comprometer a acurácia dos erros padrões, a taxa de cobertura dos intervalos de confiança, nível de significância e poder de testes de hipóteses;
- Uma alternativa frequente nesses casos são os métodos de quase-verossimilhança;
- Na análise via quase-verossimilhança fazemos suposições apenas quanto aos dois primeiros momentos da distribuição da resposta: média e variância;

Superdispersão e subdispersão

- Não acomodar super (ou sub) dispersão na análise de dados de contagens pode comprometer a acurácia dos erros padrões, a taxa de cobertura dos intervalos de confiança, nível de significância e poder de testes de hipóteses;
- Uma alternativa frequente nesses casos são os métodos de quase-verossimilhança;
- Na análise via quase-verossimilhança fazemos suposições apenas quanto aos dois primeiros momentos da distribuição da resposta: média e variância;
- Como limitações, na abordagem de quase-verossimilhança não temos condições de estimar a função de probabilidades, não dispomos de uma função de verossimilhança...

- Usando GAMLSS, assumimos uma distribuição de probabilidades, o que nos habilita a estimar a função de probabilidades, produzir inferências usando a função de verossimilhança.

Superdispersão e subdispersão

- Usando GAMLSS, assumimos uma distribuição de probabilidades, o que nos habilita a estimar a função de probabilidades, produzir inferências usando a função de verossimilhança.
- As duas principais abordagens para lidar com sub e superdispersão no contexto de GAMLSS são:

Superdispersão e subdispersão

- Usando GAMLSS, assumimos uma distribuição de probabilidades, o que nos habilita a estimar a função de probabilidades, produzir inferências usando a função de verossimilhança.
- As duas principais abordagens para lidar com sub e superdispersão no contexto de GAMLSS são:
 - Distribuições geradas por misturas;

Superdispersão e subdispersão

- Usando GAMLSS, assumimos uma distribuição de probabilidades, o que nos habilita a estimar a função de probabilidades, produzir inferências usando a função de verossimilhança.
- As duas principais abordagens para lidar com sub e superdispersão no contexto de GAMLSS são:
 - Distribuições geradas por misturas;
 - Distribuições contínuas discretizadas.

Distribuições geradas por mistura

- Distribuições geradas por misturas permitem lidar com superdispersão ao assumir que a distribuição da variável resposta Y depende de uma v.a. γ cuja distribuição é conhecida.

Distribuições geradas por mistura

- Distribuições geradas por misturas permitem lidar com superdispersão ao assumir que a distribuição da variável resposta Y depende de uma v.a. γ cuja distribuição é conhecida.
- Seja Y uma v.a. discreta com função de probabilidade $P(Y = y|\gamma)$, e γ uma v.a. contínua com f.d.p. $f_\gamma(\gamma)$.

Distribuições geradas por mistura

- Distribuições geradas por misturas permitem lidar com superdispersão ao assumir que a distribuição da variável resposta Y depende de uma v.a. γ cuja distribuição é conhecida.
- Seja Y uma v.a. discreta com função de probabilidade $P(Y = y|\gamma)$, e γ uma v.a. contínua com f.d.p. $f_\gamma(\gamma)$.
- A função de probabilidade marginal (não condicional) de Y fica dada por:

$$P(Y = y) = \int_{R_\gamma} P(Y = y|\gamma) f_\gamma(\gamma) d\gamma.$$

Distribuições geradas por mistura

- Podemos assumir ainda γ uma v.a. discreta com função de probabilidade $P(\gamma = \gamma_j)$, produzindo como distribuição marginal:

$$P(Y = y) = \sum_{R_\gamma} P(Y = y | \gamma = \gamma_j) P(\gamma = \gamma_j).$$

Distribuições geradas por mistura

- Podemos assumir ainda γ uma v.a. discreta com função de probabilidade $P(\gamma = \gamma_j)$, produzindo como distribuição marginal:

$$P(Y = y) = \sum_{R_\gamma} P(Y = y | \gamma = \gamma_j) P(\gamma = \gamma_j).$$

- A distribuição resultante da mistura pode ou não ter uma forma explícita.

Distribuições geradas por mistura

- Podemos assumir ainda γ uma v.a. discreta com função de probabilidade $P(\gamma = \gamma_j)$, produzindo como distribuição marginal:

$$P(Y = y) = \sum_{R_\gamma} P(Y = y | \gamma = \gamma_j) P(\gamma = \gamma_j).$$

- A distribuição resultante da mistura pode ou não ter uma forma explícita.
- Nas situações em que não se tem uma forma explícita, métodos de aproximação (como quadratura Gaussiana) são usados para integrar γ .

Distribuições geradas por mistura - caso da Poisson com mistura contínua

- Misturas envolvendo a distribuição de Poisson são bastante usuais para modelar dados com superdispersão.

Distribuições geradas por mistura - caso da Poisson com mistura contínua

- Misturas envolvendo a distribuição de Poisson são bastante usuais para modelar dados com superdispersão.
- Neste caso, consideramos $Y|\gamma \sim \text{Poisson}(\mu\gamma)$, e $\gamma \sim f_\gamma(\gamma)$ definida em $(0, \infty)$.

Distribuições geradas por mistura - caso da Poisson com mistura contínua

- Misturas envolvendo a distribuição de Poisson são bastante usuais para modelar dados com superdispersão.
- Neste caso, consideramos $Y|\gamma \sim \text{Poisson}(\mu\gamma)$, e $\gamma \sim f_\gamma(\gamma)$ definida em $(0, \infty)$.
- Assumindo que $E(\gamma) = 1$, então a variável resultante da mistura terá média igual a μ .

Distribuições geradas por mistura - caso da Poisson com mistura contínua

- Misturas envolvendo a distribuição de Poisson são bastante usuais para modelar dados com superdispersão.
- Neste caso, consideramos $Y|\gamma \sim \text{Poisson}(\mu\gamma)$, e $\gamma \sim f_\gamma(\gamma)$ definida em $(0, \infty)$.
- Assumindo que $E(\gamma) = 1$, então a variável resultante da mistura terá média igual a μ .
- O caso mais conhecido de mistura contínua da distribuição Poisson é a **binomial negativa**.

Distribuições geradas por mistura - caso da Poisson com mistura contínua

- Seja $Y|\gamma \sim \text{Poisson}(\mu\gamma)$ e $\gamma \sim \text{gama}(1, \sigma^{1/2})$, isso é:

$$P(Y = y|\gamma) = \frac{e^{-\mu\gamma}(\mu\gamma)^y}{y!}$$

e

$$f_{\gamma}(\gamma) = \frac{\gamma^{1/\sigma-1} \exp(-\gamma/\sigma)}{\sigma^{(1/\sigma)} \Gamma(1/\sigma)}, \quad \text{para } \gamma > 0.$$

Distribuições geradas por mistura - Poisson com mistura contínua

- A distribuição marginal de Y fica dada por:

$$\begin{aligned} P(Y = y) &= \int_0^\infty \frac{e^{-\mu\gamma} (\mu\gamma)^y}{y!} \frac{\gamma^{1/\sigma-1} \exp(-\gamma/\sigma)}{\sigma^{(1/\sigma)} \Gamma(1/\sigma)} d\gamma \\ &= \frac{\Gamma(y + 1/\sigma)}{\Gamma(1/\sigma) \Gamma(y + 1)} \left(\frac{\sigma\mu}{1 + \sigma\mu} \right)^y \left(\frac{1}{1 + \sigma\mu} \right)^{1/\sigma}, \text{ para } y = 0, 1, \dots, \end{aligned}$$

com $\mu > 0$ e $\sigma > 0$ que corresponde à distribuição binomial negativa, $\text{NBI}(\mu, \sigma)$

Distribuições geradas por mistura - Poisson com mistura contínua

- A distribuição marginal de Y fica dada por:

$$\begin{aligned} P(Y = y) &= \int_0^\infty \frac{e^{-\mu\gamma} (\mu\gamma)^y}{y!} \frac{\gamma^{1/\sigma-1} \exp(-\gamma/\sigma)}{\sigma^{(1/\sigma)} \Gamma(1/\sigma)} d\gamma \\ &= \frac{\Gamma(y + 1/\sigma)}{\Gamma(1/\sigma) \Gamma(y + 1)} \left(\frac{\sigma\mu}{1 + \sigma\mu} \right)^y \left(\frac{1}{1 + \sigma\mu} \right)^{1/\sigma}, \text{ para } y = 0, 1, \dots, \end{aligned}$$

com $\mu > 0$ e $\sigma > 0$ que corresponde à distribuição binomial negativa, $\text{NBI}(\mu, \sigma)$

- Ao usar diferentes distribuições para γ temos diferentes distribuições marginais para Y , conforme pode ser visto na Tabela 5.

Distribuições geradas por mistura - Poisson com misturas contínuas e discretas

Tabela 5: Distribuições geradas por mistura - Poisson com misturas contínuas e discretas.

Distribuição	nome <code>gamlss</code>	Dist. Mistura	$E(Y)$	$Var(Y)$
Delaporte	$DEL(\mu, \sigma, \nu)$	$SG(1, \sigma^{1/2}, \nu)$	μ	$\mu + \sigma(1 - \mu)^2 \mu^2$
NB tipo I	$NBI(\mu, \sigma)$	$GA(1, \sigma^{1/2})$	μ	$\mu + \sigma \mu^2$
NB tipo II	$NBII(\mu, \sigma)$	$GA(1, \sigma^{1/2} \mu^{-1/2})$	μ	$\mu + \sigma \mu$
NB family	$NBF(\mu, \sigma, \nu)$	$GA(1, \sigma^{1/2} \mu^{\nu/2-1})$	μ	$\mu + \sigma \mu^\nu$
PIG	$PIG(\mu, \sigma)$	$IG(1, \sigma^{1/2})$	μ	$\mu + \sigma \mu^2$
Sichel	$SICHEL(\mu, \sigma, \nu)$	$GIG(1, \sigma^{1/2}, \nu)$	μ	$\mu + h(\sigma, \nu) \mu^2$
ZI Poisson	$ZIP(\mu, \sigma)$	$BI(1, 1-\sigma)$	$(1-\sigma)\mu$	$(1-\sigma)(\mu + \sigma \mu^2)$
ZI Poisson 2	$ZIP2(\mu, \sigma)$	$(1-\sigma)^{-1}BI(1, 1-\sigma)$	μ	$\mu + \frac{\sigma}{(1-\sigma)} \mu^2$
ZI NB	$ZINBI(\mu, \sigma, \nu)$	$ZAGA(1, \sigma^{1/2}, \nu)$	$(1-\nu)\mu$	$(1-\nu) \left[\mu + (\sigma + \nu) \mu^2 \right]$
ZI PIG	$ZIPIG(\mu, \sigma, \nu)$	$ZAIG(1, \sigma^{1/2})$	$(1-\nu)\mu$	$(1-\nu) \left[\mu + (\sigma + \nu) \mu^2 \right]$

- Nesta sessão R, vamos usar simulação para verificar algumas misturas resultantes da distribuição Poisson:

- Nesta sessão R, vamos usar simulação para verificar algumas misturas resultantes da distribuição Poisson:
 - Binomial negativa (Poisson com componente de mistura com distribuição gama);

- Nesta sessão R, vamos usar simulação para verificar algumas misturas resultantes da distribuição Poisson:
 - Binomial negativa (Poisson com componente de mistura com distribuição gama);
 - Poisson inflacionada de zeros (Poisson com componente de mistura com distribuição Bernoulli).

Distribuições contínuas discretizadas

Distribuições contínuas discretizadas

- Qualquer v.a. contínua com suporte no intervalo $(0, \infty)$ pode ser discretizada, originando uma nova distribuição útil para modelar contagens.

Distribuições contínuas discretizadas

- Qualquer v.a. contínua com suporte no intervalo $(0, \infty)$ pode ser discretizada, originando uma nova distribuição útil para modelar contagens.
- Seja W uma v.a. contínua com f.d.p., f.d.a. e função de sobrevivência denotadas, respectivamente, por $f_W(w)$, $F_W(w)$ e $S_W(w) = 1 - F_W(w)$.

Distribuições contínuas discretizadas

- Qualquer v.a. contínua com suporte no intervalo $(0, \infty)$ pode ser discretizada, originando uma nova distribuição útil para modelar contagens.
- Seja W uma v.a. contínua com f.d.p., f.d.a. e função de sobrevivência denotadas, respectivamente, por $f_W(w)$, $F_W(w)$ e $S_W(w) = 1 - F_W(w)$.
- A correspondente variável discretizada Y fica definida pela seguinte f.p.:

$$\begin{aligned} P(Y = y) &= P(y < W < y + 1) = \int_y^{y+1} f_W(w) dw \\ &= F_W(y + 1) - F_W(y) = S_W(y) - S_W(y + 1), \end{aligned}$$

enquanto a f.d.a. é simplesmente $F_Y(y) = F_W(y + 1)$, para $y = 0, 1, 2, \dots$

- Como exemplo, vamos considerar a versão discreta da distribuição Weibull.

Distribuições Weibull discreta

- Como exemplo, vamos considerar a versão discreta da distribuição Weibull.
- Seja $W \sim \text{WEI}(\mu, \sigma)$, isto é, W com f.d.p. e f.d.a. dadas por:

$$f_W(w|\mu, \sigma) = \frac{\sigma y^{\sigma-1}}{\mu^\sigma} \exp \left[- \left(\frac{y}{\mu} \right)^\sigma \right]$$

e

$$F_W(w|\mu, \sigma) = 1 - \exp \left[-(y/\mu)^\sigma \right],$$

com $y > 0$, $\mu > 0$ e $\sigma > 0$.

Distribuição Weibull discreta

- Desta forma, a distribuição Weibull discreta tem f.p. dada por:

$$P(Y = y|\mu, \sigma) = \{1 - \exp[-((y+1)/\mu)^\sigma]\} - \{1 - \exp[-(y/\mu)^\sigma]\},$$

Distribuição Weibull discreta

- Desta forma, a distribuição Weibull discreta tem f.p. dada por:

$$P(Y = y|\mu, \sigma) = \{1 - \exp[-((y+1)/\mu)^\sigma]\} - \{1 - \exp[-(y/\mu)^\sigma]\},$$

enquanto a f.d.a. é dada por:

$$F_Y(y|\mu, \sigma) = P(Y \leq y|\mu, \sigma) = 1 - \exp[-(y+1)/\mu)^\sigma],$$

para $y = 0, 1, 2, \dots$

Distribuição Weibull discreta

- Desta forma, a distribuição Weibull discreta tem f.p. dada por:

$$P(Y = y|\mu, \sigma) = \{1 - \exp[-((y+1)/\mu)^\sigma]\} - \{1 - \exp[-(y/\mu)^\sigma]\},$$

enquanto a f.d.a. é dada por:

$$F_Y(y|\mu, \sigma) = P(Y \leq y|\mu, \sigma) = 1 - \exp[-(y+1)/\mu)^\sigma],$$

para $y = 0, 1, 2, \dots$

- Vamos “construir” a versão discretizada da distribuição Weibull($\mu = 2, \sigma = 2$).

Distribuições Weibull discreta




Figura 2: Ilustração - distribuição Weibull discreta.

Tabela 6: Função de probabilidades e função distribuição acumulada - Weibull discreta

y	$P(W < y)$	$P(W < y+1)$	$P(Y=y)$	$P(Y \leq y)$
0	0.0000	0.2212	0.2212	0.2212
1	0.2212	0.6321	0.4109	0.6321
2	0.6321	0.8946	0.2625	0.8946
3	0.8946	0.9816	0.0870	0.9816
4	0.9816	0.9980	0.0164	0.9980
5	0.9980	0.9998	0.0018	0.9998

Distribuições contínuas discretizadas

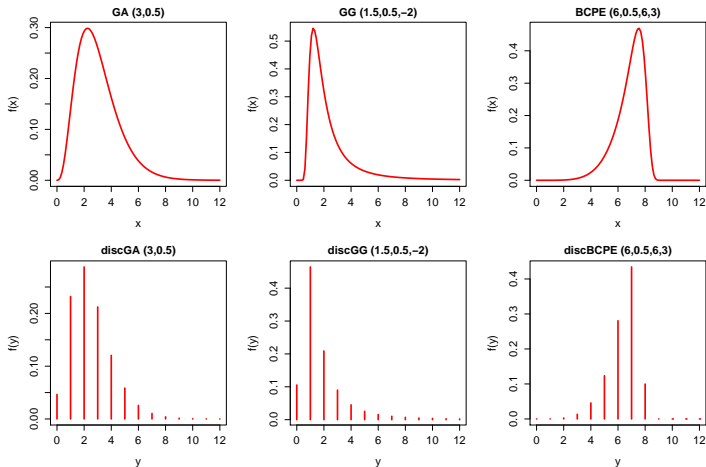


Figura 3: Distribuições contínuas discretizadas

- Em algumas aplicações, como em estudos de confiabilidade na Engenharia, é comum o interesse em variáveis discretas com suporte no conjunto $\{1, 2, 3, \dots\}$.

Distribuições contínuas discretizadas

- Em algumas aplicações, como em estudos de confiabilidade na Engenharia, é comum o interesse em variáveis discretas com suporte no conjunto $\{1, 2, 3, \dots\}$.
- Neste caso, variáveis discretizadas podem ser construídas de maneira semelhante, mas atribuindo as $P(y < W < y + 1)$ a $y + 1$, e não mais a y , para $y = 0, 1, 2, \dots$.

Distribuições contínuas discretizadas

- Em algumas aplicações, como em estudos de confiabilidade na Engenharia, é comum o interesse em variáveis discretas com suporte no conjunto $\{1, 2, 3, \dots\}$.
- Neste caso, variáveis discretizadas podem ser construídas de maneira semelhante, mas atribuindo as $P(y < W < y + 1)$ a $y + 1$, e não mais a y , para $y = 0, 1, 2, \dots$.
- Distribuições discretizadas podem ser criadas usando recursos do pacote `gamlss.cens`. Vamos ao R!

- Nesta sessão R, vamos usar dados de contagens de cistos encontrados em rins de ratos (base de dados `cysts`).

O problema do excesso ou escassez de zeros

- Problemas envolvendo contagens podem produzir frequências de contagens iguais a zero que são incompatíveis às ajustadas pelos modelos convencionais.

- Problemas envolvendo contagens podem produzir frequências de contagens iguais a zero que são incompatíveis às ajustadas pelos modelos convencionais.
- Nesses casos, modelos zero-inflacionados (*zero inflated models*) ou modelos zero-ajustados (*zero-adjusted models*) são recomendáveis.

- Problemas envolvendo contagens podem produzir frequências de contagens iguais a zero que são incompatíveis às ajustadas pelos modelos convencionais.
- Nesses casos, modelos zero-inflacionados (*zero inflated models*) ou modelos zero-ajustados (*zero-adjusted models*) são recomendáveis.
- Modelos zero-inflacionados podem lidar apenas com excesso de zeros, enquanto modelos zero-ajustados podem lidar tanto com excesso quanto com escassez de zeros.

Distribuições zero-inflacionadas

- Uma v.a. Y tem distribuição zero-inflacionada se ela assume valor zero com probabilidade p e segue alguma distribuição de probabilidades discreta com probabilidade $1 - p$.

- Uma v.a. Y tem distribuição zero-inflacionada se ela assume valor zero com probabilidade p e segue alguma distribuição de probabilidades discreta com probabilidade $1 - p$.
- Assim, para $Y \sim \text{ZID}$:

$$P(Y = y) = \begin{cases} p + (1 - p)P(Y_1 = 0) & \text{se } y = 0 \\ (1 - p)P(Y_1 = y) & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

onde Y_1 representa uma v.a. com distribuição de contagem, e $0 < p < 1$, tal que $P(Y = 0) > P(Y_1 = 0)$.

- Desta forma, a média e a variância de Y ficam dadas por:

$$E(Y) = 0 \times P(Y = 0) + (1 - p) \times \sum_{i=1}^{\infty} y P(Y_1 = y) = (1 - p)E(Y_1)$$

e

$$\text{Var}(Y) = (1 - p)\text{Var}(Y_1) + p(1 - p) [E(Y_1)]^2.$$

Distribuições zero-inflacionadas

- Desta forma, a média e a variância de Y ficam dadas por:

$$E(Y) = 0 \times P(Y = 0) + (1 - p) \times \sum_{i=1}^{\infty} y P(Y_1 = y) = (1 - p)E(Y_1)$$

e

$$\text{Var}(Y) = (1 - p)\text{Var}(Y_1) + p(1 - p) [E(Y_1)]^2.$$

- Além disso, a f.d.a. de Y é dada por:

$$F_Y(y) = P(Y \leq y) = p + (1 - p)P(Y_1 \leq y), \quad \text{para } y = 0, 1, 2, \dots$$

Distribuições zero-inflacionadas




Figura 4: Ilustração - distribuição Poisson zero-inflacionada.

Distribuição Poisson zero-inflacionada

- A v.a. Y tem distribuição Poisson zero-inflacionada (ZIP) se assume valor zero com probabilidade σ ($0 < \sigma < 1$) e se comporta como uma $\text{Poisson}(\mu)$ com probabilidade $1 - \sigma$:

Distribuição Poisson zero-inflacionada

- A v.a. Y tem distribuição Poisson zero-inflacionada (ZIP) se assume valor zero com probabilidade σ ($0 < \sigma < 1$) e se comporta como uma $\text{Poisson}(\mu)$ com probabilidade $1 - \sigma$:

$$P(Y = y | \mu, \sigma) = \begin{cases} \sigma + (1 - \sigma)e^{-\mu} & \text{se } y = 0 \\ (1 - \sigma) \frac{\mu^y e^{-\mu}}{y!} & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

Distribuição Poisson zero-inflacionada

- A v.a. Y tem distribuição Poisson zero-inflacionada (ZIP) se assume valor zero com probabilidade σ ($0 < \sigma < 1$) e se comporta como uma $\text{Poisson}(\mu)$ com probabilidade $1 - \sigma$:

$$P(Y = y | \mu, \sigma) = \begin{cases} \sigma + (1 - \sigma)e^{-\mu} & \text{se } y = 0 \\ (1 - \sigma) \frac{\mu^y e^{-\mu}}{y!} & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

com média $E(Y) = (1 - \sigma)\mu$ e variância $\text{Var}(Y) = (1 - \sigma)\mu + \sigma(1 - \sigma)\mu^2$.

Distribuição binomial negativa zero-inflacionada

- A v.a. Y tem distribuição binomial negativa zero-inflacionada (ZINBI) se assume valor zero com probabilidade ν ($0 < \nu < 1$) e se comporta como uma $\text{NBI}(\mu, \sigma)$ com probabilidade $1 - \nu$:

Distribuição binomial negativa zero-inflacionada

- A v.a. Y tem distribuição binomial negativa zero-inflacionada (ZINBI) se assume valor zero com probabilidade ν ($0 < \nu < 1$) e se comporta como uma $\text{NBI}(\mu, \sigma)$ com probabilidade $1 - \nu$:

$$P(Y = y | \mu, \sigma, \nu) = \begin{cases} \nu + (1 - \nu)P(Y_1 = 0 | \mu, \sigma) & \text{se } y = 0 \\ (1 - \nu)P(Y_1 = y | \mu, \sigma) & \text{se } y = 1, 2, 3, \dots \end{cases}$$

Distribuição binomial negativa zero-inflacionada

- A v.a. Y tem distribuição binomial negativa zero-inflacionada (ZINBI) se assume valor zero com probabilidade ν ($0 < \nu < 1$) e se comporta como uma $\text{NBI}(\mu, \sigma)$ com probabilidade $1 - \nu$:

$$P(Y = y | \mu, \sigma, \nu) = \begin{cases} \nu + (1 - \nu)P(Y_1 = 0 | \mu, \sigma) & \text{se } y = 0 \\ (1 - \nu)P(Y_1 = y | \mu, \sigma) & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

onde $\mu > 0$, $\sigma > 0$, $Y_1 \sim \text{NBI}(\mu, \sigma)$, com média $E(Y) = (1 - \nu)\mu$ e variância $\text{Var}(Y) = (1 - \nu)\mu + (1 - \nu)(\sigma + \nu)\mu^2$.

- Outras distribuições zero-inflacionadas disponíveis no pacote `gamlss` são:

- Outras distribuições zero-inflacionadas disponíveis no pacote `gamlss` são:
 - ZIP2(μ, σ): Poisson zero-inflacionada tipo 2;

- Outras distribuições zero-inflacionadas disponíveis no pacote `gamlss` são:
 - $\text{ZIP2}(\mu, \sigma)$: Poisson zero-inflacionada tipo 2;
 - $\text{ZIPIG}(\mu, \sigma, \nu)$: PIG zero-inflacionada;

- Outras distribuições zero-inflacionadas disponíveis no pacote `gamlss` são:
 - $\text{ZIP2}(\mu, \sigma)$: Poisson zero-inflacionada tipo 2;
 - $\text{ZIPIG}(\mu, \sigma, \nu)$: PIG zero-inflacionada;
 - $\text{ZIBNB}(\mu, \sigma, \nu)$: BNB zero-inflacionada;

- Outras distribuições zero-inflacionadas disponíveis no pacote `gamlss` são:
 - $\text{ZIP2}(\mu, \sigma)$: Poisson zero-inflacionada tipo 2;
 - $\text{ZIPIG}(\mu, \sigma, \nu)$: PIG zero-inflacionada;
 - $\text{ZIBNB}(\mu, \sigma, \nu)$: BNB zero-inflacionada;
 - $\text{ZISICHEL}(\mu, \sigma, \nu, \tau)$: SICHEL zero-inflacionada.

Distribuição K-inflacionadas

- Como caso mais geral, podemos definir uma distribuição inflacionada em $K \in \{0, 1, 2, \dots\}$:

- Como caso mais geral, podemos definir uma distribuição inflacionada em $K \in \{0, 1, 2, \dots\}$:

$$P(Y = y) = \begin{cases} p + (1 - p)P(Y_1 = K) & \text{se } y = K \\ (1 - p)P(Y_1 = y) & \text{se } y = 0, 1, 2, \dots \text{ (exceto } K) \end{cases}$$

Distribuição K-inflacionadas

- Como caso mais geral, podemos definir uma distribuição inflacionada em $K \in \{0, 1, 2, \dots\}$:

$$P(Y = y) = \begin{cases} p + (1 - p)P(Y_1 = K) & \text{se } y = K \\ (1 - p)P(Y_1 = y) & \text{se } y = 0, 1, 2, \dots \text{ (exceto } K) \end{cases}$$

- O pacote `gamlss.countKinf` permite gerar distribuições K-inflacionadas a partir das distribuições atualmente implementadas. E vamos ao R!

- Vamos retomar os dados de frequências de cistos em rins de ratos, e usar distribuições zero-inflacionadas na modelagem.

Distribuições zero-ajustadas

Distribuições zero-ajustadas (ou zero alteradas)

- Dizemos que Y é uma v.a. discreta zero-ajustada (ou zero-alterada) se:

Distribuições zero-ajustadas (ou zero alteradas)

- Dizemos que Y é uma v.a. discreta zero-ajustada (ou zero-alterada) se:
 - Assume valor zero com probabilidade p ($0 < p < 1$);

Distribuições zero-ajustadas (ou zero alteradas)

- Dizemos que Y é uma v.a. discreta zero-ajustada (ou zero-alterada) se:
 - Assume valor zero com probabilidade p ($0 < p < 1$);
 - Se comporta como uma v.a. discreta com distribuição truncada em zero (denotemos por Y_1) para $y = 1, 2, 3, \dots$

Distribuições zero-ajustadas (ou zero alteradas)

- Dizemos que Y é uma v.a. discreta zero-ajustada (ou zero-alterada) se:
 - Assume valor zero com probabilidade p ($0 < p < 1$);
 - Se comporta como uma v.a. discreta com distribuição truncada em zero (denotemos por Y_1) para $y = 1, 2, 3, \dots$
- Observe que, diferentemente das distribuições zero-inflacionadas, aqui $P(Y = 0)$ não depende da distribuição de Y_1 , mas somente de p ;

Distribuições zero-ajustadas (ou zero alteradas)

- Dizemos que Y é uma v.a. discreta zero-ajustada (ou zero-alterada) se:
 - Assume valor zero com probabilidade p ($0 < p < 1$);
 - Se comporta como uma v.a. discreta com distribuição truncada em zero (denotemos por Y_1) para $y = 1, 2, 3, \dots$
- Observe que, diferentemente das distribuições zero-inflacionadas, aqui $P(Y = 0)$ não depende da distribuição de Y_1 , mas somente de p ;
- Desta forma, diferentemente das zero-inflacionadas, as distribuições zero-ajustadas podem acomodar também escassez de zero (para p suficientemente pequeno).

Distribuições zero-ajustadas (ou zero alteradas)

- A f.p. de Y com distribuição zero-ajustada ($Y \sim \text{ZAD}$) pode ser representada, de maneira genérica, por:

$$P(Y = y) = \begin{cases} p & \text{se } y = 0 \\ (1 - p)P(Y_1 = y) & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

onde Y_1 é a versão truncada em zero de uma v.a. discreta com suporte em $\{0, 1, 2, \dots\}$ (denotemos a variável não truncada por Y_2).

Distribuições zero-ajustadas (ou zero alteradas)

- A f.p. de Y com distribuição zero-ajustada ($Y \sim \text{ZAD}$) pode ser representada, de maneira genérica, por:

$$P(Y = y) = \begin{cases} p & \text{se } y = 0 \\ (1 - p)P(Y_1 = y) & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

onde Y_1 é a versão truncada em zero de uma v.a. discreta com suporte em $\{0, 1, 2, \dots\}$ (denotemos a variável não truncada por Y_2).

- De maneira equivalente:

$$P(Y = y) = \begin{cases} p & \text{se } y = 0 \\ \frac{(1-p)P(Y_2=y)}{1-P(Y_2=0)} & \text{se } y = 1, 2, 3, \dots \end{cases}$$

Distribuições zero-ajustadas (ou zero alteradas)

- Seja $c = \frac{(1-p)}{1-P(Y_2=0)}$. A média e a variância de $Y \sim \text{ZAD}$ ficam dadas por:

$$E(Y) = cE(Y_2) \text{ e } \text{Var}(Y) = c\text{Var}(Y_2) + c(1 - c) [E(Y_2)]^2.$$

Distribuições zero-ajustadas (ou zero alteradas)

- Seja $c = \frac{(1-p)}{1-P(Y_2=0)}$. A média e a variância de $Y \sim \text{ZAD}$ ficam dadas por:

$$E(Y) = cE(Y_2) \text{ e } \text{Var}(Y) = c\text{Var}(Y_2) + c(1-c) [E(Y_2)]^2.$$

- Já a f.d.a. de Y é dada por:

$$P(Y \leq y) = \begin{cases} p & \text{se } y = 0 \\ p + c[P(Y_2 \leq y) - P(Y_2 = 0)] & \text{se } y = 1, 2, 3, \dots \end{cases}$$

Distribuições zero-ajustadas




Figura 5: Ilustração - distribuição Poisson zero-ajustada.

Distribuição Poisson zero-ajustada

- A distribuição Poisson zero-ajustada (ZAP), assumimos uma mistura de dois componentes: zero, com probabilidade σ ($0 < \sigma < 1$), e uma $\text{Poisson}(\mu)$ truncada em zero, com probabilidade $(1 - \sigma)$.

Distribuição Poisson zero-ajustada

- A distribuição Poisson zero-ajustada (ZAP), assumimos uma mistura de dois componentes: zero, com probabilidade σ ($0 < \sigma < 1$), e uma $\text{Poisson}(\mu)$ truncada em zero, com probabilidade $(1 - \sigma)$.
- A f.p. de $Y \sim \text{ZAP}(\mu, \sigma)$ é dada por:

$$P(Y = y|\mu, \sigma) = \begin{cases} \sigma & \text{se } y = 0 \\ \frac{(1-\sigma)e^{-\mu}\mu^y}{y!(1-e^{-\mu})} & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

com $\mu > 0$. A média e a variância de Y são dadas por:

$$E(Y) = \frac{(1 - \sigma)\mu}{(1 - e^{-\mu})} \text{ e } \text{Var}(Y) = (1 + \mu)E(Y) - [E(Y)]^2.$$

Distribuição binomial zero-ajustada

- A distribuição binomial negativa zero-ajustada (ZANBI) é gerada por uma mistura de dois componentes: zero, com probabilidade ν ($0 < \nu < 1$), e uma $\text{NBI}(\mu, \sigma)$ truncada em zero, com probabilidade $(1 - \nu)$.

Distribuição binomial zero-ajustada

- A distribuição binomial negativa zero-ajustada (ZANBI) é gerada por uma mistura de dois componentes: zero, com probabilidade ν ($0 < \nu < 1$), e uma NBI(μ, σ) truncada em zero, com probabilidade $(1 - \nu)$.
- A f.p. de $Y \sim \text{ZANBI}(\mu, \sigma)$ é dada por:

$$P(Y = y | \mu, \sigma, \nu) = \begin{cases} \nu & \text{se } y = 0 \\ \frac{(1-\nu)P(Y_2=y|\mu, \sigma)}{1-P(Y_2=0|\mu, \sigma)} & \text{se } y = 1, 2, 3, \dots, \end{cases}$$

com $\mu > 0$, $\sigma > 0$ e $Y_2 \sim \text{NBI}(\mu, \sigma)$. A média e a variância de Y são dadas por:

$$E(Y) = \frac{(1 - \nu)\mu [1 - (1 + \mu\sigma)^{-1/\sigma}]^{-1}}{(1 - e^{-\mu})}$$

$$\text{Var}(Y) = [1 + (\sigma + 1)\mu] E(Y) - [E(Y)]^2.$$

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:
 - $\text{ZALG}(\mu, \sigma)$: zero-ajustada LG;

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:
 - $\text{ZALG}(\mu, \sigma)$: zero-ajustada LG;
 - $\text{ZAZIPF}(\mu, \sigma)$: zero-ajustada ZIPF;

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:
 - $\text{ZALG}(\mu, \sigma)$: zero-ajustada LG;
 - $\text{ZAZIPF}(\mu, \sigma)$: zero-ajustada ZIPF;
 - $\text{ZAPIG}(\mu, \sigma, \nu)$: zero-ajustada PIG;

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:
 - $\text{ZALG}(\mu, \sigma)$: zero-ajustada LG;
 - $\text{ZAZIPF}(\mu, \sigma)$: zero-ajustada ZIPF;
 - $\text{ZAPIG}(\mu, \sigma, \nu)$: zero-ajustada PIG;
 - $\text{ZABNB}(\mu, \sigma, \nu, \tau)$: zero-ajustada BNB;

- Outras distribuições zero-ajustadas implementadas no pacote `gamlss`:
 - $\text{ZALG}(\mu, \sigma)$: zero-ajustada LG;
 - $\text{ZAZIPF}(\mu, \sigma)$: zero-ajustada ZIPF;
 - $\text{ZAPIG}(\mu, \sigma, \nu)$: zero-ajustada PIG;
 - $\text{ZABNB}(\mu, \sigma, \nu, \tau)$: zero-ajustada BNB;
 - $\text{ZASICHEL}(\mu, \sigma, \nu, \tau)$: zero-ajustada SICHEL.

- Vamos usar dados de frequência de visitas ao pediatra como motivação para o ajuste de modelos zero-ajustados e zero-inflacionados.

- Agora, um problema de regressão para dados de contagens (seção 7.7.3 do livro texto).

Resumindo

- Modelos para variáveis discretas são amplamente utilizados na análise de dados de contagens;

- Modelos para variáveis discretas são amplamente utilizados na análise de dados de contagens;
- Problemas como super (ou sub) dispersão, excesso (ou escassez) de zeros, requerem métodos e modelos específicos;

- Modelos para variáveis discretas são amplamente utilizados na análise de dados de contagens;
- Problemas como super (ou sub) dispersão, excesso (ou escassez) de zeros, requerem métodos e modelos específicos;
- A biblioteca `gamlss` tem implementados modelos probabilísticos para dados de contagens, permitindo lidar adequadamente com os problemas mencionados;

- Modelos para variáveis discretas são amplamente utilizados na análise de dados de contagens;
- Problemas como super (ou sub) dispersão, excesso (ou escassez) de zeros, requerem métodos e modelos específicos;
- A biblioteca `gamlss` tem implementados modelos probabilísticos para dados de contagens, permitindo lidar adequadamente com os problemas mencionados;
- Novos modelos podem ser gerados por meio de misturas ou discretização de variáveis contínuas.

Próximos passos

Próximos passos

- Família GAMLSS - tópicos adicionais

- Família GAMLSS - tópicos adicionais
 - Distribuições contínuas com suporte em $(0,1)$;

- Família GAMLSS - tópicos adicionais
 - Distribuições contínuas com suporte em $(0,1)$;
 - Distribuições contínuas inflacionadas;

- Família GAMLSS - tópicos adicionais
 - Distribuições contínuas com suporte em $(0,1)$;
 - Distribuições contínuas inflacionadas;
 - Geração de novas distribuições contínuas com suporte em $(0,1)$ e inflacionadas;

- Família GAMLSS - tópicos adicionais
 - Distribuições contínuas com suporte em $(0,1)$;
 - Distribuições contínuas inflacionadas;
 - Geração de novas distribuições contínuas com suporte em $(0,1)$ e inflacionadas;
 - Recursos adicionais.