Segmentação: exemplo chocolate

Adilson dos Anjos

Segmentação

Pacotes utilizados

```
library(FactoMineR)
library(readxl)
library(graphics)
library(cluster)
library(fpc)
```

5

Dados sobre Chocolate

5

6

C5

C6

5

```
choco<-read_excel('chocolate.xls')
head(choco)</pre>
```

A tibble: 6 x 7

Amostra Marca1A Marca1L Marca2A Marca2L Marca3A Marca3L

<chr> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <fb
7
9
4
6
5
7
2
C2
7
9
2
6
1
7
3
C3
6
8
3
3
5
4
C4
8
9
6
6
4
7

6

- Vamos utiliar apenas as notas atribuídas a cada marca por cada consumidor;
- ▶ No arquivo, as colunas 2:7 correspondem a essas notas:

choco<-choco[,2:7]

Obtendo a matriz de distâncias euclidianas

No R, esse é o tipo de objeto necesário para se obter os agrupamentos:

```
d <- dist(as.matrix(choco))
head(d)</pre>
```

[1] 4.472136 4.472136 2.449490 6.244998 5.099020 5.477226

Obtenção do agrupamento pelo Método hierárquico:

Vamos utilizar o método de Ward:

```
hc1 <- hclust(d, method = 'ward.D' ) # Método de Ward
hc1</pre>
```

```
Call:
hclust(d = d, method = "ward.D")
```

Cluster method : ward.D Distance : euclidean

Number of objects: 25

Obtenção do Dendrograma:

Graficamente, pode-se obter o resultado do agrupamento por meio de um dendograma:

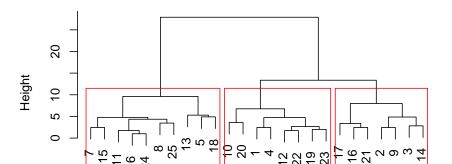
Dendrograma – Dados dos chocolates



Identificando os grupos formados

▶ Definimos 3 grupos:

Dendrograma – Dados dos chocolates



Definindo um ponto de corte para formar grupos:

▶ Aqui é possível obter os consumidores de cada agrupamento:

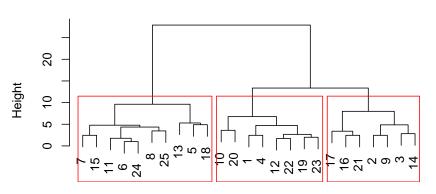
```
groups <- cutree(hc1, k=3)
groups</pre>
```

```
[1] 1 2 2 1 3 3 3 3 2 1 3 1 3 2 3 2 2 3 1 1 2 1 1 3 3
```

Como seria o gráfico com 3 grupos:

```
plot(hc1, main= "Dendrograma - Dados dos chocolates", xlab:
rect.hclust(hc1, k=3, border="red")
```

Dendrograma – Dados dos chocolates



Método K médias

```
cl <- kmeans(choco, 3)
cl$cluster</pre>
```

 $[1] \ 1 \ 1 \ 1 \ 1 \ 2 \ 2 \ 2 \ 2 \ 1 \ 3 \ 2 \ 3 \ 2 \ 1 \ 2 \ 3 \ 1 \ 2 \ 3 \ 1 \ 3 \ 3 \ 2 \ 2$

Centro do cluster para cada variável/atributo.

Observe as médias para cada agrupamento:

cl\$centers

```
Marca1A Marca1L Marca2A Marca2L Marca3A Marca3L
1 7.25 8.875000 3.875000 4.750000 3.625000 6.500000
2 4.90 6.000000 5.400000 5.700000 6.300000 8.700000
3 7.00 8.714286 5.857143 5.857143 6.571429 5.571429
```

Padronização das variáveis (opcional)

Utilizar quando a escala das variáveis for diferente.

choco.p<-scale(choco)</pre>

k-medias

cl <- kmeans(choco.p, 2)</pre>

Tamanho do cluster

Quantos indivíduos em cada cluster:

cl\$size

[1] 15 10

Mostra o centróide

► A nota média (observe que a nota foi padronizada) de cada agrupamento para cada variável:

cl\$centers

```
Marca1A Marca1L Marca2A Marca2L Marca3A
1 -0.2390022 -0.2906867 0.6862981 0.5498491 0.4104465
2 0.3585033 0.4360301 -1.0294472 -0.8247736 -0.6156697 -
```

Mostra os grupos

Onde cada indivíduo foi localizado:

cl\$cluster

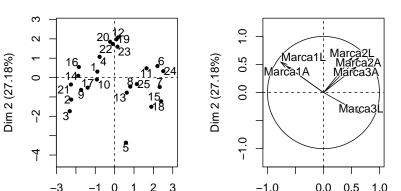
[1] 2 2 2 1 2 1 1 1 2 2 1 1 1 2 1 2 2 1 1 1 1 1 1

Utilizando o método das Componentes Principais:

Qual sua percepção de agrupamento?

```
par(mfrow=c(1,2))
choco.pca<-PCA(choco)</pre>
```

Individuals factor map (PCA) Variables factor map (PCA)

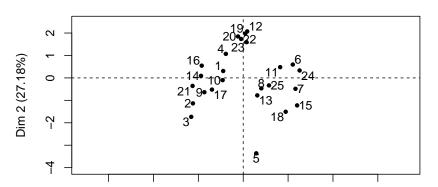


Gerando os gráficos individuais

Consumidores:

```
par(mfrow=c(1,1))
plot(choco.pca,choix=c('ind'))
```

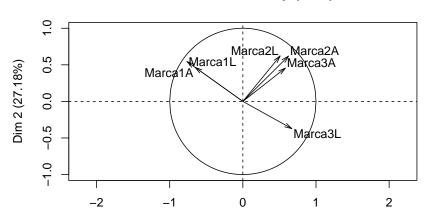
Individuals factor map (PCA)



Marcas

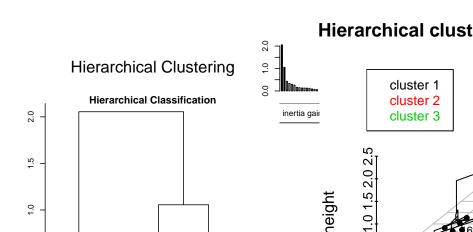
```
par(mfrow=c(1,1))
plot(choco.pca,choix=c('var'))
```

Variables factor map (PCA)



▶ O argumento *nb.clust=-1* utiliza o número de cluster sugerido pelo programa:

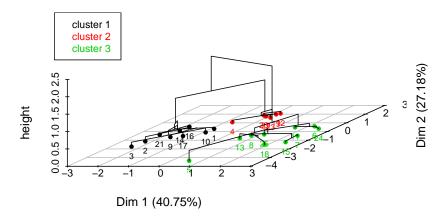
```
par(mfrow=c(1,1))
choco.hpc<-HCPC(choco.pca,nb.clust=-1)</pre>
```



Outra visualização gráfica:

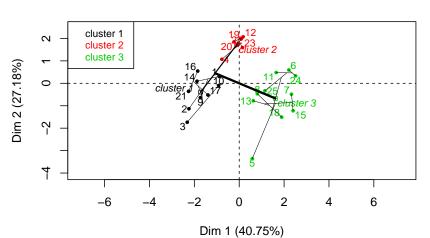
plot(choco.hpc)

Hierarchical clustering on the factor map



Mais uma visualização gráfica:

Factor map



Número de observações por grupo

table(choco.hpc\$data.clust\$clus)

- 1 2 3
- 9 6 10

6.24

0.415

1.196

Descrição dos grupos

choco.hpc\$desc.var

Marca1A 2.091269

Eta2

MarcalL 0.7189962 8.626491e-07

\$quanti.var

```
Marca2A 0.6614140 6.704392e-06
Marca3L 0.6443551 1.151285e-05
Marca1A 0.5112325 3.802989e-04
Marca2L 0.3276846 1.268538e-02
Marca3A 0.2520279 4.099579e-02
$quanti
$quanti$`1`
           v.test Mean in category Overall mean sd in category
Marca1L 2.493042
                          8.777778
                                            7.68
```

7.111111

P-value

Outras descrições

Consumidores típicos de cada cluster:

```
choco.hpc$desc.ind$para
```

```
Cluster: 1
       14
0.8061739 1.3514587 1.3683779 1.5623851 1.6197491
Cluster: 2
                23
       22
                       19
                                     12
0.4627331 0.8777349 1.0237452 1.1859265 1.4611663
Cluster: 3
                           24
                                               15
0.7945292 1.2349760 1.4506663 1.5046516 1.5099218
```

Sensometria, 2018

para -> indivíduo típico

o indivíduo 14 é típico do cluster 1

Consumidores mais distantes de cada cluster:

choco.hpc\$desc.ind\$dist

```
Cluster: 1
                      21
4.282977 4.206401 3.503739 3.077185 2.938673
Cluster: 2
     12
              19
                   20
                               22
                                        23
3.418109 3.160583 3.082706 2.854715 2.784526
Cluster: 3
     18
           15
                                        24
4.006121 4.001038 3.838864 3.306021 3.135607
```

Sensometria, 2018

dist -> distância do indivíduo e o centro dos outros clusters

o indivíduo mais distante do cluster 1 é o 2